

博士学位论文

多无人机系统的协同目标分配和航迹规划 方法研究

**RESEARCH ON COOPERATIVE TARGET
ASSIGNMENT AND PATH PLANNING FOR
MULTI-UNMANNED AIRCRAFT SYSTEM**

赵 明

哈尔滨工业大学

2016 年 6 月

国内图书分类号：TP311.5

学校代码：10213

国际图书分类号：681.3

密级：公开

工学博士学位论文

多无人机系统的协同目标分配和航迹规划 方法研究

博士研究生：赵明

导师：苏小红教授

申请学位：工学博士

学科：计算机科学与技术

所在单位：计算机科学与技术学院

答辩日期：2016年6月

授予学位单位：哈尔滨工业大学

Classified Index: TP311.5

U.D.C: 681.3

Dissertation for the Doctoral Degree in Engineering

**RESEARCH ON COOPERATIVE TARGET
ASSIGNMENT AND PATH PLANNING FOR
MULTI-UNMANNED AIRCRAFT SYSTEM**

Candidate :	Zhao Ming
Supervisor :	Prof. Su Xiaohong
Academic Degree Applied for :	Doctor of Engineering
Speciality :	Computer Science and Technology
Affiliation :	School of Computer Science and Technology
Date of Defence :	June, 2016
Degree-Conferring-Institution :	Harbin Institute of Technology

摘 要

多无人机系统协同作战任务规划是在约束条件复杂的多模型环境下,同时对异构的多架或多编队无人机进行系统控制和优化的问题。它通常由多机协同的多目标分配、多航迹规划和在线重规划三部分组成。多机协同的难点在于不仅要考虑每架无人机自身的飞行性能、约束限制条件和毁伤概率等问题;还要解决多无人机之间的协同合作和避免冲突等问题。此外,异构的目标分配模型、真实的三维环境、多个禁飞区或雷达威胁、被打击目标的执行顺序、航迹的表示和任务执行时环境的变化等都会给任务协同规划增加难度。因此,如何实施有效的目标分配策略、规划切实可行的平滑航迹、并适应环境的动态变化是解决这一问题的关键。

本文针对三维环境下多机协同任务规划的难点,以及如何在复杂的三维地形环境和多约束条件下,为无人机系统中执行任务的每架无人机分配合理的任务目标、规划安全可飞且代价较小的协同航迹等问题,在最优化理论上建立目标分配和航迹规划的统一模型,应用一致的分配代价矩阵处理目标分配;应用空间模糊集和协同相关性表示航迹关键路径点。重点研究了多机协同的目标分配、航迹规划和在线重规划问题。建立高效的任務空间表示,并改进多种优化方法进行问题求解,同时展开仿真实验进行验证。

首先,研究三维环境下满足自身和协同约束的多机系统协同目标分配问题。根据无人机与目标的量化对应关系,结合平衡指派和不平衡指派建立统一的目标分配框架;提出利用空间垂直切面快速估算航程代价的方法,并用航程代价矩阵优化目标分配算法;研究多机协同的约束条件、计算约束违背量,使分配结果更加准确。模型统一了单对单任务、多对单任务和群巡游任务的处理方式,尤其提出了群巡游任务的代价矩阵构建方法,保证与其他模型具有统一的代价矩阵形式,由此确保能够用一致的算法进行问题求解。该方法克服了传统目标分配问题中模型不统一,算法针对性差的问题。

其次,针对将多个预打击的目标分配给不同无人机时存在的模型不一致、任务规模大和规划时间长等难点问题,设计了基于航程代价、可匹配多种模型的统一基因编码策略,并在此基础上结合代价矩阵映射差分规则,以适应离散化求解。在求解过程中,采用三维航程代价表示无人机和目标的分配关系,并通过映射和反映射规则,将离散问题转换为连续问题进行求解。同时结合动态

交叉率混合差分进化策略，调整算法搜索时探测性与开发性的平衡，避免陷入局部最优。该算法能够用统一的基因编码和差分进化策略求解多模型的多机协同目标分配问题，有效提高了目标分配的准确性，且适合解决较大尺度目标分配任务。

再次，针对多无人机在三维环境下航迹规划搜索空间大、多机协同困难等问题，提出三维多机多目标协同航迹规划和平滑算法，将三维空间模糊表示和人工文化算法引入求解范畴。首先建立了空间网格点与航迹规划的模糊隶属关系，用模糊集合表示空间网格点，提高关键路径点的被关注度；然后用综合知识构建文化算法的信念集，以剪枝航迹规划的搜索范围；在种群集则利用多目标差分进化算法规划满足多机协同约束的帕累托最优解航迹组合；最后，通过信息共享，不断促进知识的积累、增加种群的多样性、并修正规划搜索的方向。该方法提高了关键路径点选取的效率，能够探索空间中更多的未知区域，有助于快速规划出多条可行的协同航迹。

此外，为了获得安全可飞的航迹，应用曲线拟合的方法对多条协同航迹进行平滑逼近。首先将航迹的关键路径点作为样条曲线的控制点，在三维空间应用三次 B 样条曲线进行航迹平滑。然后，为了降低平滑导致的路径点偏离失效，进一步反求出可通过当前关键路径点的样条曲线控制点，使平滑后的航迹能够通过必须经过的关键路径点。

最后，针对多无人机协同执行多个任务时，区域实时变化可能导致的任务失败、协同违背等问题，提出一种结合协同模糊 C 均值聚类和多 Q 学习的航迹重规划方法。该方法首先基于空间点的模糊隶属度和协同任务相关性构建空间模糊协同矩阵，并按时更新该矩阵以反映规划空间的动态变化。然后，以已知航迹的关键路径点为聚类初始中心，结合模糊协同矩阵在规划空间的各步长面上进行协同模糊 C 均值聚类，对新的可行路径点按任务进行划分。同时，将聚类的各任务分类作为 Q 学习的状态空间，将动态模糊协同矩阵作为 Q 学习的回报函数，采用多 Q 学习算法在各任务的状态空间同步进行多阶段协同航迹重规划。该方法能够适应环境的动态改变，有效约减任务规划空间，并提高了学习算法的搜索效率，可以重规划出有效的多机协同航迹。

关键词：多无人机系统；多目标分配；协同航迹规划；航迹重规划；三维空间；差分进化

Abstract

The multi-unmanned aircraft system (MUAS) cooperative mission planning for combat is a condition-complicated multi-models optimization problem, which can control and optimize the system of heterogeneous UAVs. It is composed of target assignment, path planning and task execution. The challenge of this problem is not only to consider the single UAV capability, constraints and damage probability etc, but also needs to think about the cooperative with other UAVs and avoid conflicts for each other. Moreover, the heterogeneous targets assignment models, real environment of 3D battlefields, random no-fly-zones and radar threats, the sequence of UAVs attacked targets, the cooperative representation of paths and environmental changes during the execution of tasks, are all increase the difficulty of the collaborative planning. Therefore, the key to solve MUAS cooperative is how to implement effective target assignment strategies, plan feasible smooth paths, and adapt to the local dynamics environmental changes.

This paper focus on how to solve the difficulties of MUAS cooperative target planning, and how to plan a safe and less cost path for each UAV, which is based on the complex 3D terrain and multi-constraints. A unified model of targets assignment and flight path planning is established based on the optimization theory. The consistent allocation cost matrix is used to process the targets assignment; and the spatial fuzzy sets and cooperative correlations are applied to represent the key way point. Then the targets assignment, path planning and online re-planning of multi UAVs cooperative are mainly studied, as well as it also sets up an efficient task space representation, and improves several optimization methods to solve those problems. Meanwhile, the simulation experiments are explored to verify the feasibility.

Firstly, a uniform model has been built for all kinds of UAVs targets assignment with complexity cooperative constrains. According to the relationship between UAVs and targets, the unified framework is extended by the balance and unbalance assignment cases. Then a method based on space vertical section to indicate the cost of flight path length is proposed, which applies the cost matrix of flight path length

to optimize the target assignment algorithm. Meanwhile, the collaborative constraints and the violation value of constraints are also studied, so that it can improve the accuracy of target assignment algorithm.

This model unifies the processing of the single UAV to single task, multi UAVs to single task and swarm routing tasks (multi-UAVs travel to multi-tasks). In particular, the cost matrix of swarm routing tasks is constructed to ensure that has same form as others, so that can use a consistent algorithm solving all the assignment problems. So it overcomes the shortcomings of the non uniform model and the less universality.

Secondly, to solve the difficulties problems of the inconsistency of the methods, the larger size of tasks and the planning time significantly increased for the multi-targets assignment of discrete combination optimization and multi models, a novel assignment algorithm with a unified gene coding strategy has been improved, as well as the algorithm is based on a discrete mapping differential evolution (DMDE) in three-dimensional environments. During the solving process, the flight path cost is used to indicate the assignment relationship between the UAV and the target, which turns the optimization problem from discrete space to continuous space by the mapping and inverse mapping rules. Meanwhile, the dynamic crossover rate combines with the hybrid evolution strategy, so that a balance between exploration and exploitation is achieved to avoid falling into a local optimal. The proposed DMDE algorithm with the unified gene coding strategy not only effectively solves the cooperative multi-target assignment problem, but also improves the accuracy of the multi-target assignment. It is also suitable for solving the assignment problem of large scale.

Thirdly, in order to solve the problems of searching space larger and cooperative difficulties of MUAS path planning in 3D environment, the algorithm of MUAS cooperative path planning and smoothing has been researched. The representation of spatial fuzzy set and artificial cultural algorithm are introduced to solve this problem. Firstly the relationship of fuzzy degree of membership between the space points and the path planning is established to represent the space points on 3D grid, so that the key way-points on path should be more attention. Then the belief set of cultural algorithm is constructed by the comprehensive knowledge, which effectively prunes the search space of MUAS path planning. Moreover, the

multi-objectives differential evolution is used to plan the Pareto optimal paths in the population set of cultural algorithm, which satisfies the constraints of MUAS cooperative. Finally, cultural algorithm exchanges the shared information between the belief set and the population set, so that it keeps the population diversity, accumulates the knowledge and revises the searching direction. This approach enhances the efficiency of key way-points selected, and explores more unknown space to avoid the search fall into local optimization. So it contributes to planning feasible paths for MUAS cooperative quickly.

In addition, the method of curve fitting is used to smooth those cooperative paths, which can get safe and available flight paths. The paths are smoothed by the three B-spline curves in 3D space, because the key way-points of paths can be used as the control points of spline curve. Then, in order to avoid the deviations on the smoothing paths, it can inverse find out the spline curve control points that control the smooth path to pass through the key way-points.

Finally, a novel path re-planning algorithm with multi Q-learning based on a cooperative fuzzy C means clustering is proposed, which is to solve the failures of tasks or the conflicts of cooperations when the unknown dynamic environment has changed. This approach uses fuzzy degree of membership and co-correlation of way-points to construct a fuzzy cooperative matrix, which can reflect the dynamic changes of planning space by the updating of matrix. Then the cooperative fuzzy C-means clustering is performed with the fuzzy cooperative matrix in every steps of planning space. Furthermore, the task classification of clustering is used as the state space, and the dynamic fuzzy cooperative matrix is used as the reward function of Q-learning. So a multi Q-learning algorithm is proposed to dynamic re-planning the optimization paths in the on-line state space for each task. The method can adapt to the changes of dynamic environment, reduces the task planning space and improves the search efficiency of the learning algorithm, so it can produce effective cooperative re-planning paths for MUAS.

Keywords: MUAS, Multi-target assignment, Cooperative paths planning, Path re-planning, Three dimensional space, Differential evolution.

目 录

摘 要	I
ABSTRACT	III
第 1 章 绪 论	1
1.1 课题来源	1
1.2 课题的目的和意义	1
1.3 国内外的研究现状及分析	4
1.3.1 研究概况	4
1.3.2 多机协同目标分配方法研究现状	6
1.3.3 多机协同航迹规划方法研究现状	9
1.3.4 多机协同航迹重规划方法研究现状	11
1.3.5 多无人机多任务的协同方法概述	12
1.4 存在问题分析	14
1.5 主要研究内容	15
第 2 章 复杂多约束多机协同目标分配和航迹规划的统一建模	20
2.1 引言	20
2.2 MUAS 目标分配和航迹规划统一建模	21
2.2.1 问题的表示与描述	21
2.2.2 协同约束关系分析	24
2.3 MUAS 的统一目标分配方法	26
2.3.1 多机协同统一目标分配模型	26
2.3.2 MUAS 统一目标分配模型的描述	28
2.4 基于垂直切面的航程代价和协同约束	30
2.4.1 多机航程代价的估算	30
2.4.2 航程代价矩阵构建	32
2.5 基于统一目标分配模型的验证	33
2.6 实验结果和分析	37
2.6.1 验证统一目标分配模型的分配效果	37
2.6.2 分配目标数量增多时的效率分析	40
2.7 本章小结	41
第 3 章 基于统一目标分配模型的多机协同分配方法	42

3.1 引言	42
3.2 基于 DE 算法的多机协同目标分配框架	44
3.3 基于统一目标分配模型的基因编码策略	46
3.3.1 统一的基因编码策略	46
3.3.2 个体编码产生规则	47
3.4 基于 DMDE 的 MUAS 协同统一多目标分配	49
3.4.1 离散差分映射规则	49
3.4.2 混合进化策略的 DMDE 算法	52
3.5 DMDE 算法分析和控制参数选择	54
3.5.1 DMDE 算法理论和性能分析	54
3.5.2 DMDE 算法参数选择	56
3.6 实验结果和分析	57
3.6.1 算法的有效性和适应性	59
3.6.2 DMDE 算法的性能	62
3.6.3 DMDE 与同类目标分配算法的比较	63
3.7 本章小结	65
第 4 章 基于空间模糊表示的多机协同航迹规划方法	66
4.1 引言	66
4.2 基于任务属性的空间模糊表示	67
4.2.1 空间点的模糊集表示	67
4.2.2 模糊隶属度函数设计	68
4.2.3 截集优选关键路径点	71
4.3 基于文化算法的 MUAS 协同航迹规划方法研究	72
4.3.1 空间模糊文化算法的航迹规划框架	72
4.3.2 基于模糊表示的信念集构成和更新	74
4.3.3 种群集上基于 MODE 的协同航迹规划	76
4.4 算法理论分析和参数选择	79
4.4.1 空间模糊表示和文化算法理论分析	79
4.4.2 控制参数分析和算法流程	81
4.5 基于 B 样条拟合的 MUAS 协同航迹平滑	82
4.5.1 三维空间中的 B 样条拟合航迹平滑方法	82
4.5.2 反求控制点的三维 B 样条航迹平滑	84
4.6 实验结果与分析	86
4.6.1 协同航迹规划可行性实验	86

4.6.2 与常用协同规划算法的对比分析	88
4.6.3 与其他文化算法的对比分析	89
4.6.4 航迹平滑效果与其他策略对比分析	91
4.7 本章小结	92
第 5 章 动态环境下多阶段多机协同航迹重规划方法	93
5.1 引言	93
5.2 MUAS 协同航迹重规划任务模型	95
5.2.1 重规划问题描述和难点分析	95
5.2.2 基于 CFCM 和多 Q 学习的重规划模型	96
5.3 基于 CFCM 聚类的多任务状态空间划分	98
5.3.1 协同相关系数和模糊协同矩阵	98
5.3.2 聚类空间优化和初始中心设定	99
5.3.3 基于模糊协同矩阵的 CFCM	100
5.3.4 CFCM 的参数选择准则	101
5.4 基于 CFCM 的多 Q 学习航迹重规划	103
5.4.1 环境更新和重规划区域设定	103
5.4.2 基于协同模糊回报函数的 Q 学习	104
5.4.3 改进的状态转移动作集设定	106
5.4.4 基于 CFCM 的多 Q 学习协同航迹重规划	107
5.5 实验结果与分析	109
5.5.1 协同航迹重规划可行性实验	109
5.5.2 比较采用不同回报函数的 Q 学习算法效果	113
5.5.3 与其他动态规划方法的比较	114
5.6 本章小结	115
结 论	116
参考文献	118
攻读博士学位期间发表的论文及其它成果	130
哈尔滨工业大学学位论文原创性声明和使用权限	131
致 谢	133
个人简历	134

Contents

Abstract (In Chinese)	I
Abstract (In English)	III
Chapter 1 Introduction	1
1.1 Source of the subject.....	1
1.2 Background and significance of the subject.....	1
1.3 Present situation and analysis of domestic and foreign.....	4
1.3.1 Research overview.....	4
1.3.2 MUAS cooperative target assignment method.....	6
1.3.3 MUAS cooperative path planning method.....	9
1.3.4 MUAS cooperative path re-planning method.....	11
1.3.5 MUAS and multi-tasks collaboration method.....	12
1.4 The problem description.....	14
1.5 Main research contents of this dissertation.....	15
Chapter 2 A unified modeling methods of MUAS cooperative targets assignment and path planning by complex multi-constraint conditions	20
2.1 Introduction.....	20
2.2 Unified model of MUAS for targets assignment and path planning.....	21
2.2.1 The representation and description of the problem.....	21
2.2.2 Analysis of cooperative constraint relations.....	24
2.3 Unified targets assignment method of MUAS.....	26
2.3.1 Targets assignment model of MUAS cooperative.....	26
2.3.2 Unified modeling for targets assignment.....	28
2.4 The cost based on vertical section and cooperative constraints.....	30
2.4.1 Estimated the cost of flight path length for multi-UAVs.....	30
2.4.2 The cost matrix of flight path length.....	32
2.5 Verification based on the unified target assignment model.....	33
2.6 Experimental results and analysis.....	37
2.6.1 Verify the effect of the unified model assignment.....	37

2.6.2 Analysis of the efficiency by the increase of the number of task.....	40
2.7 Summary of this chapter.....	41
Chapter 3 MUAS cooperative targets assignment based on the unified model.....	42
3.1 Introduction.....	42
3.2 The overview of DE algorithm framework.....	44
3.3 The encoding strategies based on unified model.....	46
3.3.1 The unified encoding strategies.....	46
3.3.2 The generation rules of individual code.....	47
3.4 MUAS cooperative multi-targets assignment based on DMDE.....	49
3.4.1 Discrete differential mapping rules.....	49
3.4.2 DMDE with hybrid evolution strategies.....	52
3.5 DMDE algorithm analysis and control parameter selection.....	54
3.5.1 Theory and performance analysis of DMDE.....	54
3.5.2 The parameter selection of DMDE.....	56
3.6 Experimental results and analysis.....	57
3.6.1 The effectiveness and adaptability of DMDE.....	59
3.6.2 The performance of DMDE.....	62
3.6.3 A comparison between DMDE and similar algorithms.....	63
3.7 Summary of this chapter.....	65
Chapter 4 MUAS cooperative paths planning based on the representation of fuzzy space.....	66
4.1 Introduction.....	66
4.2 The spatial fuzzy representation based on task properties.....	67
4.2.1 The spatial fuzzy set of spatial points.....	67
4.2.2 The design of fuzzy membership function.....	68
4.2.3 Optimal key way point selected by cut set.....	71
4.3 The cultural algorithm for MUAS cooperative path planning.....	72
4.3.1 Path planning framework of culture algorithm on spatial fuzzy set.....	72
4.3.2 The composition and updating of belief set based on fuzzy.....	74
4.3.3 Path planning by multi-objective DE in population set.....	76
4.4 Algorithm theory analysis and parameters selection.....	79
4.4.1 Theoretical analysis of spatial fuzzy and cultural algorithm.....	79

4.4.2 Control parrameters analysis and algorithm flow.....	81
4.5 Path smoothing for MUAS cooperative based on B spline.....	82
4.5.1 B-spline fitting for path smoothing method in 3D.....	82
4.5.2 Reversely control vertexes of B-spline for paths smoothing.....	84
4.6 Experimental results and analysis.....	86
4.6.1 Experiments for feasibility of path planning	86
4.6.2 Comparison and analysis with conventional algorithms.....	88
4.6.3 Comparison and analysis with other cultural algorithms.....	89
4.6.4 Effect of smoothness and comparison with different strategies.....	90
4.7 Summary of this chapter.....	91
Chapter 5 Multi stages MUAS path re-planning under dynamic environment.....	93
5.1 Introduction.....	93
5.2 The task model of MUAS cooperative path re-planning.....	95
5.2.1 The overview of path re-planning.....	95
5.2.2 The re-planning model based on CFCM and multi-Q learning.....	96
5.3 The division of multi-tasks state space based on CFCM clustering.....	98
5.3.1 Correlation coefficient of cooperative and fuzzy cooperative matrix.....	98
5.3.2 Optimization of clustering space and center initial.....	99
5.3.3 CFCM clustering based on fuzzy cooperative matrix.....	100
5.3.4 Parameters selection criterion of CFCM.....	101
5.4 The multi-Q learning for path re-planning based on CFCM clustering.....	103
5.4.1 Update of environmental and regional of re-planning.....	103
5.4.2 Q learning algorithm and return function of cooperative fuzzy.....	104
5.4.3 Improved action set for state transfer.....	106
5.4.4 Cooperative path re-planning by CFCM and multi Q learning.....	107
5.5 Experimental results and analysis.....	109
5.5.1 Experiments for feasibility of path re-planning.....	109
5.5.2 Compare the effect of Q learning with different return function.....	113
5.5.3 Comparison with other dynamic programming methods.....	114
5.6 Summary of this chapter.....	115
Conclusions.....	116
References.....	118

Papers published in the period of Ph.D. education.....	131
Statement of copyright and Letter of authorization.....	132
Acknowledgements.....	133
Resume.....	134

第1章 绪论

1.1 课题来源

本论文的研究内容源自“复杂环境下数目未知时变的多目标连续跟踪方法研究”(国家自然科学基金资助项目,批准号:61175027)、“显微视频数据中的扩展目标跟踪方法研究”(国家自然科学基金资助项目,批准号:61305013)和中央高校基本科研业务费专项资金资助项目(批准号:HIT.NSRIF.2015069)。

1.2 课题的目的和意义

无人机(Unmanned Aerial Vehicle, UAV)是指不载乘任何操作人员;利用空气动力进行飞行;能够自主或远程领航控制;可扩展和回收并可携带有效载荷的无人飞行平台^[1]。与有飞行员驾驶的载人飞行器相比,无人机具有众多潜在的优点,如:自主飞行的无人机在燃油充足的情况下不需要休息,可以进行更长时间的巡航;无人机不需要提供飞行员必须的生命支持系统,这不仅减少了飞行成本,还为部署传感器和其他设备提供了更多空间^[2];此外,无人机不用考虑机载人员的生理限制,因此可以以超越人类极限的更灵活的自由度完成各种复杂的飞行机动,并可探索人类无法接近的危险区域,能够替代人类执行各种“枯燥、恶劣、危险”的任务^[3]。现代战争中,无人机的广泛使用,极大程度上降低了人员伤亡的代价,提高了作战系统平台的安全性和自适应性,而“无人化”必将逐渐改变现代战争的面貌,成为支撑未来信息化战争的重要节点^[4],并引领未来战争发展的新方向。

在民用和科研领域,无人机的作用也日益凸显,业已成为辅助人类探索自然、提高社会安全、参与救灾抢险等重大任务必不可少的技术支撑^[5]。在海洋探测、城市监控、航拍摄影、矿产探测、应急检测、气象预报、社会安全防范^[6]等领域均有长足的发展。此外,近年来随着无人技术的广泛推广,无人系统(Unmanned System)在各领域获得普遍关注,除了无人飞行器系统(Unmanned Aircraft System, UAS)被概念化以外,无人地面系统(Unmanned Ground System, UGS)^[7]和无人海洋系统(Unmanned Maritime System, UMS)^[8]均获得普遍关注。由此可见,未来无人技术发展的趋势必然是陆地、天空、海洋以及外太空多种无人系统一体化的综合应用^[3]。无人系统技术的全面推广,将以更全面复杂的方式影响人类的未来。

当前无人机的飞行过程既可由地面控制中心在安全区域进行远程遥控，也可由机载设备进行自主控制^[2]。为了有效提高无人机的飞行适应能力，降低人机交互带来的系统性能下降，可以将以上两种方法相融合，在不需要遥控或失去通信控制时，无人机可以自主选择飞行策略，而在复杂飞行区域和实施目标打击时，才加入人为干预。然而这种依靠远程控制的无人飞行系统，仍然会受到各种人为限制因素带来的影响，如控制者同时可控飞行器数量的限制，通信延迟和人为操作错误导致的多机间冲突等问题，使远程遥控的技术手段很难适应日益增长的多无人机系统(Multi Unmanned Aircraft System, MUAS)整体协同执行任务的需求。因此，完全自主飞行、智能化的 MUAS 和其协同任务的规划方法成为近年来研究的热点。图 1-1 显示了美国国防部对 UAS 的自主级别发展规划路线^[9]，从其中可以看出，分布式控制、群协同和在线重规划等自主需求都是重要级别的研究目标要加以实现，而完全群体自主的 MUAS 则是未来发展的主要目标。




图 1-1 UAS 预期的自主级别

Fig 1-1 Expected autonomy level of UAS

随着无人控制技术的不断发展，MUAS 具有越来越高的自主控制和相互协调的能力，多机系统能够以更低的风险、更廉价的费用、更灵活的操控方式执行多种复杂危险的作战任务。在空间立体化复杂的战场环境态势下，参与执行任务的飞行器种类不断增加，性能迅速提高，形成了技术密集、结构复杂的特征。因此单架无人机单一的性能和有限载荷很难独立完成复杂环境态势中的多种信息采集、敌方区域监视、多目标同时攻击等任务^[10]。而 MUAS 协同执行任务则可以处理各种复杂情况，提高任务完成的成功率，具有比单机更全面、

执行任务效率更高、安全性更强等突出优点。同时，多机系统中部分无人机的毁伤和失效不影响最终完成任务的效果，因此多机系统具有更高的鲁棒性和可信性。在复杂环境下，某些综合任务如广域搜索(Wide Area Search)、情报、监视与侦查(Intelligence Surveillance and Reconnaissance, ISR)、压制敌军空防系统(Suppression of Enemy Air Defense, SEAD)等，必须由多机协同配合才能得以执行^[11]。MUAS 通过自主协同合作，极大程度地扩展了系统整体执行任务的能力和范围，因此已逐渐取代单机，成为执行各种复杂任务的关键技术。

但是，MUAS 也增加了处理的难度，其复杂度随 UAV 和目标数量的增加呈几何级数增长。在协同过程中，不但要处理无人机自身的约束条件，还要考虑相互协同的制约关系；为降低系统的耦合程度，要对任务进行分解和规划；此外，还要避免多机间冲突导致的系统退化、共享资源竞争等关键问题的影响。在控制方面传统的基于中央控制的方法越来越难行，尤其是异构的多架次无人机协同，需要更多的通信带宽、更完备的信息共享和更高的自主决策能力支持^[12]，由此可见，MUAS 的研究仍面临着复杂的挑战。

多无人机系统的协同任务规划是指在复杂环境态势下，针对多个已知要侦查或打击的目标，利用多架同构或异构的无人机协同合作，共同完成这些目标所规划的具体的方案或策略。这些方案和策略期望多无人机以最小的任务代价、最合理的目标配比、最优化的飞行航线、最佳的变化适应能力，协同实施完成多个任务的执行，并使多无人机系统能够在最少人为干预的前提下，快速、高效、自主的完成全部任务，且具有一定的容错性和鲁棒性。MUAS 协同任务规划从功能和实施阶段上，可以分为多机协同目标分配、多机协同航迹规划和多机协同重规划三个部分。其中多机协同目标分配(MUAS Cooperative Multi-Target Assignment, MUCMTA)是基于一定的环境知识和任务需求，为多机系统中的 UAV 分配一个或一组有序目标，以便在完成最大可能数量任务的同时执行目标总代价最小和总效益最大的问题。该问题是一个异构多模型，约束条件复杂的最优化 NP 难题，既要考虑到飞行器的数量、是否异构、任务的类别和权重、飞行的环境等因素；又要考虑可行的航程代价、合理的分配算法、各种协同约束条件等问题。多机协同航迹规划(MUAS Cooperative Path Planning, MUCPP)是在给定已知、部分已知或未知信息的环境中，规划出从起始点到达目标点，可以绕过威胁区和障碍物、安全可靠无碰撞、且同时满足各种约束条件和协同关系的多条可行飞行航迹。该问题是一个多目标优化问题。通常不仅要考虑无人机自身的飞行性能，还要考虑无人机之间的避免碰撞和同时到达等协同问题。在任务执行阶段，环境的动态改变可能导致全局规划结果

的部分失效,为了保证 UAVs 飞行的安全性并降低任务失效的概率,还需要对环境的改变做出响应,对失效的航迹段进行在线协同重规划(MUAS Online Cooperative Path Re-Planning, MUOCPRP),以保证任务执行过程中 UAVs 的安全有效。

无人机技术和 MUAS 经过了几十年的发展,提出了大量的理论和方法,在不同的领域都取得了丰硕的成果。其支撑理论涉及到多个学科和技术领域的综合和交叉,如自动控制、人工智能、学习模式、无线通信、分布式和最优化理论等,目前还存在着大量亟待解决的问题,在理论和实践上均具有较高的研究价值。同时,由于执行的任务越来越复杂;环境和约束的变化越来越宽泛;协同和合作的目标越来越具体;完成任务的时间和打击效果越来越精细,这就要求 MUAS 必须具备更优良的技术和性能。因此,只有对现有的技术进行改进和创新,不断提出新的理论和方法,才能够保证多无人机系统有效协同执行复杂多约束条件下的多个任务,这也是本课题的研究目标。因此,本文从统一目标分配建模、协同目标分配方法优化、协同航迹规划和在线航迹重规划几个方面展开研究,重点研究三维环境下 MUAS 自主协同规划的若干问题。

1.3 国内外的研究现状及分析

1.3.1 研究概况

近年来,无人机的研究和应用在多数发达国家呈几何级数的趋势增长,这些国家投入了大量的人力和财力组织研发,涌现出一批性能优良的新型无人机系统,如 Global Hawk、WASP 3、Raven、Scan Eagle、MQ-18、RQ-4 Blk、X47-B 和 RQ-170^[12]、以及我国自主产权的“翼龙(GJ-1)”、“海鹰(WJ-600)”等。随着无人机性能不断深入发展,针对无人机系统性的研究也获得普遍关注。近年来,国际民用航空组织(ICAO)、美国联邦航空管理局(FAA)、美国国防部(DoD)、欧洲航空安全局(EASA)一致通过采用“Unmanned Aircraft System(UAS)”取代即将过时的术语“UAV”^[1],将系统性的研究提到了新的高度。一个完整的 MUAS 包括多种异构的无人机或无人机编队、其他单元系统组成,如任务规划系统、发射系统、取回机制、地面控制中心和基础通信设施等^{[13][14]}。在阿富汗和利比亚的作战中,无人机系统产生了不可估量的作用,因此,自 2009 年始,美国空军开始训练更多的无人机驾驶员以取代飞行员和投弹员,截至到 2011 年,其投放战场的 UAV 总飞行时间就已经超过一亿小时。美国国会则倡议未来陆军三分之一的作战飞行器和地面战斗用车辆

(Ground Combat Vehicle, GCV)全部实现无人化。美国海军研究委员会也将水面无人机(Unmanned Surface Vessel, USV)应用于海岸巡逻,以打击走私和海盗犯罪,并在危险气候环境下帮助搜索和救援。由此可见,无人机技术已经成为未来战争和社会发展的主要方向。

针对 UAS 概念的提出和发展,在任务需求复杂度不断提高的情况下,多机协同任务规划系统的研究也日益广泛,并逐渐成为未来无人机应用的主要研究方向。例如,美军已将多种 UAV 纳入联合任务规划系统(Joint Mission Planning System, JMPS)中,以提高不同机型相互合作的协同作战能力。美国国防部建立了无人机联合开发局(Joint Program Office, JPO),致力于从大尺度多机系统转型为研发小型、低空、低成本、一次性的多无人机系统,通过大量廉价的小型无人机协调合作,完成复杂的任务,并且不考虑个别无人机的毁伤和失效^[14]。2013 年,DoD 在 UAS 未来 25 年规划中提出:联合地面、天空和海洋多种 UAS 一体化协同合作,将成为无人机技术发展的新挑战^[3]。此外,欧盟早在 2001 年就进行了异构多无人机实时协同和控制(Real-time coordination and control of multiple heterogeneous unmanned aerial vehicles, COMETS project)项目的研究。该项目主要研究异构无人机实时协作控制技术、协同环境感知、协作侦测和通信传播等多个任务。近年来,多机系统不断向着群体人工智能和分布式网络控制技术方向发展,例如,欧盟联合开发的 Neuron 作战无人机单元阵列项目、美国海军研究所的低代价多无人机系统项目(Low-Cost UAV Swarming Technology, LOCUST)都是利用群智能的典范,克拉根福大学的自主多无人机系统也将研究的目标定位于自组织智能网络化的多机协同技术,旨在综合处理网络、感知和协同,以增加多机系统自主控制的有效性^[15]。此外,多种仿真技术也广泛应用在多无人机系统的研究上,如爱荷华州立大学的虚拟现实应用中心与空军研究实验室共同开发的沉浸式虚拟现实系统,通过虚拟战场集成技术测试多无人机任务规划系统的有效性。

我国无人机领域的研究起步虽然比较晚,但是发展的速度非常惊人,尤其是近年来国家相关研究机构日益重视该领域的发展和建设。自 90 年代以来,多所高校率先成立了无人机和无人机任务规划系统的专门研究机构,并已研发出几十个型号的无人机和多种无人机仿真平台。清华大学、北京航空航天大学、西北工业大学、华中理工大学、南京航空航天大学,国防科技大学、哈尔滨工业大学等院校均对此领域的研究做出了重要贡献。2000 年后,中航工业集团等一些企业和院所也开始了国产军用或民用 UAV 的研制。近年来,随着国产导航通信技术的飞速提高和民用领域对无人机应用需求的迅猛发展,涌现

出众多民间研发企业和公司，国产无人机大批量生成和产业化发展已初见规模，国内无人机市场化趋势已成为必然^[16]。尤其值得一提的是，2015 年纪念抗战 70 周年阅兵式上，我国首次以无人机受阅方队的形式，向全世界展示了多种最新型的国产军用无人机，从而表明我国无人机的发展已经在新军事变革过程中走向高新技术的前沿。

然而，国内针对多机系统的研究目前还处于起步阶段，尤其是对操控多无人机协同执行复杂任务的自主规划系统研究仍然较少，且大多停留在理论研究的层面。目前主要有国防科技大学多无人机协同任务控制任务分配与任务协调技术的研究^[17]，清华大学多 UAV 协同任务规划的研究^[18]，北京航空航天大学基于 DTC 的无人机任务规划研究^[19]，华中科技大学的无人飞行器多航迹规划与协同航迹规划研究^[20]等，这些研究虽获得了大量丰硕的研究成果，但是要适应实际的三维战场和危险环境下的多机协同应用，还有相当大的差距，因此，有必要继续深入进行多机协同任务的相关研究和探索。

MUAS 协同任务规划由多机协同目标分配、多机航迹规划和执行过程中的重规划三个部分组成。其中，多机协同目标分配主要对预期打击的目标进行合理的分配协调，使整体作战目标完成的可行性最大，执行全部目标的总代价最小，可用最优化方法寻找符合约束条件的最优分配结果；多机协同航迹规划是在执行任务区域内为已分配目标的无人机规划合理的飞行航线，使无人机能够在保证航油指标、机动性能、时间和通信等约束条件下，突防敌方威胁区域，执行目标的风险最小、航迹最优、且可避免相互碰撞等问题。而协同航迹重规划则重点考虑在线阶段环境随时间动态变化带来的系统失效问题，通过有限时间窗口内的局部重新协调和规划方法，改善已有协同航迹的安全可靠性，提高协同任务规划执行状态的稳定性。下面详细介绍这三个方面的常用方法和研究现状。

1.3.2 多机协同目标分配方法研究现状

多机协同目标分配是指基于环境知识和任务需求，为多机系统中的 UAV 分配一个或一组有序任务，以便完成最大可能数量任务的同时使多机系统整体效率和资源配比达到最优^[21]。分配目标时既要考虑到飞行器的数量、是否异构、任务的类别和权重、飞行的环境等因素；又要考虑可行的航程代价、合理的分配算法、各种协同约束条件等问题。因此，该问题是 UAV 异构多模型、且约束条件复杂的最优化 NP 问题^{[22][23]}。目前常采用集中式或分布式方法对此问题进行求解。集中式方法可以统一控制，全局协调目标之间的各种复杂关

系,但是此类方法过度依赖控制中心,扩展性相对较差;分布式方法计算灵活,可将复杂的问题分派到不同的无人机上并行处理,适合解决大规模的目标分配问题,但是它往往对无人机性能过度抽象,对系统通信要求过高^[10],因此分配最优目标的误差较大。当前研究具体的方法有:数学规划法、协商法和智能算法等。

1.3.2.1 基于数学规划法的协同目标分配

数学规划(Mathematical Programming)法是集中式解决分配问题的经典方法。多机协同目标分配问题本身是一个离散的组合优化问题,因此利用数学规划的方法求解非常有效。

早期的研究把多目标分配等同于工作指派问题,而匈牙利算法是解决此类问题的经典算法^[24],算法核心是分析分配代价矩阵中的独立0元素数量,通过寻找增广路径,求二分图的最大匹配。该算法通过构造代价矩阵,并在矩阵中寻找最小总代价值来实现目标的分配^[25]。但是,利用该算法求解时,要求环境信息已知,且算法容错能力较差,难以处理不平衡的分配,因此仅适合求解单一模型的分配问题。

目标分配也可以看做一个典型的整数规划问题,可利用分支定界或完全枚举法等求解。Jonathan P.How 等人采用混合整数线性规划(Mixed Integer Linear Programming, MILP)方法进行多无人机的目标分配求解,取得了较好的效果^{[26][27]}。MILP 方法结构简单、计算灵活、且求解速度较快,但是对复杂问题的描述过于抽象、复杂环境表示太简单。在 MILP 的基础上,Jonathan P.How 等人继续深入研究,提出了利用动态规划进行协同任务分配的方法^[28]。此外鉴于滚动优化原理,Mehdi Alighanbari 等人还提出了基于 MPC 的多机协同目标分配方法^[29]。但是,整数规划算法要求无人机的数量多于目标数量,且代价计算过于简单,因此不适合三维环境的目标分配计算。

此外,动态规划(Dynamic Programming, DP)也是求解多无人机协同目标分配问题常用的一种数学规划方法。Jeong 等人利用动态规划方法求解分配问题^[30],把多阶段多过程问题转化为一系列单阶段问题,利用各阶段之间的关系逐步求解,该方法为了构造模型,过度简化了无人机之间的协同关系,降低了结果的可信度。Mehdi Alighanbari 则将动态规划与 MILP 有机结合,较好的改进了该方法^[29],可以有效解决多目标分配问题。

1.3.2.2 基于协商法的协同目标分配

目前常用的分布式方法有基于协商的合同网方法。合同网将分配问题等价于市场交易的买卖过程,通过拍卖机制的招投标流程实现任务的委派迁移

[31]-[33]。UAV 将执行任务过程中自己无法处理的任务对外拍卖，由其他 UAV 进行投标，系统通过协商将任务迁移给能够以最低代价执行的 UAV。

基于合同网的方法原理简单、易于实现、效率较高。但是对协同和约束的处理能力较差，在追求整体最优的目标下，通常会与个体利益冲突。Moon 等人采用基于满意决策论的目标分配方法^[34]，通过对 UAV 个体执行任务的效能评估，确定联合满意度，在分布式系统中定义多机协同关系策略，按策略实施拍卖或竞标方案以协调目标的分配，能有效解决分配时的冲突和偏序问题^[35]。但此类方法依赖于系统中的信息交换和共享，对时延要求较高。P.B.Sujit 等人则在环境未知、信息受限的情况下，提出了利用可变协商策略机制进行决策目标分配的方法^[10]，取得了较好的分配效果。

1.3.2.3 基于群智能算法的协同目标分配

智能优化算法具有灵活、自适应、启发性、易于实现和计算复杂度低等优点，可以有效求解多机协同的目标分配问题。近年来，群体智能算法的研究日益广泛，它扩展了群体协同优化的结构和目标，并将协同约束条件嵌入到群体进化的属性中，因此有效提高了分配的准确性。当前，随着复杂任务对 MUAS 协作的需求越来越多，以及 UAV 越来越小型化、造价越来越低廉，使更大数量的 UAV 集群工作成为未来发展的首要目标，求解逐渐从单一问题转向集群问题，因此群体智能算法的研究开始获得人们的重视，其发展具有重要的研究意义。

多目标遗传规划方法在协同目标分配中对多个基于小生境的种群群体并行优化，向多群 *Pareto* 适应度最优的个体集合方向搜索，可以有效收敛到最优的多目标分配结果^{[36]-[38]}。但是遗传规划存在迭代周期长、容易陷入局部最优解的问题，因此出现了更多改进方法，如采用差分进化算法^[39]、免疫进化算法^[40]、协同进化算法^[41]等。Yeonju Eun 等人利用遗传算法将目标和可选航迹组合编码，可在目标分配同时优选备选航迹^[38]，但是该方法利用 Voronoi 图表示备选航迹，搜索的空间过于简化。郑昌文等人采用群论与禁忌搜索相结合，以消解目标分配中的强耦合性问题，具有较好的效果^[20]，但该方法仅对目标点进行编码，忽略了无人机的性能差异。宋敏等人采用差分进化算法求解异构多无人机的目标分配，通过分层解耦降低了不同模型的求解难度^[42]，但是该方法忽略了目标分配问题的离散组合优化特性，进化中利用取整操作不能有效对应合理的分配目标。

粒子群算法则通过种群中粒子个体运动位置和整体最优位置的记忆与学习在解空间中向着最优方向快速运动。粒子在演化学习过程中，不但受整体精英

粒子的影响,还受其近邻相关粒子的影响,因此粒子飞行的方向是社会和个体经验的集合,由此该算法反映了群体智能决策的简单和高效性^{[43][44]}。与进化算法相比,粒子群算法摒弃了交叉和变异操作,具有更高的效率^[45]。但它精细搜索能力不强,尤其是处理离散问题时易陷入局部最优,全局搜索能力差^[46]。Shinn 等人利用改进的 PSO 方法分配目标^[47],但仅考虑了任务的数量,忽略了任务代价,且对离散优化问题处理不佳。

蚁群算法是一种利用隐式通信进行信息共享,在未知环境中通过群体信息积累搜索目标和解的智能自组织方法^[48]。该方法参照蚂蚁或蜜蜂等昆虫群体协作进行觅食的行为^{[49][50]},通过传递信息素共享隐含的全局环境信息,引导个体搜索向信息密度较高的方向爬行。它通过无智能或简单智能单元的聚集协同表现出全局的群体智能行为特性,具有计算简单、鲁棒性好的优点^[51]。但是蚁群系统收敛速度较慢,易于出现停滞现象。

1.3.3 多机协同航迹规划方法研究现状

多机协同航迹规划是 MUAS 任务规划中的另一主要问题,它是对单机航迹规划的拓展和扩充;是指在综合考虑各种复杂多约束条件和协同关系的前提下,为参与任务的多架 UAV 规划出一组安全可靠的协同飞行航迹,以保证所有任务顺利执行的问题^[52]。目前,单机航迹规划仍存在很多问题,规划时既要考虑 UAV 的性能、有效负荷、燃油消耗、飞行时间,又要考虑地形跟随、禁飞区和威胁区域、执行目标的角度和时间等复杂的约束。而 MUAS 协同航迹规划还要进一步考虑 UAV 相互间的协同约束、冲突消解、执行逻辑、碰撞检测等,因此更增加了求解的难度。目前常用的研究方法有:从单机航迹规划发展来的多机规划方法,如启发式方法、图规划法、人工势场法;适合群体计算的群智能算法,如协同进化算法,多目标粒子群法,蚁群算法等;以及基于路径优化的规划方法,如 Dubins 曲线法、B 样条曲线等。

1.3.3.1 从单航迹规划推广而来的多航迹规划

A*算法是在路网中求解最短路径最经典的启发式方法,它通过启发式信息估算下一步前进的最优节点位置,不断探索未知空间寻找最优路线^[53]。A*算法和稀疏 A*算法^{[54]-[56]}可以很好地处理无人机和环境中的各种复杂约束条件,常用来求解二维环境下的单机或多机协同航迹规划问题。之后研究者将稀疏 A*方法扩展到三维环境,实现了三维环境中航迹的规划^[21]。此外还有结合地形平滑技术和可变步长来提高算法效果的研究^{[55][57]}。郝永军等人则进一步改进 A*算法,使其能够解决多机协同扩展的问题,可同时搜索多条航迹^[58]。但是,该

算法对环境信息的依赖程度高, 计算量大, 并行能力差, 因此不适合处理规模较大的多机协同航迹规划问题。

用概率图简化空间表示的方法是常用的规划方法之一, 它将要规划的空间按系统约束和威胁规避等条件约减成一个简单安全的路网图, 然后在路网图上获取最优飞行线路。常用的概率图算法包括通视图法、轮廓图法、随机路线图法和 Voronoi 图法等^[20]。Voronoi 图是由连接两邻点直线的垂直平分线组成的连续多边形网格图, 它将环境中的威胁源和障碍物作为空间划分的特征元素, 按照最邻近原则划分平面^[59], 形成安全可飞的通路网。Voronoi 图可以表示飞行航迹中距离威胁最远的通路, 在这个通路上搜索最优航迹, 能够确保飞行的绝对安全。Voronoi 图具有数量级低、构造时间快、距离威胁和障碍最远, 因而航路最安全等优点^{[60][61]}。但是 Voronoi 图虽在二维平面上构成容易, 却很难在三维空间中构建; 此外, 在三维空间中, 因为没有确定的特征元素选择方法, 因此最短路径也不一定存在于其上。

此外, 由 Khatib 提出的人工势场法^[62], 也是多机协同航迹规划的一种有效方法。它在规划空间中仿效吸引和排斥作用力影响 UAV 运动, 牵引 UAV 沿着势函数下降最快的方向前进, 此时, 无人机沿着合力的方向运动, 就可以规避开障碍和威胁, 到达目标点所在位置^{[63][64]}。人工势场法的优点是速度快、安全性高、适合协同规划。缺点是由于斥力和引力存在相等的静止点, 可能导致算法的停滞使规划失败。

1.3.3.2 基于群智能的多航迹协同规划

群智能算法同样适合求解多机协同的航迹规划问题, 是目前研究最广泛的方法。它具有规划速度快、并行性好、易于协同、可以收敛到最优等优点。利用群智能算法还可以将多机协同的目标分配和航迹规划用类似的算法结构统一起来进行处理^[65]。其缺点在于没有明确的基因表示定义、求得的最优解不唯一、且存在冲突和违背约束等问题, 因此可能导致规划和协同的失败。

Nikolos 较早采用遗传算法和差分进化规划单机和多机协同的飞行航迹^{[66][67]}。之后, 大量的航迹规划研究都围绕着改进的进化算法展开, 如多种群小生境进化算法^[68]、平行进化算法^[69]、量子遗传算法^[70], 以及将免疫机制与遗传算法相结合的方法^[71]等。这些方法证明了利用物种进化机制和并行寻优方法, 可以较快搜索到解空间的最优位置, 从而获得多条可行的协同航迹。此外, 进化理论不受空间结构的限制, 因此适合处理三维、甚至多维空间中的航迹规划问题^{[68][69][72]}。

Foo J.L 等人利用 PSO 算法实现多无人机的协同航迹规划, 并在三维虚拟仿

真平台(Virtual Reality Applications Center, VRAC)上进行了实验^[73]。鉴于粒子群算法比遗传算法更多的优点和更高的效率,近年来利用PSO算法进行多机航迹规划的研究逐渐增多^{[74]-[76]}。Roberge V等更是将平行进化算法与粒子群算法进行了比较^[77],强调了两者的区别和各自的优点,并混合这两种方法,将其应用于实际的航迹协同规划中。

此外,利用连续蚁群优化^{[78][79]}、LRTA*算法^[80]、人工免疫算法^[81]、神经网络^[82]等智能算法进行多机协同航迹规划的研究也与日俱增。这些智能算法的应用,均在一定程度上获得了可行的规划结果。由此可见,基于群体智能和仿生学的航迹协同规划算法,必将在无人机发展的道路上走的更远。

1.3.3.3 基于路径优化的多机协同航迹规划

无人机特殊的六自由度机动特性和易损毁性,要求规划的航迹必须具有空间可行性,因此规划结果必须是一条曲率受限、平滑可飞的航线。现有研究多是在空间中寻找一系列满足各种约束条件的路径点,将这些路径点进行连接,然后再平滑处理获得可行的航迹。常用的曲线平滑方法有二次样条曲线、B样条曲线、Bezier曲线等。Nikolos采用B样条控制点作为遗传基因,通过遗传算法优化B样条曲线,规划平滑可飞的飞行航迹^[66]。安柏义通过几何修正动态平滑在Voronoi图上获得的折线航迹,使其在转角处能够平滑拐弯^[83]。这些方法的优点是把规划和平滑分成两个阶段,在保证规划效率的前提下优化不符合飞行条件的航迹,使最终航迹可飞。其缺点是分离了无人机性能和规划之间的具体联系,可能导致规划的失败。

Antonlos Tsourdos指出将规划和平滑分开的不合理性,并提出直接利用曲线对无人机的航迹进行规划的方法,基于无人机飞行最大转角,利用Dubins曲线进行多机协同的航迹规划^[84]。考虑到Dubins曲线的曲率不变性,他还分别用螺旋曲线(Clothoid)和毕达哥拉斯曲线(Pythagorean Hodograph)改进了曲线航迹规划的方法,获得了良好的效果。该方法可以快速实现二维和三维可飞航迹的规划,缺点是规划的曲线不是最优航迹,且多航迹协同规划时可能产生冲突。

1.3.4 多机协同航迹重规划方法研究现状

当前关于多机协同航迹重规划的研究有很多,最常见的是将全局离线规划的方法直接扩展为动态重规划的方法。例如,文献[85]将经典的混合整数线性规划应用于动态环境中进行路径优化和避免碰撞,用数学规划的思想简化UAVs的引导。然而此方法过度简化了原始任务的复杂程度,因此很难在三维

环境下应用。此外,基于图的方法(如随机路线图、随机搜索树等)也被扩展到航迹重规划领域^[86],这类方法有效降低了空间复杂度,在重规划时能够快速更新图的结构,有效进行部分航迹的更新,但是此类方法很难在三维空间进行建模,且对空间过度抽象,获取的航迹较为粗糙。

利用启发式搜索算法和智能理论算法进行协同航迹重规划的方法也较为常见,例如源自 A*算法的 D*算法(动态 A*算法)和三维 A*算法被广泛应用于航迹重规划的研究^{[87][88]},该算法在环境动态变化的情况下,可以只探索最短路径上下一节点或临近节点的变化情况进行寻路,因此适合于航迹重规划的实施^[89]。但是,该方法计算量较大,且扩展路径时很难考虑多机间的协同,因此不适合于多机协同的航迹重规划。将三维多机协同航迹重规划问题看成时间的函数,就成为一个四维的问题,由于智能算法不受维度的限制,因此可以有效处理重规划问题。利用动态环境下简化的遗传算法^{[90][91]}、粒子群算法^[92]、蚁群算法^[93]等群决策方法,可以有效进行多机协同的航迹重规划,且能够动态收敛到全局较优的位置。然而,智能算法的主要缺点就是求解过程复杂、计算量大、迭代周期过长。现有研究通常是缩短算法的迭代次数、降低种群规模和简化个体形式等方法来提高算法的速度,这种处理方式极易使结果陷入局部最优或导致重规划失效。

从在线规划的角度来看,基于动态规划思想进行实时航迹规划已获得了广泛的认同。当前,作为动态规划有效扩展的马尔科夫决策方法(Markov Decision Process, MDP)^{[94]-[96]}与增强学习方法(Reinforcement Learning, RL)^{[97]-[100]}被广泛应用于航迹的在线规划,此类方法利用状态转移逐步进行区域的探索和预测,并通过学习来提高 MUAS 处理复杂未知不确定环境的能力。该类方法不仅考虑当前阶段航迹扩展的即时效应,还要考虑对将来继续决策产生的影响,因此适合于实时性的航迹重规划求解。但是,此类方法要处理复杂的状态转移模型,具有潜在“维数灾难”导致的性能严重下降的问题,因此大多数研究仅限于单机的在线规划,很难对多机协同问题进行有效的处理。

1.3.5 多无人机多任务的协同方法概述

MUAS 执行任务的复杂程度越高,任务越密集,就越需要多机间的共同合作、彼此协调、避免资源竞争和相互碰撞等问题,以完成多个复杂任务的共同执行,而多 UAV 相互的协同合作,是保证顺利完成这些任务的关键。目前,常见的多机协同方法主要有:空间的协同、时间的协同、时序的协同和通信的协同等。

1) 空间协同方法

空间协同反映了多机在飞行过程中的空间位置相关性，当两架次以上的 UAVs 在某一个时刻所处位置的距离小于规定的安全距离时，那么 UAVs 之间就会产生较大的碰撞威胁。因此要保证 UAVs 之间的空间协同，就要保证在飞行的任意时刻，UAVs 之间始终保持一定的安全距离。为了达到这个目的，通常采用基于安全距离的避免碰撞方法，或基于当前路径点对不同任务执行的相关性计算方法进行处理^{[64][83]}。其中，采用避碰的方法，要时刻更新当前无人机的位置信息，判断 UAVs 相互之间的距离，当距离小于安全距离时，进行必要的调整；而基于路径点相关性的判断方法，可由当前路径点执行不同任务的隶属度相似性获得，当空间某个点执行某个任务的隶属度远高于其他任务时，认为该点的空间协同性能较高。

2) 时间协同方法

在多机执行任务的过程中，要求所有的无人机都能在自己的最大飞行时间内完成相应的打击任务，因此需要对无人机最大飞行时间进行协同，保证所有的无人机都具备完成任务的能力，同时要求总的飞行时间不小于某架无人机执行任务的最大时间： $T_{total} \geq \max(T_1, T_2 \cdots T_i \cdots T_n)$ 。

在复杂的任务计划中，某些任务要求多架不同的无人机能够同时发起攻击，因此需要协调不同无人机的飞行或等待时间，保证能够同时到达目标。丁明跃等人采用协调估计到达时间(ETA)的方法，确保 UAVs 执行时间上具有交集，并控制速度快的 UAV 在目标点附近盘旋等待，直到所有 UAV 同时到达再发起攻击^[20]。此外还可以采用调整无人机飞行速度、多备选航迹选择等方法进行时间的协同^[27]。

3) 时序协同方法

目标的时序关系表示部分被攻击目标的必要执行顺序和相互依赖，也表示着某个目标的重要程度。当任务 T_i 必须在任务 T_j 之前完成时，有时序关系对： $Sequenc(T_i, T_j)$ ，要求 $T_j - T_i > 0$ 。一组具有时序约束的目标称为时序目标组。例如文献[32]中利用多于目标数量的 UAVs 协同处理一个时序目标组，以保证有足够数量的空余 UAV 可按时序协调目标选择，从而保证攻击目标的时序严格性。

4) 通信协同方法

基于分布式并行体系的 MUAS 任务规划，可利用机载传感器和便携通信设备进行信息的交换和共享，有效提高多机自主协同的能力。目前常见的通信方式有显式通信和隐式通信两种。

显式通信将每个无人机作为信息发布和接收的载体,采用全局广播、局部多播、以及点对点通信的方法,在分布式无人机系统的无线网络中交换共享各种信息。显式通信不仅要考虑无线网络通信的协议和路由算法,还要考虑无人机的通信能力和范围。目前常用的方法有基于 Ad Hoc 网络实现的多机协作定位^[101]等。

隐式通信则通过共享规划空间中隐含的全局或局部信息,如信息素或灯塔信息等进行通信,使有效信息可以快速在多智能体之间散布传播。目前常用的方法有基于信息素机制的蚁群算法等^[102]。然而,这种通信机制不存在数据的显式交换,且过于偏信共享的信息,因此可能产生较大的误差。

1.4 存在问题分析

相对于单机规划而言, MUAS 执行复杂任务的规划问题面临着大量的困难和挑战。主要集中在多机协同目标分配模型的统一、协同约束条件的选取和计算、多机间协同航迹的规划和平滑,以及任务执行时针对突发情况的多机航迹协同重规划等问题。具体有以下几个方面:

1) 在多机协同的定义和建模方面,因为多种 UAV 的使用目的、飞行性能、巡航范围和飞行速度均不相同;预期打击的目标类型、属性、单一或集群,固定或移动等性质也不相同,因此, MUAS 中的 UAV 在根据具体情况分配一个或多个目标时,存在多模型并存的情况。现有的研究针对多机协同问题处理的模型不统一,采用的方法不一致,从而导致协同目标分配和航迹规划的效率降低,产生不必要的资源冲突、协调困难、以及重复规划等问题。此外,三维空间中多机的目标分配和航迹规划的复杂性远高于二维空间,直接推广二维到三维的方法很难有效解决三维实际环境下的多机协同问题。因此,如何有效的表示航程代价、用统一的方法求解不同类型的规划问题也是亟待解决的难点所在。

2) 在多机协同多目标分配方面,现有方法很难用相同的结构统一处理多种情形下的目标分配模型,且往往忽略了分配问题与实际执行任务之间的代价属性的联系,从而导致在执行阶段才发现分配的目标与无人机不合适。同时,多无人机之间的协同目标分配比单机直接委派任务要复杂很多,协同时既要考虑单机的性能是否适合委派的目标,还要考虑该机与其他 UAV 相互协调和配合时存在的多种复杂的协同约束条件。此外,针对某些特殊的任务,要侧重考虑重要目标的配比关系,对重要目标通过分配多架 UAV 共同执行来保证任务完成的可靠性;而对于 UAV 数量少于执行目标,或 UAV 能力较强可以完成一组多个任务时,还要考虑 UAV 如何以最优化的协同效果分配处理多个任务。

因此，如何统一求解不同的分配类型，如何在目标代价中处理协同约束量，以及如何确保多机同时发起攻击等，都是亟待处理的重要问题。

3) 在多机协同的航迹规划方面，首先，如果没有合理的空间表示方法和较优的空间约减方法，那么在结构复杂的三维空间中快速寻找 UAV 执行任务的可行航迹关键路径点就非常困难，如何从任务和环境信息中抽取有效的空间表示内涵，以从空间中可飞路径点的角度考察航迹的规划和协同性能优劣，是亟待解决的难题。其次，协同航迹规划过程中，如何提炼和保留搜索过程中获取的较优航迹信息、协同信息和环境信息，使多无人机之间能够利用现有的经验资源，快速有效的进行协同规划，是对规划效率有效提升的关键。此外，从单机约束(如燃油、转向角、飞行高度、飞行时间等)和协同约束(如时间协同、避碰协同等)的选择对航迹进行限制，确保获取的航迹平滑可飞，是保证多机协同航迹规划成功的关键所在，也是具体执行规划求解时的难点。

4) 在 MUAS 执行任务阶段，环境的改变和突发的威胁，可能使已规划的部分航迹失效，或出现协同冲突等问题，导致任务执行失败或无人机毁伤等严重后果。多阶段的航迹协同重规划是快速解决任务执行时 MUAS 出现问题的重要手段，其难点在于如何快速响应当前阶段环境的变化，并根据变化对协同的若干条航迹迅速做出调整，以降低部分任务的失败和 UAV 毁伤概率。同时，为了有效提高重规划的时效性，如何结合已有航迹和环境变化信息有效约减重规划的任务空间，并在多机协同重规划过程中保持局部 UAVs 的协同合作，确保针对多机多任务能够快速重规划出下一阶段可行的协同航迹组，有效降低多机协同完成任务的成本，是协同航迹重规划的难点。此外，为了有效节约重规划的资源，还要尽可能提前预测环境改变对重规划影响的趋势，使重规划的航迹更适应未来可能的变化和协同，也是亟待解决的问题。

1.5 主要研究内容

本文从多机协同目标分配建模，目标分配求解，协同航迹规划和协同航迹重规划四个角度重点研究了三维环境中 MUAS 协同执行多个复杂目标的多任务协同规划问题，此研究可应用于军事行动中多无人机协同侦查、情报获取、空防一体化和打击敌方地面军事建筑设施等方面。在任务建模阶段，根据多机协同任务目标和多机协作存在的多种协同约束条件，期望分配的结果在整体上达到资源配置最优化。因此基于最优化理论，可将复杂多机多约束的协同目标分配和航迹规划问题统一建模成一个多目标最优化问题。然后用一致的框架描述不同任务的目标分配模型，使各种分配问题能够在统一的框架内进行处理；

在目标分配求解阶段，基于一致的算法进行求解，利用实际问题的物理属性和映射规则改进算法，以提高分配的效率和准确性；在全局航迹规划阶段，为了有效约减规划空间，提高关键路径点选择的被关注度，利用与任务和环境相关的模糊集空间表示方法优化搜索空间，提高空间点的信息量化程度，并采用有效的平滑方法拟合航迹段，使最终获得的航迹安全、平滑、可飞；在任务执行的航迹重规划阶段，基于模糊空间表示进行模糊聚类，划分协同任务的状态空间，然后利用动态规划和增强学习相结合的多 Q 学习方法进行多阶段航迹重规划，以处理任务执行中不断变化的环境造成的全局航迹部分失效。根据以上分析并结合实际任务需求，又可将协同多机任务规划系统分成三个层次：目标分配层、航迹规划层和航迹重规划层。

根据层次划分，建立 MUAS 协同规划的系统模型，采用问题逐层分解的思想对系统的各个部分求解，并协调各部分之间的关系，使任务规划系统能够适应多机多任务条件下的复杂问题求解，如图 1-2 所示。




图 1-2 MUAS 协同任务规划的系统模型

Fig.1-2 The system model of MUAS cooperative task planning

图 1-2 中显示了协同任务规划系统的结构，从图中可以看出，任务规划系统由目标分配、航迹规划和航迹重规划三个主要的部分组成。其中，目标分配阶段是对任务计划、各种资源信息和环境的预处理，通过合理的分配策略可以有效将目标任务分解成具体 UAV 执行的序列，使复杂的问题逐步化简成一系列的子问题加以解决。而对于多种分配关系的统一处理，可以有效提高算法的适应能力，解决多种不同情况下的复杂目标分配问题。因此，目标分配是任务

规划的前提和基础。航迹规划阶段是对已分配好目标的 MUAS 进行协同规划, 寻找最优航迹组合, 是保证有效完成全部目标任务的关键所在。通过航迹规划找到适合 UAV 执行目标的最优协同航迹, UAV 按照这些航迹进行飞行, 可以有效规避执行目标时遇到的威胁, 提高 UAV 自主完成任务的能力, 并最大可能的保证 UAV 的安全, 降低任务风险代价。因此, 航迹规划是任务规划的核心。航迹重规划是在任务执行阶段, 对突发问题和环境改变进行有效的响应和调整的过程, 是确保任务执行的有力补充, 在已有全局航迹的基础上, 对突发问题的区域内的航迹进行合理调整, 保证 MUAS 能够规避突发的威胁和环境的改变, 提高执行任务的安全性。因此, 航迹重规划是保证飞行安全的关键。此外, 为保证航迹的可飞, 还要包含航迹平滑和信息更新等模块, 这些模块也在 MUAS 中起着不可或缺的重要作用。

如图 1-3 所示, 本文研究内容的章节安排如下:




图 1-3 多无人机协同多目标分配和多航迹规划方法的研究内容

Fig.1-3 Research contents of multi-task assignment and multi-path planning for cooperative of UAVs

第2章针对复杂多约束条件下的 MUAS 协同目标分配和航迹规划问题进行统一建模。依据最优化理论建立统一的优化目标模型。然后, 根据 UAVs 与目

标点的数量对应关系将分配问题划分为 $N=M$, $N>M$ 和 $N<M$ 三类, 并设计了统一的目标函数和综合决策变量, 分析了 UAV 执行任务时需要满足的单机约束和无人机之间相互影响的协同约束; 在此基础上, 提出了基于垂直切面的三维航程代价矩阵, 以提高实际三维空间中分配的准确性和有效性; 最后利用统一的矩阵形式设计协同目标分配的策略, 用部分差分映射改进 DE 算法的差分操作, 以获得有效的目标分配方案。

第 3 章研究 MUAS 多目标分配问题的表示方法, 并改进离散差分进化算法的框架和策略以提高分配效率。首先基于统一分配模型和航程代价矩阵设计一致的基因编码规则, 将分配关系与具有实际物理意义的航程代价关联在一起; 利用航程代价映射分配关系, 在连续实值空间进行差分操作, 然后再将操作获得的临时解通过反映射规则映射回离散的分配关系空间, 保证获得有效的子代个体, 并且提高了分配的合理性; 进化过程中还动态混合差分进化策略, 以维持算法的开发性与探索性的平衡, 使进化过程既可以覆盖更广阔的空间, 又可以搜索到更深入的层面, 使算法始终向着全局最优的方向前进。

第 4 章在获得了有效的 MUAS 目标分配结果之后, 重点研究这些目标执行的全局航迹规划问题。根据三维空间栅格点与任务代价和威胁区的关系设计隶属度函数, 用模糊集表示空间栅格点, 以提高空间点的被关注程度, 从而有效约减空间, 提高搜索效率; 在此基础上, 引入基于空间模糊表示的文化算法进行多目标协同的航迹规划, 该方法用空间模糊集表示环境文化, 同时维护信念集和种群集两个不断积累和进化的系统, 并利用接受协议和影响协议进行相互通信; 信念集维系种群世代变迁积累的文化符号, 由环境知识、历史知识和协同知识组成, 以模拟人类社会的知识积累过程, 为种群集的演化提供文化指导, 可以加速种群集演化的速度和能力; 种群集则根据已有的文化知识为指引, 快速在三维空间中搜索最优航迹, 同时将当前的最优信息、协同信息输入到信念集予以保留; 此外, 获得最优的航迹关键路径点之后还要对航迹平滑处理, 利用三次 B 样条曲线和反求控制点的 B 样条曲线对航迹进行拟合平滑, 可以确保各航迹最终的安全可飞性。

第 5 章研究 MUAS 在任务执行阶段, 由于环境变化导致部分航迹失效引起的局部航迹在线重规划的问题。在已有全局航迹的基础上, 利用多阶段动态规划模型描述在线重规划问题, 以适应任务随当前时刻的变化; 用全局航迹作为初始聚类的中心, 基于协同相关系数和模糊协同矩阵对当前的模糊空间栅格进行聚类, 生成各任务对应的状态空间划分; 在各任务独自的状态空间中, 应用多 Q 学习算法选择各任务下一时刻的最优动作, 将动态模糊协同矩阵作为 Q 学

习的回报函数，通过不断反馈更新 Q 值表，使当前阶段的动态规划能够快速收敛于回报率较高的重规划航迹。

从图 1-3 中可以看出，第 2 章将协同的目标分配和航迹规划问题用一致的模型进行描述，统一了任务规划研究的问题模型；同时采用形式相似的航程代价矩阵描述不同的目标分配任务，使各类型分配问题能够在一致的算法框架下进行求解。第 3、4、5 章分别从多机协同目标分配、多机协同航迹规划和协同航迹重规划三个方面来处理 MUAS 协同攻击多目标的任务规划问题。其中，多目标分配是 MUAS 执行任务的前提和基础，合理的分配结果能够有效降低整体任务执行和协同的风险，提高任务完成的质量；在多目标分配的基础上，协同航迹规划是指导 MUAS 自主完成打击目标的重要依据，最优的航迹能够确保 UAV 以最低的费用、最安全的策略和最有效的协同去执行分配的目标；而协同航迹重规划则是保证实施任务时 MUAS 安全和任务完成的关键，它是对目标分配和全局航迹规划的检验和调整，是对 MUAS 任务执行的监视和修正。因此，通过对这三个层次的深入研究，提出各个阶段有效的处理方法，能够在复杂的三维环境下，确保 MUAS 自主协同执行多个目标，完成预期的任务。

第 2 章 复杂多约束多机协同目标分配和航迹规划的 统一建模

2.1 引言

单架次无人机的飞行机动性能和有效载荷远低于 MUAS 协同作战, 因此单 UAV 难以完成某些复杂军事任务, 如大范围敌方环境监视、广域信息采集、同时执行多个任务等。但是, MUAS 也有其自身难以克服的缺点, 多机协同的规模非常大、复杂度非常高、安全隐患严重; 在执行任务时, 不仅要考虑环境、敌方目标和自身的性能限制, 还要考虑与其共同作战的其他 UAVs 可能带来的意外毁伤、资源竞争等; 同时, 群体作战也提高了被发现的几率。因此, 为降低系统耦合程度, 提高协同性能和任务完成质量, 要对任务进行分解和规划, 以避免多机间冲突导致的系统退化等问题。

多机协同的目标分配和航迹规划是 MUAS 任务执行规划分解的两个主要阶段, 其中目标分配基于多种委派关系进行(UAV→任务)的最优化匹配; 航迹规划则在目标分配的基础上重点优化(UAV→任务)的可行飞行航迹。两者在任务模型上是一个问题的两个阶段, 前者为后者提供任务需求关系, 后者具体实施前者的期望目标。将不同类型的目标分配和航迹规划问题统一在一致的模型框架下, 可以有效避免重复规划、资源竞争等问题。近年来, 由于智能算法的结构具有普遍适应性, 可以有效提高问题求解的效率, 因此人工智能方法的应用逐渐增多。同时, 群智能算法的推广和流行, 也为多机协同目标分配和航迹规划问题的研究提供了更好的处理框架。同时基于智能算法的协同目标分配和航迹规划统一建模也成为可能。

当前 MUAS 协同目标分配和航迹规划研究的主要问题如下:

1) 多机协同的目标分配和航迹规划情况较单机复杂, 模型多变, 因此需要建立统一的数学描述。各种复杂战场态势下的目标分配和航迹规划约束条件各不相同, 尤其是在三维环境下, 分配和规划的单机约束条件和协同约束条件的计算更为复杂。在统一建模时, 更要合理的选择多种分配关系和航迹规划的约束条件, 保证 UAV 自身飞行安全的同时, 还要兼顾任务目标和协同合作, 使系统整体的执行效益最大化, 才能有效完成各种复杂的作战任务。

2) 在目标分配阶段, 只针对某种具体的分配模型进行研究, 异构的 UAV

和不同的分配目标类型可能导致处理问题的方法各有不同,增加了方法选择的困难和求解问题的复杂性,例如可以有效处理一对一分配关系的整数线性规划方法,就很难完成多机同时攻击一个目标的任务,而满足多机同时攻击一个目标任务的匈牙利算法又很难实现一架无人机巡游打击多个目标的任务。因此,如何将不同的分配任务类型归纳在统一的模型框架下进行处理,使用一致的算法结构求解多种目标分配模型,以降低选择分配方法的难度,并为之后的航迹规划提供有效的指导,是有待解决的问题。

3) 航程代价估算和协同航迹表示方法的优劣,极大程度决定了模型分配和航迹规划结果的合理性和可靠性,而现有模型大多采用简化的直线距离表示 UAV 与目标点之间的代价关系,因此分配的结果存在较大的误差。此外,当前研究多基于二维平面的规划问题,虽然二维平面可以适度简化问题求解的规模,但是由于三维空间的复杂性远远高于二维尺度,很多二维空间适用的方法,如 Voronoi 图法和随机路线图等方法,是无法有效处理三维的分配和规划的。为了有效求解三维真实环境中的分配和规划问题,必须采用适合三维环境的代价估算和航迹表示方法。因此,在三维空间中,采用航程代价估算方法来近似估算航程代价,可以使目标分配的结果更为合理,而采用适合的航迹表示方法则可以保证任务执行的正确。因此航程代价估算和航迹表示是协同建模的关键问题之一。

因此,本章首先阐述了适应 MUAS 多种目标分配和航迹规划的统一数学模型的建立;然后在此基础上重点研究不同类型的目标分配统一处理方法,提出基于空间垂直切面的航程代价估算方法,并利用代价矩阵表达任务分配的对应关系,使目标分配问题可以用一致的算法进行处理。最后,借鉴遗传算法的部分交叉映射,确保差分进化算法有效处理离散组合优化问题,以验证统一求解不同模型的目标分配的可行性。

2.2 MUAS 目标分配和航迹规划统一建模

2.2.1 问题的表示与描述

MUAS 协同目标分配和航迹规划问题,是指首先基于已知战场环境信息和攻击目标的需求,为系统中的 UAVs 分配一个或一组有序目标,以便在完成最大可能数量目标的同时,保证系统整体效率达到最优^[21];然后在目标最优分配的基础上,针对同时执行多个任务的 UAV 自身和协同约束,合理规划安全可飞的飞行航迹。为有效求解这一问题,首先建立起统一的分配和规划模型框

架，以确保不同类型的分配和规划问题能够在一致的算法框架下求解，从而降低多模型共存的复杂性。

因为多机协同的目标分配和航迹规划都可以抽象归纳为优化问题，因此根据优化理论，对任何模型的目标分配和航迹规划的建模都可以统一成一个求解多约束条件下的最优化问题。带约束的最优化问题通常由以下基本要素构成：

定义 2.1: 带约束的最优化问题具备一个目标函数 $f(\mathbf{x})$ ，表示待优化的目标；一个未知变量集 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ ，以影响目标函数的取值；以及一个约束集 $(h_m(x), g_m(x))$ ，其中 $h_m(x)$ 表示等式约束， $g_m(x)$ 表示不等式约束，它们是优化问题的边界条件集，可以约束最优化问题的求解方向和范围。

根据定义 2.1，可以定义带约束的最优化问题如下：

定义 2.2: 带约束最优化问题的数学表示：

$$\begin{aligned} \min(f(\mathbf{x})), \quad \mathbf{x} &= [x_1, x_2, \dots, x_n] \\ \text{s.t. } h_i(x) &= 0, i = 1, 2, \dots, m \\ g_j(x) &\leq 0, j = 1, 2, \dots, l \\ x &\in D \subseteq R^n \end{aligned} \quad (2-1)$$

其中 $x \in D$ 是最优化问题的决策变量。

根据最优化问题定义 2.1 和定义 2.2，结合多机协同目标分配和航迹规划的具体问题，现假设在任务空间 S 上，有 n 架出发位置相同或不同的 UAV，预执行打击 m 个散布在区域内不同位置的目标，考虑优化目标为全部 UAVs 执行全部目标的总航程距离最短，并且总飞行时间最少，其协同目标分配和航迹规划统一的目标函数可定义如下：

$$\begin{aligned} f(x) = & \left(\sum_{u=1}^n \sum_{i=1}^m \sum_{j=1}^m d_{(u,ij)} x_{(u,ij)} w \right) \\ & + \alpha (\max [\sum_{i=1}^m \sum_{j=1}^m t_{(u,ij)} x_{(u,ij)}, \forall u, i, j]) \end{aligned} \quad (2-2)$$

式(2-2)中第一项代表总航程代价， w 为目标的权重因子，且有 $(0 < w < 1)$ 。第二项代表总飞行时间， α 为时间代价的比例缩放因子，该因子使总飞行时间的值与航程代价保持同一量级。总飞行时间为 UAV 中执行时间的最大值，该时间能保证所有任务顺利完成。 $x_{(u,ij)}$ 是决策变量，当任务处于目标分配阶段，它由具体任务的对应关系决定，当任务处于航迹规划阶段， $x_{(u,ij)} = 1$ 。此外， $d_{(u,ij)}$ 和 $t_{(u,ij)}$ 在目标分配和航迹规划阶段的表示也不同，目标分配时 $d_{(u,ij)}$ 为估计的航程代价， $t_{(u,ij)}$ 为估计执行时间，而航迹规划时 $d_{(u,ij)}$ 为当前航迹的航程， $t_{(u,ij)}$ 则

为实际航迹的飞行时间。

MUAS 执行任务的决策变量约束、单机和协同约束条件可以表示为：

1) 决策变量约束条件：

$$\sum_{i=1}^n x_{(u,ij)} = 1, \quad j = 1, 2, \dots, m, \quad n \geq m \quad (2-3)$$

$$\sum_{j=1}^m x_{(u,ij)} = 1, \quad i = 1, 2, \dots, n, \quad n < m \quad (2-4)$$

根据 UAV 与目标数量的对应关系，当 $n \geq m$ 时，UAV 数量多于或等于要执行的目标数量，此时任务决策要求每架 UAV 必须且至少打击一个目标点；当 $n < m$ 时，UAV 数量少于目标数量，UAV 必须执行多于一个目标才能完成要求的任务，因此任务决策要求每个目标点至少被一架 UAV 打击。

2) 单机约束条件：

$$B_k^{i,i+1} \geq \min\{|P_k^j - P_k^i| \}, i, j = 1, 2, \dots, k \quad (2-5)$$

$$\varphi \geq \arccos\left(\frac{a_i' a_{i+1}}{|a_i| |a_{i+1}|}\right), i = 1, 2, \dots, n \quad (2-6)$$

$$\theta \geq \arctan\left(\frac{|z_{i+1} - z_i|}{|a_i|}\right), i = 1, 2, \dots, n \quad (2-7)$$

$$\sum_{i=1}^{C_s} f_{TAi} < f_{TA}^*, i = 1, 2, \dots, n \quad (2-8)$$

仅考虑单架次 UAV 自身的飞行限制条件，其中，(2-5)式表示最小航迹段长度约束， $B_k^{i,i+1}$ 表示航迹 Tr_k 上相邻两点 p_k^i 到 p_k^j 的距离；(2-6)式为最大水平转角约束， φ 为 UAV 机动时从点 p_k^i 到点 p_k^j 的转角，其中方向向量 $a_i = (x_k^{i+1} - x_k^i, y_k^{i+1} - y_k^i)'$ ；(2-7)式为最大爬升/俯冲角约束， θ 为两点间高度差和方向向量的倾斜角；(2-8)则为航迹段与威胁区的约束，表示点 p_k^i 附近的多个位置上威胁值之和小于临近威胁值。

3) 协同约束条件：

$$\begin{cases} \tau = T(j)_{\min} - T(i)_{\max} \\ t_j = t_i + \Delta t \quad i, j = 1, 2, \dots, m, \quad n < m \end{cases} \quad (2-9)$$

$$\begin{cases} [T_{k-1}, T_k] \neq \emptyset \\ \max\{t_i, \dots, t_j\} \leq T_k \quad i, j = 1, 2, \dots, m \\ \min\{t_i, \dots, t_j\} \geq T_k \quad i, j = 1, 2, \dots, m \end{cases} \quad (2-10)$$

$$\sum_{u=1}^n \sum_{i=1}^m \sum_{j=1}^m d_{ij} x_{(u,ij)} \leq \sum_{k=1}^n D_k \quad k=1,2,\dots,n \quad (2-11)$$

$$\max[\sum_{i=1}^m \sum_{j=1}^m t_{(u,ij)} x_{(u,ij)}, \forall u, i, j] \leq T_k \quad k=1,2,\dots,n \quad (2-12)$$

$$\bigcap_{u=1}^K ([t_{\min}(u), t_{\max}(u)]) \neq \emptyset \quad K=1,2,\dots,n \quad (2-13)$$

考虑多架 UAV 协同执行任务的情况，式(2-9)表示目标 j 必须晚于目标 i 执行的时序关系，其中 τ 为 i, j 的最小时间间隔， T 为约定的任务完成时间， t 为实际执行时间；(2-10)表示多时窗约束，按不同时窗对目标分组，组内目标点的执行时间不能超过该组时窗范围 $[T_{k-1}, T_k]$ ；(2-11)、(2-12)表示最大航程约束和最大执行时间约束；(2-13)表示同时到达目标的协同约束， $t(u)$ 表示第 u 个 UAV 的执行时间， K 表示参加协同的 UAV 数量，要求参与协同的各 UAV 执行时间交集非空。

在此基础上，进一步简化目标函数和决策变量的表示形式，并将各种约束条件以违背惩罚项加权和给出，目标函数综合形式可表示如下：

$$f(x) = (\sum_{i=1}^n \sum_{j=1}^m w_j d_{(i,j)} x_{(i,j)} + \alpha \left(\max \left(\sum_{i=1}^n \sum_{j=1}^m t_{(i,j)} x_{(i,j)} \right) \right) + \beta \sum_{k=1}^K c_k \quad (2-14)$$

其中， c_k 表示违背约束的惩罚值， w_j 是目标 j 的权重系数，其取值范围为： $0 < w_j \leq 1$ ， α ， β 是缩放因子，用于平衡多项式量纲，通常根据经验取值。 $x_{(i,j)}$ 是决策变量，用于决定 UAV 与目标点的对应关系。该式将约束关系以罚函数的形式给出，使有约束的最优化问题变成无约束最优化问题，简化了最优化的求解。

2.2.2 协同约束关系分析

因为单机约束在很多文献中已有详细的分析，因此本文重点分析多机协同的协同约束关系。根据 MUAS 目标分配的协同性能需求，主要考虑以下几项协同约束关系，通过约束违背量的计算，使目标分配的结果更加合理可靠，算法的准确性有所提高。

1) 最大航程约束：体现各 UAV 的性能和航油消耗指标，表示在完成任务过程中各 UAV 的最大航程限制。该约束反映协同的关键是：保证每架 UAV 分配其能力可行的目标，如果分配的目标不可达，将对其进行惩罚。最大航程约束能够协调不同能力的 UAV 共同完成指定的任务。

$$D_{\text{constrain}} = \begin{cases} 0 & d_{ij} \leq D_i \\ n & d_{ij} > D_i \end{cases} \quad (2-15)$$

式(2-15)中 D 为 UAV 最大航程能力矩阵, d_{ij} 为航程代价, 当 UAV 航程代价超过其最大航程时进行惩罚。

2) 最大飞行时间约束: 体现了 UAV 的速度约束和执行任务的续航性能, 表示 UAV 完成任务的最长飞行时间限制。该约束反映协同的关键是: 保证所有 UAV 都在其最大执行时间内完成分配的目标。最大飞行时间约束能够协调各 UAV 在规定飞行时间内打击目标。

$$T_{\text{constrain}} = \begin{cases} 0 & \frac{D_{(i,j)}}{v_{u \min}} \geq \frac{d_{ij}}{\bar{v}_u} \\ m & \frac{D_{(i,j)}}{v_{u \min}} < \frac{d_{ij}}{\bar{v}_u} \end{cases} \quad (2-16)$$

式(2-16)中 $v_{u \min}$ 为 UAV 最低飞行速度, $\bar{v}_u$ 为 UAV 平均飞行速度, 当 UAV 平均飞行时间超过最大飞行时间时进行惩罚。

3) 目标间时序约束: 体现了目标间的执行顺序和依赖关系, 表示 UAV 打击目标的时序特性和多时窗逻辑。该约束反映协同的关键是: 重要的目标应优先执行, 其它目标在重要目标之后执行; 当具有多个时窗逻辑时, 目标要严格限制在规定的时窗内执行。

$$\text{Ord}_{\text{constrain}} = \begin{cases} 0 & T_j - T_i > 0 \\ k & T_j - T_i \leq 0 \end{cases} \quad (2-17)$$

式(2-17)表示算法趋于淘汰违背时序的分配结果。时序约束可由目标时序约束矩阵给出, 该矩阵由多个二元组 (i,j) 组成, 表示任 i 必须在任务 j 之前执行。

$$T_{\text{window}} = \begin{cases} 0 & T_{k-1} \leq [t_i, \dots, t_j] \leq T_k \\ l & [t_i, \dots, t_j] > T_k, [t_i, \dots, t_j] < T_{k-1} \end{cases} \quad (2-18)$$

式(2-18)表示同一时窗中的 UAV 若超出时窗范围, 则进行惩罚, $[T_{k-1}, T_k]$ 是第 k 个时窗的范围, t_i 到 t_j 为该时窗中包含目标的执行时间。

4) 同时到达约束: 体现了多机协作共同执行任务的能力, 表示 MUAS 必须同时到达某个目标。该约束反映协同的关键是: 执行相同任务的 UAVs 打击目标的时间窗口有交集, 多机可以同时发起攻击。

$$T_{min}(i) = \frac{L_{pi}}{v_{max}} + T_{Start}; \quad T_{max}(i) = \frac{L_{pi}}{v_{min}} + T_{Start} \quad (2-19)$$

$$S_{constrain} = \begin{cases} 0 & \bigcap_{i=1}^K ([T_{min}(i), T_{max}(i)]) \neq \varnothing \\ k & \bigcap_{i=1}^K ([T_{min}(i), T_{max}(i)]) = \varnothing \end{cases} \quad (2-20)$$

式(2-19)表示 UAV 的最小、最大飞行时间，式(2-20)表示若 UAVs 时间交集为空，则进行惩罚。当 UAVs 满足该约束时，对飞行时间短的 UAV，通过设置初始等待时间协调 MUAS 同时到达目标。

此外，为了确保 MUAS 同时到达目标，我们引入了最大初始等待时间矩阵 T_{wait} ，该矩阵允许某些 UAVs 等待其他 UAV 飞行一段时间后再出发，具体可描述如下：

$$T_{wait} = [t_{wait}(1), t_{wait}(2), \dots, t_{wait}(k)], \quad k=1, 2, \dots, n \quad (2-21)$$

设 $T'_{max}(i) = T_{max}(i) + T_{wait}(i)$ ，则同时到达约束的惩罚项就可以改为：

$$S_{constrain} = \begin{cases} 0, & \bigcap_{i=1}^L ([T_{min}(i), T'_{max}(i)]) \neq \varnothing, L=1, 2, \dots, n \\ K_p & \bigcap_{i=1}^L ([T_{min}(i), T'_{max}(i)]) = \varnothing, L=1, 2, \dots, n \end{cases} \quad (2-22)$$

其中， $T_{min}(i)$ 是 UAV 以最高速度完成任务的时间， $T_{max}(i)$ 是 UAV 以最低速度完成任务的时间。 K_p 是惩罚项，当协同任务的时间没有交集时进行惩罚。

2.3 MUAS 的统一目标分配方法

2.3.1 多机协同统一目标分配模型

基于 MUAS 协同目标分配和航迹规划的统一数学模型，我们重点研究实际应用中的多机协同目标分配模型的求解方法。因为目标分配是航迹规划的前提和基础，正确合理的目标分配结果可以在决策上优化具体的航迹规划和执行，可以避免航迹规划时的重复分配和资源冲突等问题。此外，如果在目标分配时完成 UAV 与任务的对应委派，那么在航迹规划阶段就可以只关注航迹的优化生成，因此研究不同模型的统一目标分配问题，可以为航迹规划提供有力的指导。为了能够建立起统一的分配模型，可以按 UAV 和目标点的执行关系进行


分类, 这样的分类方式只考虑任务目标和执行者之间的对应关系, 而将类型信息、任务强度、约束限制等作为问题求解的条件放到具体的计算方法中实现, 因此可以将不同的类型统一到一起进行分析。现假设非 0 正整数 N 代表 UAV 数量, M 代表目标点数量, 则按任务执行的关系, 有以下三种分配模型:

1) UAV 与要执行的目标数量相同($N=M$) 时: 要求在模型中找到一对一执行目标的分配关系(如图 2-1(a)所示), 使总的任务代价最小。该模型任务关系简单, 协同约束少, 容易计算, 但是对 UAV 性能要求过高, 一旦有 UAV 毁伤就会导致任务失败。求解的难点在于避免目标竞争引发的冲突, 并利用协同执行任务降低毁伤概率等。

2) UAV 多于要执行的目标点($N>M$)时: 要求在模型中至少一个目标可以分配给多架 UAV 共同执行, 一架 UAV 只能执行一个目标(如图 2-1(b)所示), 所有 UAV 执行全部目标的总代价最小。该模型对应关系不平衡、协同时间约束复杂、任务难度大, 但可以避免部分 UAV 失效导致的任务失败问题, 还能分解复杂的目标, 利用 MUAS 协作共同完成任务。求解的难点在于分配任务不平衡性增加了计算复杂度, 严格的时间约束如同时到达目标等, 可能导致多机协作困难。

3) UAV 少于要执行的目标点($N<M$)时: 要求在模型中一架 UAV 可分配多个任务目标, 并按照一定的巡航次序依次执行这些目标, 一个目标则只有一架 UAV 执行(如图 2-1(c)所示), 所有 UAV 执行全部目标的总代价最小。该模型是一个典型的群巡游问题(UAV Swarm Routing Problem, SRP)^[103], 其对应关系不平衡, 具有特定的巡航逻辑, 巡航代价计算复杂, 对 UAV 的性能要求较高, 但该模型能够利用最少的 UAV 资源完成复杂的任务, 并能有效处理时序约束关系。求解的难点在于既要考虑单机巡航的最优化, 还要顾及多机间巡航执行任务的协同, 巡航代价计算复杂, 求解难度大, 该问题是目前研究的难点。

在实际应用中, 往往是多种不同类型目标分配问题的综合求解, 尤其是在不同类型任务混合执行时, 某些目标可能需要多类型 UAV 重叠执行, 因此以上三种模型可以相互混合, 互相影响 (如图 2-1(d)所示), 给整体的目标分配求解带来较大的困难。例如美国国防部提出的 SEAD (Suppression of Enemy Air Defense)任务分配系统, 异构无人机要同时执行三种不同的任务: 侦察、打击和评估^{[13][104]}。当三种任务混合在一起执行时, 就可能出现多种模型混合, 并相互影响制约的情况, 此时就迫切需要统一的模型或算法进行目标分配处理。






图 2-2 三维环境下 MUCMTA 案例

Fig 2-2 The scenario of MUCMTA in 3D environment

多机协同目标分配还要考虑不平衡指派 ($N > M$, $N < M$) 的情况, 因此可以根据 UAV 和任务的数量关系, 扩展指派问题模型的决策变量表示, 则统一的分配模型可描述如下:

其中 $x_{(u,ij)}$ 为决策变量, 根据不同的任务模型有:

$$x_{(u,ij)} = \begin{cases} x_{(u,i)} & n = m \\ x_{([u_m, u_k], i)} & n > m \\ x_{(u, [i, j])} & n < m \end{cases} \quad (2-23)$$

1) 当 $n = m$ 时 $x_{(u,i)}$ 表示一对一的对应关系:

$$x_{(u,i)} = \begin{cases} 1 & \text{任务 } i \text{ 被 } u \text{ 执行} \\ 0 & \text{否则} \end{cases} \quad (2-24)$$

2) 当 $n > m$ 时 $x_{([u_m, u_k], i)}$ 表示多对一的对应关系:

$$x_{([u_m, u_k], i)} = \begin{cases} 1 & \text{任务 } i \text{ 被 } [u_m, \dots, u_k] \text{ 执行} \\ 0 & \text{否则} \end{cases} \quad (2-25)$$

3) 当 $n < m$ 时 $x_{(u, [i, j])}$ 表示一对多的对应关系:

$$x_{(u, [i, j])} = \begin{cases} 1 & \text{任务 } [i, \dots, j] \text{ 被 } u \text{ 顺序执行} \\ 0 & \text{否则} \end{cases} \quad (2-26)$$

其中 $u = 1, 2, \dots, n$ 代表不同的 UAV, $i, j = 1, 2, \dots, m$ 代表不同的目标。由此, 目标分配的决策变量可进一步表示为:

$$x_{(i,j)} = \begin{cases} x_{(i,j)} & N = M \\ x_{(i',j)}, i' = [i_s, \dots i_l], s, l \in N & N > M \\ x_{(i,j')}, j' = [j_p, \dots j_q], p, q \in M & N < M \end{cases} \quad (2-27)$$

采用该决策变量的分配模型，可将三种目标分配的情况统一在一起，描述了一致性的分配关系。为求解该模型，本章首先建立了仿真三维环境，设定地理信息地形信息、威胁区域、UAVs 和目标点的坐标；然后结合三维垂直切面快速估算航程代价，并根据不同模型的代价矩阵统一求解方式；最后采用改进的差分进化算法验证统一模型的可行性。此外，还要分析各种协同约束关系，并将航程代价、时间代价与约束违背量之和做为适应度函数。因此，统一目标分配的体系结构如图 2-3 所示。




图 2-3 统一的目标分配模型结构图

Fig 2-3 Structural drawing of uniform target assignment model

2.4 基于垂直切面的航程代价和协同约束

2.4.1 多机航程代价的估算

UAV 在无法预知航迹的前提下，不能精确计算航程代价，只能用估计的代价求解目标分配问题。因此，航程代价表示方法的优劣，极大程度决定了分配结果的可靠性和合理性。目前常利用两点间直线距离、有障碍连通图或 Voronoi 图上的航迹段距离来近似估算二维 UAV 的航程代价。本章提出一种基于垂直切面的三维航程代价估算方法，使三维环境下估算的航程代价更合理有效。

该方法的主要思想是，利用 UAV 和目标点间的三维垂直切面简化航程代价的估算，忽略 UAV 的飞行限制条件，在垂直切面上利用地形信息跟随和 UAV 飞行保持获取近似三维航程，估算航程代价。有效解决三维环境中连通图或

Voronoi 图无法表示航程，直线距离计算航程误差大，其他现有方法难以计算的问题。

本章采用 DEM(Digital Elevation Model)数字高程模型来描述环境区域空间的地貌形态。通过初始点 S 和目标点 T 的连线做垂直水平面的切面，将切面与地形相交的高程值作为估计航程的基准，通过坐标变换，在二维切面坐标系上规划出一条满足地形跟随和飞行高度策略的航迹，此航迹的长度与目标权重的乘积即为预估计的航程代价。算法具体步骤如下：

Step1: 取初始点 S ，目标点 T ，以及两点的连线 $L(S,T)$

Step2: 在 $L(S,T)$ 上取一点做垂直于 XOY 平面的垂线，在垂线上取一点 M ，过 S 、 T 、 M 做平面 STM 即为垂直于 XOY 平面的切割面。

Step3: 求出切割面与地形和威胁区的所有交点，将切割面映射成二维坐标面，取 $L(S,T)$ 为 x 轴， Z 为 y 轴，进行坐标变换，将所有与切割面相交的地形和威胁区上的点映射到此二维坐标系上。

Step4: 在二维坐标系上，按照以下原则，生成估计航迹：

假设初始飞行高度比初始点高 mx ，飞行器按此高度开始飞行，当飞行器与地形高度之间的距离小于 mx ，则逐渐爬升；当高度距离大于 mx 且小于 my ，则保持平飞；当高度距离大于 my 则飞行器逐渐下降。

Step5: 计算估计航迹长度 L ，将其作为航程代价与目标点的权重相乘，获得初始点与目标点间的代价值 $D(i, j)$ 。


$$D(i, j) = L(S, T) * W(T) \quad (2-28)$$

此外，雷达的可侦测区域是 UAV 面临的主要威胁，假设雷达侦测的范围在空间各方向上相同，则以雷达最大侦测距离为半径的半球区域可表示如下：

$$Z_{thread(i)} = \sqrt{r^2 - (x - x_0)^2 - (y - y_0)^2} + z_0 \quad i = 1, 2, \dots, n \quad (2-29)$$

其中 (x_0, y_0, z_0) 为圆心， r 为半径。加入威胁区域后，估计航程的策略按照新的威胁与地形共同的高程值为基准进行调整，生成符合实际情况的估计航程，如图 2-4 所示。

在切面上获得一条可行的航线，作为这个目标的估计航程值，这种方法虽然不是实际最短的航程，但是充分利用了三维地形信息，比计算两点间直线距离的方法更接近最优航程，且计算简单快速，适合三维环境的多机协同目标分配问题求解。



(a) Schematic drawing of 3D vertical section (b) Flight path length cost be mapped

图 2-4 基于垂直切面的估计航程代价

Fig 2-4 Estimated cost of path length by 3D vertical section

2.4.2 航程代价矩阵构建

利用垂直切面法估算航程代价比计算直线距离复杂，如果在迭代中重复计算会严重降低算法的性能。参考匈牙利算法在代价矩阵中搜索最优组合的方法，可以利用航程代价矩阵预先存储全部代价值，在 DE 进化计算时，通过查找航程代价矩阵减少重复计算，提高算法的效率。基于不同的指派问题模型，其代价矩阵也是不同的。因此定义各模型的代价矩阵如下：

1) 无人机与目标相等的代价矩阵：当 $N=M$ 时，代价矩阵 $\mathbf{c}_{\text{cost1}}$ 为方阵。矩阵中的每个值 $c_{i,j}$ 表示第 i 个无人机执行第 j 个任务所需要的航程代价。

$$\mathbf{c}_{\text{cost1}} = \begin{pmatrix} c_{1,1} & \cdots & c_{1,n} \\ \vdots & \ddots & \vdots \\ c_{n,1} & \cdots & c_{n,n} \end{pmatrix} \quad (2-30)$$

2) 无人机多于目标的代价矩阵：当 $N>M$ 时，代价矩阵 $\mathbf{c}_{\text{cost2}}$ 是非方阵。矩阵中的每个值 $c_{i,j}$ 表示第 i 个无人机执行第 j 个任务所需要的航程代价，其中多个不同的无人机可以执行同样的任务 j 。

$$\mathbf{c}_{\text{cost2}} = \begin{pmatrix} c_{1,1} & \cdots & c_{1,n} \\ c_{2,1} & \cdots & c_{2,n} \\ c_{3,1} & \cdots & c_{3,n} \\ \vdots & \ddots & \vdots \\ c_{m,1} & \cdots & c_{m,n} \end{pmatrix} \quad (2-31)$$

3) 无人机少于目标的代价矩阵: 当 $N < M$ 时, 代价矩阵 $\mathbf{c}_{\text{cost}3}$ 由两部分组成: 矩阵上半部分为无人机与目标代价矩阵, 矩阵中的每个值 $c_{i,j}$ 表示第 i 个无人机执行第 j 个任务所需要的航程代价, 矩阵下半部分为目标与目标之间的航程代价矩阵, 矩阵中的每个值 $t_{i,j}$ 表示以目标点 i 为起点与其他目标点 j 之间的航程代价, 该矩阵是一个左对角线为 0 的对称方阵。

$$\mathbf{c}_{\text{cost}3} = \begin{pmatrix} c_{1,1} & \cdots & c_{1,m} \\ \vdots & \ddots & \vdots \\ c_{n,1} & \cdots & c_{n,m} \\ 0 & \cdots & t_{1,m} \\ \vdots & \ddots & \vdots \\ t_{m,1} & \cdots & 0 \end{pmatrix} \quad (2-32)$$

在此代价矩阵中, 即可查出 UAV 从出发点开始执行首个任务的代价, 还可查出该 UAV 从已完成任务点出发, 继续执行其他任务的代价。

根据代价矩阵, 计算目标分配总航程代价和最大航行时间的方法如下:

1) 当 $N=M$ 或 $N>M$ 情况时, 总的航程代价为分配结果中所有 UAV 航程代价的总和, 最大航行时间为分配结果中所有目标消耗时间的最大值, 它们分别为:

$$D_{\text{all}} = \sum_{i=1}^n \sum_{j=1}^m d_{ij} x_{(i,j)} \quad (2-33)$$

$$T_{\text{max}} = \max[d_{ij} x_{(i,j)} / v_i, \forall i, j] \quad (2-34)$$

2) 当 $N < M$ 时, 目标分配模型是一个 SRP 问题模型, 其代价由 UAV 与目标代价和目标与目标代价两部分组成, 如图 2-5 所示。此时, 总航程代价为所有 UAVs 完成巡游的航程代价综合, 其总航程代价和最大航行时间分别为:

$$D_{\text{all}} = \sum_{u=1}^n \sum_{i=1}^m \sum_{j=1}^m (d_{ui} x_{(u,i)} + d_{ij} x'_{(i,j)}) \quad (2-35)$$

$$T_{\text{max}} = \max[d_{ui} x_{(u,i)} / v_u + \sum_{i=1}^m \sum_{j=1}^m d_{ij} x'_{(i,j)} / v_u, \forall u, i, j] \quad (2-36)$$

2.5 基于统一目标分配模型的验证

为了验证统一模型进行多机协同目标分配的有效性, 我们改进差分进化 (Differential Evolution, DE) 算法以对多模型的分配问题进行验证。首先根据目标分配的序列对多种模型进行统一的基因编码表示, 然后为了使 DE 算法能够适




图 2-5 SRP 任务示意图和代价矩阵

Fig 2-5 Schematic drawing of SRP and cost matrix

应离散的组合优化问题，参考遗传算法中常用的部分交叉映射方法，我们提出了一种适合差分进化交叉操作的部分交叉映射算法，以有效的求解离散的问题，具体内容如下：

1) 对进化的个体基因进行编码。根据 UAV 与目标点的对应关系，假设 UAV 是有序的，因此只考虑对应目标的顺序即可。用目标点的排序作为差分进化的个体编码，目标点的序列值就表示个体上的某个基因，如图 2-6 所示：

Uav	1	2	3	4	5	6	7	8
Target (n=m)	3	6	4	5	1	8	2	7
Target (n>m)	1	1	1	2	2	3	3	3
Target (n<m)	3	6	4	5	1	8	2	7

图 2-6 个体的统一基因编码表示

Fig 2-6 Unified gene encoding and population initialization

根据图 2-6，种群初始化的过程就是随机生成 s 条目标点不重复序列的过程，生成的每个序列与 UAV 的排序相对应，即成为一个目标分配的进化个体。在保持 UAV 按序排列的基础上，差分进化的目的就是选取已有目标序列个体进行差分计算，产生新的目标序列，并通过比较新个体与父代个体的协同适应度分值来决定整个种群进化繁殖方向的过程。此外，在 $N < M$ 情况时，考虑到任务分组和巡游的顺序，假设 UAV 按顺序依次执行分组中的目标点，以方便代价的计算，提高找到优解序列的速度。

2) 执行部分交叉映射操作。遗传算法中常用部分映射交叉算子(Partially Mapped Crossover)来解决组合优化问题^[20]。部分映射交叉算子是将交叉后的染色体中重复的部分一一映射，然后按位置交换映射，保证新染色体是符合要求的不重复排列。DE 进化的交叉是实数域的运算，如果生成新的个体时，仅将

差分结果取整，那么新个体中可能有重复值、零值、负值或越界值，这样无意义的个体将导致差分进化的失败，如图 2-7 所示。

Uav	1	2	3	4	5	6	7	8
Target1	1	2	3	4	5	6	7	8
Target2	2	3	5	1	6	4	7	8
Target3	2	4	7	6	1	8	3	5

↓

Uav	1	2	3	4	5	6	7	8
(2-3)	0	-1	-2	-5	5	-4	4	3
1+(2-3)	1	1	1	-1	10	2	11	12

图 2-7 错误的差分结果

Fig 2-7 Error results of differential

文献[105]将实数运算结果的排序作为新个体基因位置映射，使 DE 算法适于组合优化问题的求解，但该方法忽略了繁殖过程中差分的作用，增大了映射的随机性，降低了遗传对子代的影响。因此参考和扩展部分交叉映射算子并与文献[105]的方法相结合，提出一种新的适合 DE 求解离散组合优化问题的交叉映射差分进化方法，其操作过程如图 2-8 所示。

Uav	1	2	3	4	5	6	7	8
Target1	8	2	5	1	6	7	3	4
Target2	5	7	4	6	8	2	1	3
Target3	3	8	1	4	2	5	7	6

↓

Uav	1	2	3	4	5	6	7	8
Target1	8	2	5	1	6	7	3	4
(2-3)	2	-1	3	2	6	-3	-6	-3

↓

Uav	1	2	3	4	5	6	7	8
1+(2-3)	10	1	8	3	12	4	-3	1
Ref	2	5	6	7				

↓

Uav	1	2	3	4	5	6	7	8
New	6	7	8	3	5	4	2	1

图 2-8 部分交叉映射算子交叉过程

Fig 2-8 The crossover process of partially mapped crossover operator

在图 2-8 中，种群个体首先选择无人机序列进行差分，计算后的解 x 中存在越界值 $x(1)=10$ ， $x(5)=12$ ，负值 $x(7)=-3$ ，重复值 $x(2)=x(8)=1$ ，设 x 中没有出现的值的数组 $R_{ref}=[2,5,6,7]$ ，将这些整数映射到不符合要求的基因 $x(1), x(5), x(7), x(2)$ 上，生成新的可行 UAV 排列。然后将有序的目标点排列重新随机分组，两者组合形成新的个体。验证统一目标分配的差分交叉映射算法流程如算法 2-1 所示。

算法2-1 验证统一目标分配的差分交叉映射算法
Alg 2-1 A verification algorithm of partially mapped crossover for
uniform targets assignment

输入： 群体规模 $P(k)$ ，迭代次数 $G(n)$ ，代价矩阵 MC ，变异率 P_c ，约束条件 $C(l)$
输出： 适应度最优的解 x

```

01:  For  $i=1, \dots, k$ , do                                /*初始化种群*/
02:      根据目标数量 $m$ 随机生成不重复的排序 $P(i)$ ;
03:  End for
04:   $g=0$ ;
05:  While ( $g < G(n)$ ) do                                /*部分交叉映射的差分进化*/
06:      For  $j=1, \dots, k$ , do
07:           $r1, r2, r3 \in \text{rand}[1, 2, \dots, k]$ ;        /*随机产生三个不一样的数*/
08:           $s \in [1, 2, \dots, k]$ ;                      /*随机产生备选个体序号*/
09:          If  $S_c > \text{rand}[0, 1]$  then
10:               $c = P(r1) + P_c \times (P(r2) - P(r3))$ ;
11:              取出 $c$ 中不合理的基因组成参考数组:  $Ref[n]$ ;
12:              根据 $Ref$ ，替换 $c$ 中不合理的基因，更新 $c$ ;
13:              根据 $Ref$ ，替换 $c$ 中值相同的基因，更新 $c$ ;
14:              验证 $c$ 满足可行目标分配解的要求;
15:              子代个体:  $Tr=c$ ;
16:          Else
17:              子代个体:  $Tr=P(s)$ ;
18:          End if
19:          子代个体的适应度 $f(tr)$ ;                      /*根据代价矩阵计算*/
20:          If  $f(tr) < \min(f(x))$  then
21:               $x=tr$ ;
22:          End if
23:           $g=g+1$ ;
24:      End for
25:  End while

```

应用部分交叉映射的方法可以使父代在差分过程中生成符合规则的子代，算法能在离散的空间进行搜索；映射过程保留了差分计算中合理的结果、增加了遗传进化的信息量、提高了算法的性能。因此，该算子可以使差分进化适合于多无人机协同目标分配求解。

3) 基于灭绝的种群变异。采用部分交叉映射的差分进化算法，可能出现局部最优解在短时间内填满种群的“早熟”现象。文献[42]中采用种群灾变的思想解决这一问题，但是必须等到局部最优解保持恒定不变后才进行灾变，增加了等待时间和计算的冗余。自然进化中的变异是随机产生的一种特性，因此应该在进化过程中随机变异；但部分随机变异的结果可能导致当前已经找到的最优解丢失，且变异的幅度和效率不高，往往起不到刺激种群的作用。因此，为了

有效提高种群变异对整体和个体的影响，我们结合变异率和集群灭绝的思想对进化种群进行整体变异操作，一次灭绝的过程就是将种群中现有个体全部杀死，然后繁衍重生出全新的群体，同时将上一代的最优个体加入灭绝后的种群，这样做不仅有效改变了种群的生存行为，还保护了当前最优解，保证优化的结果不会丢失。

基于灭绝的种群变异算子由变异率、种群重置、优解保留三部分组成，变异率 S_c 随机决定种群是否变异；种群重置是生成全新的变异种群替换当前全部种群个体；优解保留则将当前最优解加入到灭绝后的种群，使上一代的最优解能够保留在变异种群中，公式表示如下：

$$x_j(t) = \begin{cases} \text{new}(x_j(t)); & x_j^{(i)}(t) = x(t)^{\text{best}}, \text{ if } S_c > \text{rand}[0,1] \\ x_j(t), & \text{otherwise} \end{cases} \quad (2-37)$$

基于灭绝的种群变异算子避免了“早熟”现象，且不需要额外的计算；最优解保留使算法能够朝着更优的方向进行。该算子的应用解决了差分进化中容易陷入局部最优解的问题。

2.6 实验结果和分析

本章在双核主频 1.86GHz，内存 4GB，并安装 64 位操作系统的微机上，利用 64 位版本的 Matlab 仿真软件，对三维 MUAS 协同目标分配算法进行仿真实验。假设执行任务的三维空间范围为：180km×220km×50km，采用 Matlab Mapping 工具箱提供的标准 DEM(USGS 30-meter Digital Elevation Models)地形数据做为实验验证的真实地理数据信息和仿真环境规划空间，随机设置三个固定雷达侦测点，设定不同的 UAV 和目标数量及初始参数，对目标分配模型进行仿真实验。

2.6.1 验证统一目标分配模型的分配效果

实验 2.1：针对分配模型进行仿真，验证算法能否统一处理不同的分配模型；能否找到较优的可行解；能否处理各种协同约束关系。实验初始数据设定 UAV 和目标点的数量：N=8，M=8；起飞点的坐标矩阵 U_{start} ；飞行器能力矩阵 En (UAV 最大、最小飞行速度)；飞行器最大航程矩阵 $MaxD$ ；目标点坐标矩阵 $Target$ ；目标点权重矩阵 W (W 分为四个级别，级别高的优先执行)；目标点时序关系矩阵 $TSort$ ($[i, j]$ 表示任务 i 先于任务 j 执行)。实验的参数设定如表 2-1 所示。

表 2-1 实验 1 的数据设定
Tab 2-1 The data of experiment 1

模型	参数	1	2	3	4	5	6	7	8
N=M	<i>Ustart</i>	[11,2,3]	[2,17,5]	[34,26,7]	[5,2,2]	[6,33,3]	[27,34,6]	[21,45,5]	[25,12,3]
	<i>En(km/m)</i>	[0.2,0.3]	[0.2,0.4]	[0.4,0.75]	[0.3,0.6]	[0.2,0.3]	[0.35,0.45]	[0.3,0.5]	[0.3,0.6]
	<i>MaxD(km)</i>	400	700	650	500	700	900	450	610
	<i>Target</i>	[40,210,22]	[170,90,13]	[80,197,21]	[172,120,13]	[160,56,13]	[160,143,21]	[170,200,21]	[113,200,12]
	<i>W</i>	1.0	3.0	4.0	2.0	1.0	1.0	3.0	3.0
	<i>Tsort</i>	[3,4]	[5,2]	[6,8]	[7,4]				
N>M	<i>Ustart</i>	[31,20,11]	[112,27,12]	[134,26,7]	[45,52,11]	[36,133,12]	[67,34,16]	[21,185,10]	[26,62,11]
	<i>En(km/m)</i>	[0.2,0.3]	[0.2,0.4]	[0.4,0.75]	[0.3,0.6]	[0.2,0.3]	[0.35,0.45]	[0.3,0.5]	[0.3,0.6]
	<i>MaxD(km)</i>	400	700	300	500	700	900	450	610
	<i>Target</i>	[40,190,13]	[120,180,21]	[112,199,13]					
	<i>W</i>	1.0	2.0	1.0					
	<i>Tsort</i>	[1,2]	[3,1]						
N<M	<i>Ustart</i>	[150,27,5]	[65,26,23]	[11,45,5]					
	<i>En(km/m)</i>	[0.2,0.4]	[0.4,0.75]	[0.3,0.6]					
	<i>MaxD(km)</i>	900	700	850					
	<i>Target</i>	[30,181,12]	[15,133,13]	[19,151,12]	[160,192,13]	[100,100,23]	[160,113,12]	[22,101,11]	[173,140,12]
	<i>W</i>	1.0	1.0	3.0	1.0	1.0	4.0	1.0	1.0
	<i>Tsort</i>	[2,4]	[4,6]	[7,3]					

考虑最大航程约束、最大飞行时间约束、目标间时序约束，在 $N>M$ 时，考虑同时到达约束，设定算法迭代 500 次，交叉率 $Pc=0.9$ ，变异率 $Sc=0.5$ ，实验结果如图 2-9 所示；为验证算法搜索较优解和处理协同约束的能力，对每个模型进行十次实验，分配结果如表 2-2 所示，表中 UAV 表示无人机序列，*TAR* 表示目标点序列，各种约束关系用布尔值表示，值为 0 表示符合该约束条件，为 1 表示违背了该约束；代价值是一个综合了优化目标和各种约束违背量的适应度分值，且根据不同模型进行了适当缩放，所以是无单位量纲。

从实验结果可以看出，算法适合解决三种不同情况的多机目标分配问题，且满足各种协同约束条件；多组实验均收敛到一致的解，证明算法具有一定的全局寻优能力，能够找到较好的可行解。从图 2-9 中可以看出目标分配对应的结果和估计的航程表示，其中黄色圆圈表示 UAV 的出发位置，黄色五星表示要执行的任务位置，黄色半圆区域为雷达威胁区或禁飞区，灰色为 DEM 高程地形，单位为 *km*。图 2-9 (a)~(c) 分别表示三种分配类型的分配结果，其中蓝色线代表垂直切面与地形的交线，红线代表估计航程，图 2-9(d) 是综合复杂情况下分配的结果。从表 2-2 中可以看出， $N=M$ 时计算量小，算法时间短，




图 2-9 实验 1 的分配结果

Fig 2-9 Assignment results of experiment 1

表 2-2 实验 1 的结果数据

Tab 2-2 The results of experiment 1

模型	解集	代价值	实验次数	平均时间(s)	航程约束	时间约束	时序约束
$N=M$	UAV 1 1 1 2 3 3 3 3	993.1809	10	363.3825	0	0	0
	TAR 8 4 6 5 2 1 3 7						
$N>M$	UAV 2 1 7 3 8 5 4 6	792.8408	10	401.0131	0	0	0
	TAR 1 1 2 2 3 3 3 3						
$N<M$	UAV 1 1 1 2 3 3 3 3	869.2282	10	363.3825	0	0	0
	TAR 8 4 6 5 2 1 3 7						

$N>M$ 和 $N<M$ 时相对复杂，算法时间较长；三种情况分配的结果均可满足最大航程约束、最大时间约束和时序协同约束，在 $N>M$ 时，可满足同时到达目标的协同约束。

2.6.2 分配目标数量增多时的效率分析

实验 2.2: 对比 UAV 和目标点数量增多时算法的效率，并比较交叉率和变异率对求解的影响，验证增大求解规模时算法的分配能力。当 $N=M$ 时，执行时间随目标数量增加的曲线如图 2-10 所示。




图 2-10 UAV、目标数量与执行时间对比

Fig 2-10 Comparison between UAVs, targets and execution time

从实验结果可以看出，算法执行时间随 UAV 和目标数量的增多，近似成比例增长，可以有效对问题求解。不同的交叉率和变异率对执行时间影响较大，当两者较小时，虽能减少算法执行时间，但会导致局部最优；当两者较大时，会增加执行时间，降低算法效率。因此适当的交叉率和变异率设置是获得算法最优性能的关键。

当 $N>M$ 和 $N<M$ 时，由于模型的不平衡性，导致问题的复杂度远大于 $N=M$ 的情况。为验证算法性能，逐渐增大实验的规模，分别设定四组 UAV 和目标数量递增的实验进行比较。最后，为验证算法处理大规模综合作战的能力，分别设定 UAV 和目标数量为 100 和 150 两组各种模型综合的复杂情况进行实验，实验的结果如表 2-3 所示。

从表 2-3 可以看出，当 $N>M$ 或 $N<M$ 时，算法性能和执行效率随 UAV 和目标数量的增多降低较快，违背协同约束条件的次数增多，这与该模型下问题的复杂程度成正比，算法虽然执行时间较长，但分配的结果中，违背约束的总次数仍是个较小的值，因此绝大部分的 UAV 都可以完成指定的任务，而产生违背约束的目标可以由冗余的 UAV 或其他已经完成任务的 UAV 继续完成，较小次数的约束违背与大规模的任务相比，是在可以接受的范围内的，其获得的目

标分配的解仍然是可行的，且接近全局最优解，因此，该模型能够有效完成较大规模的目标分配任务。当 UAV 与目标数量的各种对应关系类型混合在一起时，可以通过任务分解先将不同类型的任务按 $N=M$ 、 $N>M$ 和 $N<M$ 三种模型进行分组，然后依据统一的模型和处理方法，针对任务所属分组逐一进行目标分配，以简化对复杂问题的求解。实验表明该模型可以获得有效的复杂目标分配结果。

表 2-3 实验 2 的结果数据
Tab 2-3 The results of experiment 2

类型	N	M	Pc	Sc	迭代次数	代价值	执行时间(s)	违背约束(次)
N>M	8	3	0.9	0.5	500	792.8408	413.1218	0
	20	10	0.7	0.4	500	3104.1021	700.6941	4
	30	20	0.6	0.3	500	4615.9210	876.7100	6
	50	30	0.8	0.2	500	7939.8401	1048.5010	6
N<M	3	8	0.9	0.5	500	869.2282	367.6788	0
	10	20	0.6	0.4	500	4084.7105	729.9911	3
	20	30	0.8	0.2	500	7293.7608	673.4563	1
	30	50	0.7	0.3	500	16300.0384	1504.1426	2
综合情况	100	100	0.8	0.4	500	16811.6000	2003.8339	11
	150	150	0.7	0.3	500	27963.3000	2675.9532	13

2.7 本章小结

本章首先建立了目标分配和航迹规划的统一数学模型，研究了各种多机协同的约束条件；然后扩展指派问题，基于数量对应关系统一多机协同目标分配的模型，并充分利用三维空间的地形和威胁信息，改进航程代价计算方法，提出基于垂直切面的三维航程代价估算方法，提高了代价计算的合理性；在此基础上，通过计算约束违背量提高多机执行任务时的协同性能，保证分配结果更准确合理，最后，采用部分交叉映射算法对统一目标分配模型的可行性进行验证，该方法虽然改进不足，效率较低，但是可以有效证明统一模型的效果。仿真实验表明统一模型的通用性较强，适应能力较好，能够有效解决三维环境下不同模型的 MUAS 协同多目标分配问题。然而为了获得更好的分配效率，还需要对目标分配的算法进一步深入研究。

第 3 章 基于统一目标分配模型的多机协同分配方法

3.1 引言

与单架无人机执行任务相比, MUAS 通过协同合作, 具有较高的速度、可靠性和灵活性^[107]。在复杂战场环境下, 某些综合作战任务必须由多机协同配合才能得以执行^{[11][38]}。因此 MUAS 已逐渐取代单机去执行各种复杂任务。但是, 多机协同作战增加了问题的规模, 问题的复杂程度随无人机和任务数量的增加呈几何级数增长。同时, 协同作战还受到环境限制、设备退化、共享资源竞争、协同约束、UAV 之间冲突等关键问题的影响^{[108]-[111]}。因此, 求解最小代价的多机协同最优解具有相当的挑战。此外, 三维空间的搜索范围较大, 因此很难建立有效的图结构表示。同时无人机必须在不平坦的地形上飞行, 并且要避免各种威胁区域和禁飞区, 而且这些无人机还要满足自身的约束和协同约束。因此, 规划时对三维环境考虑的越少, 就会给无人机带来越大的毁伤概率, 从而导致任务失败。因此, 实际的目标分配求解时, 应该综合考虑估计航程、执行时间和各种各样的协同约束条件。

然而, 现有的进化算法求解目标分配问题时, 大多应用于某一种目标分配模型的求解。当目标分配模型发生改变, 任务配比关系需要调整时, 原有的算法结构和编码表示就很难适应这些改变, 其原因在于固定的基因表示方法和针对性较强的约束关系设定。为解决此问题, 我们在上一章已经验证了利用改进的 DE 算法可以进行统一模型的多目标分配, 但是, 该方法执行目标分配的效率和性能还比较低。为了将 DE 算法有效用于统一的目标分配模型, 就必须着重考虑如何进一步设计出更合理的、适合多种 MUAS 任务分配模型的统一基因表示方法, 并要综合考虑单机约束和多机间协同约束的影响, 以提高 MUAS 协同目标分配的效率。此外, 虽然现有 DE 算法在求解连续问题上明显优于其他同类的进化算法, 但由于其仅支持连续函数, 在求解离散组合优化问题时, 仍需要进行复杂的空间转换。当前已有文献^{[42][105]}证明某些改进的 DE 算法可以较好处理离散问题, 但是这些方法没有考虑实际问题的物理意义与分配目标的关系, 因此搜索具有一定的盲目性, 所以, 在进化过程中, 对有效的空间转换策略也需要进一步深入的研究和分析。

因此, 在本章中我们深入改进差分进化算法的统一编码方式和差分进化

操作,以便更精细的求解 MUCMTA 问题。尽管 DE 算法已经被有效应用于组合优化问题,但在实际应用中该算法还是存在以下难点问题:

1) 如何根据实际任务代价,有效表示统一目标分配模型的解的形式和协同约束关系,以方便对不同类型的分配问题统一求解。设计统一、高效的基因编码策略,可以有效覆盖不同模型的问题求解,而且备选解表示的优劣也与搜索算法寻优效率的高低密切相关。此外如果将目标分配和航迹规划的任务表示统一在相同的编码策略下,则可以共享算法中相关的信息,保证分配与规划的协同统一。

2) 如何结合符合实际问题优化目标的任务代价进行有效的目标分配,与传统基于离散序列对应关系相比,在任务代价空间中对目标进行分配更为合理,也更符合真实优化目标的需要。文献[105]研究了差分进化应用于离散空间的方法,并测试了多种空间转换的映射规则,然而,这些规则与 UAV 和目标之间的关系很难建立有效的联系,因此无法应用于多机协同目标分配的问题求解。在多机协同目标分配问题中,UAV 与目标点的对应物理意义上与航程代价有着密不可分的联系,航程代价和约束关系充分表示了分配的有效性,因此在空间转换时要考虑到实际问题的物理意义,设计合理的空间转换映射规则,才能有效利用差分算法较好的求解性能,并保证算法向着正确的方向前进。

3) 现有采用进化策略进行目标分配等优化问题的求解,多数只关注于优化的某个方面,或者趋于更好的探索,或者趋于更快的收敛,然而保持两者的平衡可以有效提高搜索性能。搜索时既要保证尽可能探索到空间的未知区域,对空间有较大的覆盖性,同时还要保证局部搜索的精细化,以避免丢失了最优的进化方向。因此对不同策略的改进和混合,以保证算法的优良性能,平衡搜索的宽度和广度也是研究中的一个难点问题。

因此,本章在三维环境下深入研究易于表示不同模型的统一基因编码策略,并提出一种新颖的离散映射差分进化(Discrete Mapping Differential Evolution, DMDE)方法,该方法用统一的基因编码和进化算法框架处理各种分配模型;然后,设计了空间转换的离散映射和反映射规则,采用 UAV 与目标点对应的估计航程代价作为差分映射的媒介,将问题从离散空间转换到连续空间,保证了差分的合理性,使算法易于搜索到具有物理意义的临时最优解;接下来,反映射匹配策略将差分得到的临时解再映射回分配关系空间,综合产生进化可行的子代个体。此外,在进化过程中应用动态交叉率混合差分策略,也提高了离散差分算法的搜索效率。

3.2 基于 DE 算法的多机协同目标分配框架

DE 算法是基于种群进化的随机、平行搜索方法，它通过衡量个体间距离的差异产生子代个体，用以演化搜索^[43]。与其他智能方法相比，DE 采用了连续参数控制进化，因此具有更高的效率和竞争力。DE 算法在进化过程中与其他进化算法有相似的种群传递、繁殖、变异等进化特性^[105]，它的独到之处是通过向量差分计算当前种群个体间差异，进而在连续空间中执行快速有效的搜索^{[112][113]}。DE 算法的性能主要取决于进化个体的基因表示和差分策略的选取^{[105][114]}。基因表示是从微观上对解的变化的考察，因为差分进化是根据个体间距离差异向量来判断变异的步长，进行优化搜索的方法，因此基因表示、选取和变化方式可以直接反映出群体进化的趋势。差分策略则根据不同的参数形式重组解向量，在探索 and 开发两个方面制约算法前进的方向。

差分策略常用 DE/x(base)/y(number)/z(cross)表示，其中 x 为差分趋势， y 为差异向量的数量， z 为交叉类型， z 通常在二项式或指数交叉中选择。二项式交叉随机选择可能的交叉点，而指数交叉则在邻近的点中循环选择。研究[42]指出在处理离散问题时，两者的结果相似。目前常用的差分策略有很多种，但是理论上可归结为随机策略和最优策略两种，因此个体差异计算的差分方法可统一描述为：

$$v_i(t) = \lambda x_{best}(t) + (1 - \lambda)x_{r1}(t) + F \cdot \sum_{k=1}^y (x_{rk}(t) - x_{rk+1}(t)), 0 \leq \lambda \leq 1 \quad (3-1)$$

其中 $\lambda \in [0,1]$ 控制着差分的贪婪程度。例如当 $\lambda = 1$ 时，是 DE/best/y/z 策略，当 $\lambda = 0$ 时，是 DE/rand/y/z 策略，当 λ 介于 0 和 1 之间时，则是 DE/rand to best/y/z 策略。公式(3-1)中的规模因子 $F \in (0, \infty)$ ，控制着差异变量变异的步长的增长幅度，其取值的大小直接影响算法搜索的宽度和广度。此外，差异向量的数量 y 表示同时探索的个体方向数量。 y 越大，每代参与差分的个体就越多，其可探索的方向也就越多。设参与进化的种群大小为 S ，则每一代差别扰动的总数量^[106]为：

$$\binom{S}{2y} 2y! \approx \Phi(S^{2y}) \quad (3-2)$$

根据公式(3-1)，差分在二维向量空间的几何描述可由图 3-1 给出：





图 3-1 差分进化过程的几何空间演示

Fig 3-1 The processing of differential evolution in geometrical space

此外，DE 算法的优势主要在于优化连续参数的值。如果求解基于离散参数的组合优化问题，则需要某些方法将离散参数转换到连续空间，并用连续函数搜索离散问题的解空间。在求解 MUCMTA 问题时，我们基于任务代价与分配的对应关系，提出了一个合理的、利用映射和反射策略进行空间转换的方法。这个方法不仅提高了 DE 算法的性能，而且利用 MUCMTA 的任务属性来有效降低差分的随机误差。

因此，本章首先提出一种新颖的统一基因编码策略，将 UAV 与目标点的对应关系与其航程代价联系在一起，可以更全面的表示三种分配模型 $N=M$ ， $N>M$ 和 $N<M$ 中任务执行的关系；然后，利用飞行航程代价矩阵作为映射矩阵，通过一定的映射规则，将离散参数转换至连续空间，在连续空间中差分求得临时的差分结果；接下来，根据反射规则转换差分结果到分配关系空间，通过映射和反射转换得到合理的具有一定实际意义的 DE 子代个体；最后，结合协同适应度和各种约束条件，保持进化始终朝着 MUCMTA 最优的方向前进。此外，我们还用混合差分策略提高 DMDE 的效率。算法框架见图 3-2。



这种表示方式存在的问题是：很难将目标点与 UAV 数量不同的情形用统一的进化算法来处理，同时随机指定 UAV 与目标点关系，忽略了两者的航程代价关系，使搜索过程具有盲目性，必然降低了算法的搜索效率。为了统一、高效处理不同情况，根据分配模型的共同特点，可采用形式统一的基因编码方式描述不同模型。从之前的分析可以看出，三种模型的航程代价矩阵具有相似的形式，在代价矩阵中可查询 UAV 执行不同目标点对应的估计航程代价值。因此，在产生种群个体时，通过矩阵查询，将 UAV、执行目标和航程代价三个量组合在一起，做为一个基因位，可以有效的组成形式统一的种群个体。所以，结合三维估计航程代价矩阵，采用矩阵关系三元组：

$$g_s = (U_i, T_j, C(i, j)), \quad s = 1, 2, \dots, n \quad (3-3)$$

或巡游关系三元组:

$$g'_s = (T_j, T_{(j+1)}, T_c(j, (j+1))) \quad s = 1, 2, \dots, (m-n) \quad (3-4)$$

来表示差分进化的基因编码。其中 U_i 表示第 i 架 UAV, T_j 表示第 j 个目标, $C(i, j)$ 为从第 i 个 UAV 的起飞点到目标点 j 的航程代价, $T_c(j, (j+1))$ 为从第 j 个目标点(UAV 以该目标点作为执行下一个目标的起点)到第 $j+1$ 个目标点的航程代价。进化个体为一组满足全部目标分配任务的三元组基因集合, 如图 3-3 所示。




图 3-3 基于代价矩阵的统一基因编码

Fig 3-3 Uniform code based on cost matrix

图 3-3 中, 黑色实线区域表示 UAV 与目标点数量相等($N=M$)时的代价矩阵; 蓝色虚线区域表示 UAV 大于目标点数量($N>M$)时的代价矩阵; 红色间隔线区域表示 UAV 小于目标点数量($N<M$)时的代价矩阵。右侧为各情况下与其代价矩阵对应的进化个体的编码方式。

3.3.2 个体编码产生规则

虽然统一的编码策略具有相同的形式, 但是针对不同的分配模型, 其编码表示的意义并不相同, 因此生成规则也略有差别, 现描述如下:

规则 3.1: 当 $N=M$ 时, 要求生成进化个体基因序列中的 UAV 和目标点

一一对应, U_i 和 T_j 均不能有重复值。这是因为此时 UAV 和目标点是一一对应的, 每个基因表示第 U_i 架无人机执行第 T_j 个目标点, 其执行任务的估计航程代价为 $C(i,j)$ 。任务要求每个目标点至少被一架 UAV 执行, 每架 UAV 只能执行一个目标点, 因此在如图 3-4 所示。




图 3-4 $N=M$ 的进化基因个体表示

Fig 3-4 The gene code sequence of individuals when $N=M$

规则 3.2: 当 $N>M$ 时, 要求生成进化个体基因序列中的无人机 U_i 不能有重复值, T_j 可以有重复值, 且 T_j 必须满足最少出现一次。这是因为此时 UAV 和目标点是多对一的关系, 每个基因表示的含义与规则 1 相同。但此时多架 UAV 可以攻击相同的目标, 因此同一个目标可以重复对应多架 UAV, 此外, 为保证所有目标均被执行, 要求每个目标至少与一架 UAV 相对应 如图 3-5 所示。




图 3-5 $N>M$ 的进化基因个体表示

Fig 3-5 The gene code sequence of individuals when $N>M$

规则 3.3: 当 $N<M$ 时, 要求生成进化个体基因序列中的无人机 U_i 可以有重复值, 目标点 T_j 不能有重复值, 且无人机 U_i 必须满足最少出现一次。这是因为此时 UAV 和目标点是一对多的对应关系, 一架 UAV 可能要巡游多个不同的目标点才能完成全部作战任务, 而且该 UAV 执行这些目标的序列不是随意的, 因此某个基因与其他基因存在着潜在的联系, 个体中具有相同 UAV 的基因在一起组成一组巡游关系, 表示该 UAV 从一个目标点开始依次执行组内的其他目标点。此时一组基因在一起表示一个完整的含义, 即第 U_i 架无人机和一组目标点 $[T_j, \dots, T_k]$ 的对应关系, $C(i,j)$ 为无人机 U_i 执行第一个目

标 T_j 的估计航程代价值, $T_c(j,k)$ 为无人机 U_i 以上一个目标点 T_j 为新的起点, 到下一个目标点 T_k 继续执行任务的估计航程代价值, 其中 $[T_j, \dots, T_k]$ 的序列依据最短路径原则确定, 以保证巡游全部目标的航程代价之和最小。如图 3-6 所示。




图 3-6 $N < M$ 的进化基因个体表示

Fig 3-6 The gene code sequence of individuals when $N < M$

利用以上基因编码规则生成的进化个体形式, 可表示多种模型协同目标分配任务的备选解。用含义相似的三元组表示组成个体的基因, 从而将不同的分配模型统一在一致的种群空间中, 这样就可以用相同的进化算法框架进行处理, 避免了不同模型采用不同方法进行求解的困难, 并且能够有效求解复杂的多模型混合问题, 提高了求解算法的通用性; 同时, 在基因中存储了执行任务的估计航程代价值, 可以在差分进化过程中利用该信息指导搜索前进的方向, 提高分配计算的合理性。

3.4 基于 DMDE 的 MUAS 协同统一多目标分配

3.4.1 离散差分映射规则

多无人机协同目标分配问题的备选解是 UAVs 和目标点对应关系的整数离散序列对集合, 用经典的连续型实值 DE 算法无法直接求解该问题。如果仅对序列值差分的结果进行取整, 新个体中则可能会出现无效的重叠值、零值、负值和越界值, 这样产生的个体不能继续参与进化计算, 必然导致算法的失效。现有的方法如对个体中部分错误基因进行修正、或对差分实数值进行排序、以及利用相关位置进行索引等方法^[105]改进 DE 算法, 虽然都可以获得可行的新个体, 能够解决差分进化失效的问题, 但这些方法均是随机搜索的一种变体, 与 UAV 和目标点之间的实际物理意义无关, 因此很难获得高效的分配结果。由此可见, 若要用 DE 算法求解多模型分配问题, 必须对其进行改进, 将离散空间上的搜索过程映射到有物理意义的连续空间, 在连续

空间上执行差分操作搜索临时最优解，再采用合理的方法将结果反射回原来的离散空间，通过空间转换和映射策略实施有效的搜索。可见设定符合实际问题物理意义的映射方法是求解多无人机协同目标分配问题的关键。

在多机协同目标分配问题中，UAV 和目标点的对应关系在物理意义上与航程代价有紧密的联系，搜索的主要目标就是找到总航程代价最小的集合。因此，本章结合三维估计航程代价矩阵，用航程代价作为映射关系，将离散的 UAV 和目标点集合映射到连续的代价值空间，在其上搜索最优分配集合。设由有限整数序列对构成的 d 维离散向量空间为 $\{(k,i) \in Z^d \mid 0 < k \leq n, 0 < i \leq m, d = \max\{n, m\}\}$ ，航程代价值构成的连续向量空间为 R_c ，则空间映射函数为：

$$\phi: \{(U_i, T_j) \in Z^{n_d}\} \xrightarrow{C_{cost}} R_c^n \quad (3-5)$$

其中 ϕ 将估计航程代价矩阵 $\mathbf{c}_{cost}$ 作为空间映射的置换矩阵，用 $\mathbf{c}_{cost}$ 中的代价实值映射 UAV 与目标点的对应关系序列。计算时直接对映射的代价值集合进行差分交叉操作，获得新的临时代价值，映射后的差分操作是在连续空间中对代价值进行的，因此按标准的差分进化公式，可获得临时实数解如下：

$$C_j^{(iy)}(t) = \begin{cases} C_j^{(r_1)}(t) + F \cdot (C_j^{(r_2)}(t) - C_j^{(r_3)}(t)), & CR > rand[0,1] \\ C_j^{(i)}(t), & Otherwise \end{cases} \quad (3-6)$$

其中 $C_j^{(iy)}(t)$ 是差分获得的临时代价值，它体现了父代个体在距离上的差异， r_1, r_2, r_3 表示种群中执行差分操作的不同个体， F 是比例因子， CR 是交叉率。新生个体的协同适应度若优于先辈的个体，则用其替代先辈个体，使整体向更优方向移动。

因为差分后获得的临时代价值与航程代价矩阵中的航程值存在差异，并且其中可能出现越界值、零值和重复值，因此在将差分结果映射回离散整数序列对空间时，必须要对新个体中的基因进行反射匹配，以满足备选解的要求，获得可行的子代个体，其反射函数定义为：

$$\phi': R_c^n \xrightarrow{Match_{rules}(1,2,3)} \{(U_i, T_j) \in Z^{n_d}\} \quad (3-7)$$

其中 ϕ' 要按一定的映射规则对差分结果进行匹配，生成满足进化条件的新子代个体，保证进化能够有效进行。反射匹配的规则定义如下：

规则 3.4(最近邻匹配规则): 对差分后临时代价值集合中的每个合理

值，在航程代价矩阵中找到与其距离最近的值 $C(i,j)$ ，将其对应的序列关系对 $(U_i, T_j, C(i,j))$ 作为该位置上的新个体基因：

$$C'_{(i,j)} = C_{(i,j)} \mid \min\{|x_j^{(i)'}(t) - C_{(i,j)}|, 0 < i < N, 0 < j < M\} \quad (3-8)$$

规则 3.5(唯一匹配规则)：为保证符合不同模型 UAV 与目标点对应关系的唯一性，同时避免新的临时代价值重复映射到相同位置，匹配过程中要采取一定的策略对位置进行选择，不同的模型采用的策略不同，具体描述如下：

a) 当 $N=M$ 时，要求 UAV 与目标点一一对应且不能重复，因此按规则 1 找到对应的代价值并将其加入新个体基因后，在代价矩阵中删除该基因所在的行列，保证该 UAV 与目标点不再参与之后的匹配。

b) 当 $N>M$ 时，要求 UAVs 不能重复，但同一个目标点可以重复匹配给不同的 UAVs。因此，首先要保证每个目标至少被匹配一次，然后可以重复匹配 UAV 到相同的目标点；匹配过程中，按规则 1 找到对应的值并加入新个体基因后，删除该基因对应的行，以防止 UAV 重复。

c) 当 $N<M$ 时，要求目标点不能重复，而 UAV 可能巡游一组不同的目标点，因此，采用迭代替逐个匹配临时结果，首先在代价矩阵的上半部分进行匹配，保证所有的 UAV 最少匹配一个目标；然后删除目标点对应的列，并用该目标点在代价矩阵下半部分中对应的行替换当前 UAV 的行，保证替换后的代价行是 UAV 以当前目标点作为新的起点，继续执行下一个目标点任务的代价值，使最后匹配的基因满足巡游关系；最后，重复迭代执行这一过程，不断改变上半部分矩阵，直到全部匹配完成。

规则 3.6(无效变异匹配规则)：在按规则 1 和规则 2 匹配完合理的差分临时结果之后，剩下了无效的差分临时值和未匹配的矩阵。对这些无效的零值、负值、越界值，可利用局部随机变异的方法进行匹配，即对无效的值，依次随机匹配一个未被映射到新个体中的代价值作为变异后的新基因，最后按规则 2 修改矩阵，继续匹配其他无效的值，直到全部任务匹配完，映射矩阵为空为止。

在实际计算过程中，因为每次删除矩阵的操作会严重降低算法求解的效率，因此，可利用无限大值 Inf 重置要删除的行或列，使这些行列失去继续参与匹配的能力，这样操作既降低算法的代价，又保证算法能够有效进行。映射匹配操作如图 3-7 所示。




图 3-7 映射匹配过程原理

Fig 3-7 The schematic of match action

3.4.2 混合进化策略的 DMDE 算法

进化算法是一种随机搜索算法，算法性能的优劣主要受探索性和开发性两个方面的制约，探索性可以有效识别出问题空间中最优解的区域，开发性则能够加速优化收敛的速度^{[112][113]}。要改善 DE 算法的寻优性能，不仅要提高覆盖问题空间的探索性能，还要提高深化问题空间的开发性能，然而这两者是互相制约的两个方面，过度的探索性会导致算法无法接近最优解；过强的开发性则有可能导致算法陷入局部最优。所以，只有探索性和开发性两者均衡，才能够提升进化算法的整体性能，更好的进行问题的求解。

按单一进化策略搜索的 DE 算法只关注于优化的某个方面，如趋向于更好的探索性(*DE/rand/y/z*)或更快收敛的开发性(*DE/best/y/z*)，策略(*DE/rand to best/y/z*)虽然在两者之间有更好的平衡，但是随机和最优参数是固定的，因此优化的能力还是有限的。

为更好的平衡算法的探索 and 开发能力，本章采用动态变异率来调整算法搜索的平衡性。在进化搜索的初期，以随机搜索策略(*DE/rand/1/bin*)为主导，随着进化的深入，逐渐侧重于最优策略(*DE/best/2/bin*)，算法根据搜索的进程动态调整进化的策略，使探索性和开发性始终保持动态平衡，因此可以有效提高算法搜索的效率和能力。首先设动态交叉率 *CR* 为：

$$CR(x) = 1 - \left(\frac{\log(x)}{\log(S)} \right)^\theta, \quad x = 1, 2, \dots, S, \theta = 1, 2, \dots, n \quad (3-9)$$

其中, x 是当前进化代数, S 为进化的总代数, θ 为曲率变化指数, 交叉率 CR 随不同指数 θ 变化的曲线如图 3-8 所示。




图 3-8 交叉率变化曲线

Fig 3-8 The curve of crossover rate

从图 3-8 中, 可以看出 θ 决定了曲线的变化程度。合适的 θ 值能更好地平衡探索性和开发性。例如, 当 $\theta=3$ 时, 动态交叉率在搜索初期下降较快, 具有随机搜索的探索性的比重很快接近具有精细化搜索的开发性的比重。然后, 交叉率变化的速度越来越慢、越来越平缓, 开发性的比重逐渐大于探索性, 确保在搜索的最后阶段, 精细搜索趋于主导地位。

在混合策略和动态交叉率下产生新个体的过程, 如下式所示:

$$C_j^{(i)'}(t) = \begin{cases} C_j^{(r_1)}(t) + F \cdot (C_j^{(r_2)}(t) - C_j^{(r_3)}(t)), & CR(t) \geq rand[0,1] \\ C_j^{(best)}(t) + F \cdot (C_j^{(r_1)}(t) + C_j^{(r_2)}(t) - C_j^{(r_3)}(t) - C_j^{(r_4)}(t)), & CR(t) < rand[0,1] \end{cases} \quad (3-10)$$

$$F(t) = \begin{cases} 2CR(t), & CR(t) \geq rand[0,1] \\ (2 - CR(t)) / 2, & CR(t) < rand[0,1] \end{cases} \quad (3-11)$$

公式(3-10)显示, 当搜索处于开始阶段, CR 值较大, 交叉偏重于探索性能较强的策略($DE/rand/1/bin$), 然后两者的比例随着 CR 的变化而改变。在进化迭代到一定程度以后, 算法已经接近最优解的区域, 此时 CR 值接近最小值, 交叉偏重于开发性能比较强的策略($DE/best/2/bin$)进行局部寻优, 使算法更深

入的收敛到最优解。此外，公式(3-11)设定缩放因子 F 的取值也与 CR 的变化相关，使进化过程中差分比例因子也是动态改变的值。

此外，我们还利用代间变异率 $GMR(t)$ 取代原有的随机灭绝，以增加搜索覆盖范围的可控性。在最优解保留时，因为最优解反映的当前种群信息量太低，极有可能被灭绝之后若干代的发展灭绝彻底消亡，这就使之前的搜索变成无效过程，导致搜索信息的不连贯和资源的浪费。因此在世代间灭绝操作时，适当降低环境压力指标，选择保存当前种群中一定数量的较优个体，而将其他的普通个体全部进行重置，改善了种群突变带来的毁灭性影响。设环境压力是一个 $[0 \sim 0.3]$ 之间的随机值，那么在灭绝时，对个体适应度进行归一化，抛弃大于环境压力的个体，保留在环境压力范围之内的较优个体。同时，代间变异操作可以有效改变先前种群的搜索趋势，提高种群多样性和随机搜索的覆盖范围。将代间变异率与动态交叉率相对应，可设代间变异率 GMR 为：

$$GMR(t) = \begin{cases} 0, & CR(t) \geq \delta \\ 1 - CR(t), & CR(t) < \delta \end{cases} \quad (3-12)$$

公式(3-12)中 δ 为产生灭绝的动态变异率临界值，当动态变异率小于该值时才产生世代间的灭绝操作，以避免搜索初期发生的混乱。当 CR 小于临界值以后， GMR 是随着 CR 的降低逐渐增加的，使后期的搜索更容易跳出先前搜索趋向的局部最优范围。

3.5 DMDE 算法分析和控制参数选择

3.5.1 DMDE 算法理论和性能分析

DMDE 算法基于统一形式的基因三元组，将 UAV 与目标的关系映射到代价空间，并在此代价空间进行迭代寻优。因此为说明该算法的有效性，可证明利用代价值差分优于其他基于序列差分的方法。首先给出代价距离和任务近邻关系的定义：

定义 3.1： 根据基因表示的三元组，空间某任务 (U_i, T_j) 对应的航程代价为 $C(i, j)$ ，则 $\Delta C_k = (C(i_1, j_1) - C(i_2, j_2))$ 表示任务 (U_{i1}, T_{j1}) 与任务 (U_{i2}, T_{j2}) 之间的代价距离。

代价距离 $\|\Delta C_k\|$ 的大小可以客观衡量任务选择的优劣，当代价距离较小时，同类 UAV 选择执行 (U_{i1}, T_{j1}) 或 (U_{i2}, T_{j2}) 这两个任务所需的资源消耗、航行能力以及约束条件更相似，因此比代价距离大的任务更接近较优的备选解。

定义 3.2： 代价距离可以用来表示任务选择的近邻关系，若代价距离

$\|C(i1,j1)-C(i2,j2)\|>\|C(i1,j1)-C(i3,j3)\|$, 则任务 (U_{i1},T_{j1}) 与任务 (U_{i3},T_{j3}) 的执行代价更相似, 任务 $i1$ 与 $i3$ 为任务近邻关系。

因此, 个体中每一个基因上的差分操作都可表示为:

$$C_{vi}(t) = C_{r1}(t) + F \cdot \sum_{k=1}^y \Delta C_k(t) \quad (3-13)$$

则任务选择是与差分结果 $C_{vi}(t)$ 最近邻的任务:

$$C'_{(i,j)}(t) = C_{(i,j)}(t) | \min\{\|C_{vi}(t) - C_{(i,j)}(t)\|\} \quad (3-14)$$

由此可见, 差分选择的结果是对 $C_{r1}(t)$ 进行差分扰动后得到的最近邻的任务。在理想情况下, 假设个体每一基因位的代价值差分都能匹配到现有的近邻任务上, 忽略时间代价不计, 则其适应度函数为:

$$\begin{aligned} f(t) &= (C'_1(t) + C'_2(t) + \dots + C'_n(t)) + \delta \sum_{l=1}^L c'_l \\ &= \sum_{k=1}^n \min\{\|C_{vk}(t) - C_{(i,j)}(t)\|\} + \delta \sum_{l=1}^L c'_l \\ &= \min \sum_{i=1}^m \sum_{j=1}^n C_{(i,j)}(t) + \delta \sum_{l=1}^L c'_l \end{aligned} \quad (3-15)$$

其中 δ 是约束惩罚的惩罚系数, 从式中可以看出, 基于代价距离差分的适应度能够获得最小代价组合, 因此必然优于其他随机选择方法所产生的个体适应度。

此外, DE 算法是一种随机搜索算法, 其基本概念的数学模型可由马尔科夫链模型进行定义, 文献[115]给出了一般 DE 进化的有限齐次马尔科夫模型的证明。在此基础上, 我们改进的 DMDE 进化模型增加了映射转换操作的转移概率和混合进化策略的动态交叉转移概率, 因此, 可在新增的状态转移概率下考察 DMDE 算法是否依然是有限齐次马尔科夫模型。

定理 3.1: DMDE 算法迭代中, 个体 L_{ij} 的状态由 $x(t)$ 转移到 $x(t+1)$ 的概率为 $P(x(t) \rightarrow x(t+1)) = P(C_1 \rightarrow C_v) P(C_v \rightarrow C_2) P_{select}$ 。

其中差分转移概率为:

$$P(C_1 \rightarrow C_v) = \frac{1}{\left| x_{r1} + F \sum_{k=1}^y (x_{rk} - x_{rk+1}) \right|} \quad (3-16)$$

映射转移概率为:

$$P(C_v \rightarrow C_2) = \frac{1}{N_p} \quad (3-17)$$

选择转移概率为：

$$P_{select} = \begin{cases} 1, & f(C_v) \geq f(C_{r1}) \\ 0, & f(C_v) < f(C_{r1}) \end{cases} \quad (3-18)$$

证明：因为差分进化过程中，差分、交叉、映射和选择操作均相互独立，且从父代选择的 $2y$ 个样本也相互独立，因此根据差分操作：

$$v_i(t) = x_{r1}(t) + F \cdot \sum_{k=1}^y (x_{rk}(t) - x_{rk+1}(t))$$

可求得差分转移概率如公式(3-16)所示；根

据近邻关系映射 $C'_{(i,j)}(t) = \min\{\|C_{vi}(t) - C_{(i,j)}(t)\|\}$ ，要做至多 N_p 次选择，其中 N_p 为种群个体数量，可求得映射转移概率如公式(3-17)所示；最后选择转移概率为历史最佳位置的选择概率。此外，根据动态变异率公式(3-9)和交叉操作公式(3-10)，可以看出每次迭代交叉的结果必然为某一种策略的转移值，因此转移概率始终为 $P_{CR(t)} = (1 - CR(t) + CR(t)) = 1$ ，即在状态转移过程中不用考虑交叉转移概率。

综上所述，在 DMDE 算法中， L_{ij} 的状态由 $x(t)$ 转移到 $x(t+1)$ 的概率为 $P(x(t) \rightarrow x(t+1)) = P(C_1 \rightarrow C_v) P(C_v \rightarrow C_2) P_{select}$ ，证毕。

根据定理 3.1 和文献[115]，差分进化种群中的个体相互独立的，因此这些个体的状态转移也是相互独立的事件。因此，设差分进化当前种群的状态 $S(t) = \{x_1(t), x_2(t), \dots, x_n(t)\}$ ，则从 $t-1$ 时刻的种群状态 $S(t-1)$ 到 t 时刻的种群状态 $S(t)$ 的转移概率为：

$$P(S(t-1) \rightarrow S(t)) = \prod_{i=1}^{N_p} P(x_i(t-1) \rightarrow x_i(t)) \quad (3-19)$$

由以上分析可知，DMDE 算法虽然加入了代价空间映射和动态变异率，但其在离散种群空间上仍然具有马尔科夫特性，且是有限齐次的马尔科夫链。因此该算法没有改变 DE 进化的有效性。

3.5.2 DMDE 算法参数选择

由文献[115]可知，DE 算法在全局无法保证收敛性，因此要保证算法优化搜索具有较强的全局和局部搜索能力，就要采用有效的参数控制策略对算法进行控制。然而，目前并没有定性的分析可以证明有效的参数选择方法，大多数参数的选择来自于具体的工程实践。本文结合实践经验就 DMDE 的参数

的选择做以下分析：

在多目标协同分配的问题中，影响 DMDE 算法的参数主要有以下三类：

1) 种群控制参数：包括种群大小 N_p 和迭代次数 S 。其中种群大小对算法的探索性有着直接影响，种群越大，差分方向就越多，则可以探索更多的位置。但是，算法的复杂度也随着种群大小的增加而增加。从差分角度分析种群的大小，假设有 N_v 个差分操作，则最少需要 $2N_v$ 个个体，因此个体的下界为： $N_p > 2N_v + 1$ 。此外，为了控制种群过度膨胀，通常设定种群上界不超过 $10N_v$ ，即： $10N_v > N_p > 2N_v + 1$ 。迭代次数 S 可以根据终止条件自行演化，也可在保证充分收敛的情况下，根据实际人为设定。通常 S 不大于 5000 代。

2) 差分参数：包括动态交叉率的指数 θ 和规模因子 F 。根据图 3-7，可以看出取不同 θ 值的变化曲线，在实际应用中，当 $\theta=3$ 时，动态交叉率的变化情况较好；规模因子 $F \in (0, \infty)$ ，控制着差异变量 $(x_{rk}(t) - x_{rk+1}(t))$ 的增大， F 越小，变异的尺度越小，算法收敛时间就会越长；而 F 值过大，则有可能越过最优位置。因此实际操作中常取 $0 < F < 2$ ，以保证算法既有较快的收敛速度，又不会越过可能的最优位置。本文为了更好的调整规模因子，采用与动态交叉率相关的动态规模因子来进行差分，如公式(3-11)所示，可以更好的优化规模因子，以保证差异结果能够覆盖更多位置。

3) 适应度参数：DMDE 算法的适应度函数与公式(2-13)中的目标函数相同，因此，除了航程代价之外，还有总航行时间和约束惩罚项。因此存在缩放因子 α 和 β ，根据多次实验发现，对 $N \geq M$ 的情况和 $N < M$ 的情况设定不同的缩放因子值，可以获得更好的效果，这是因为无人机执行多个目标时，其巡游关系与单目标任务执行略有不同，通常设定 $\alpha = 2.5$ ， $\beta = 1.5(N \geq M)$ ，和 $\alpha = 1.5$ ， $\beta = 1(N < M)$ 。

综上所述，DMDE 算法流程如算法 3.1 所示。

3.6 实验结果和分析

为了验证改进后的离散差分进化算法处理 MUAS 统一目标分配的有效性，本章在酷睿 i5 双核 3.20GHz、8GB 内存的 PC 机上，利用 Matlab2011b 进行了多组仿真实验。并预先设定三维 DEM 仿真地形、随机的雷达威胁坐标、以及不同数量的 UAVs 和目标点等。

算法3.1 基于离散映射差分进化的协同目标分配算法
Alg.3.1 A cooperative targets assignment algorithm based on
discrete mapping differential evolution

输入: 群体规模 P , 个体规模 D , 迭代次数 S , 代价矩阵 MC , 变异率 CR , 约束条件 $C(l)$
输出: 适应度最优的解 Ind_{best}

```

01:   For  $i=1$  to  $P$    do                                     /*初始化种群*/
02:       For  $j=1$  to  $D$    do

03:            $Ind_{i,j} = \begin{cases} U_j^i = rand(1,n) \\ T_j^i = rand(1,m) \\ C_{(u,t)} = C_{cost}(U_j^i, T_j^i) \end{cases};$ 

04:       End for
05:       根据适应度  $f(Ind_{i,j})$  评估个体优劣;
06:   End for
07:   For  $gen=1$  to  $S$    do                                     /*DMDE进化*/
08:       For  $i=1$  to  $P$    do
09:           随机产生四个不一样的数 $[r1,r2,r3,r4] \in \{1,2,\dots,P\}$ ;
10:           按公式(3-9)计算动态交叉率 $CR$ ;
11:           For  $j=1$  to  $D$    do
12:               If  $rand\ CR \geq rand_j[0,1]$    then           /*映射到连续空间*/
13:                    $C_j^i = C_j^{r1} + F \cdot (C_j^{r2} - C_j^{r3});$ 
14:               Else  $rand_j(0,1) > CR$ ;
15:                    $C_j^i = C_j^{best} + (1-F) \cdot (C_j^{r1} + C_j^{r2} - C_j^{r3} - C_j^{r4});$ 
16:               End if
17:               If  $C_j^{(ij)} = C_j^i \mid \min\{|x_j^{(ij)}(t) - C_j^i|\}$  存在   then   /*反映射回离散空间*/
18:                   按规则1:  $[U_{j+1}^i, T_{j+1}^i, C_{j+1}^i] = MC(U_j^i, T_j^i, C_j^{(ij)});$ 
19:                   按规则2处理代价矩阵 $MC$ ,  $C_{cost}(N_{row}) = Inf$ ,  $C_{cost}(N_{col}) = Inf$ , 获得 $MC'$ ;
20:               Else
21:                   将无效的临时解存入待匹配数组 $K$ ;
22:               End If
23:           End for
24:           For  $k=1$  to  $K$    do
25:               按规则3随机匹配 $S$ 到 $MC'$ ;
26:           End for
27:           获得可行的差分解  $Ind(x')$ ;
28:           If  $f(Ind(x')) < f(Ind_{best})$    then               /*执行选择*/
29:                $Ind_{best} = Ind(x')$ ;  $f(Ind_{best}) = f(Ind(x'))$ ;
30:           End if
31:       End for
32:   End for

```

3.6.1 算法的有效性和适应性

为验证 DMDE 算法能够正确有效的搜索到全局最优解，我们设定了两个尺度的实验，实验 3.1 基于数量较少的 UAVs 和目标点，主要验证算法的可行性。实验 3.2 设定较大规模的 UAVs 和目标点，用以证明算法能够有效处

理复杂环境的问题。实数据设定形式为 UAV 速度矩阵 $\mathbf{V} = \begin{bmatrix} v_{min}^1 & v_{max}^1 \\ \vdots & \vdots \\ v_{min}^n & v_{max}^n \end{bmatrix}$ ；UAV

最大协同航程约束集合 $D = [d_{max}^1, \dots, d_{max}^n]$ ；UAV 最大协同时间约束集合

$T = \left[\frac{d_{max}^1}{v_{min}^1}, \dots, \frac{d_{max}^n}{v_{min}^n} \right]$ ；目标点的权重集合 $W = [w_1, \dots, w_n]$ ；协同时序约束矩阵

$\mathbf{T}_{sort} = \begin{bmatrix} t(i_1) & t(j_1) \\ \vdots & \vdots \\ t(i_l) & t(j_l) \end{bmatrix}, i, j \in \{1, \dots, m\}, l < m$ ；同时到达目标点约束集合

$T_s = [k_1, k_2, \dots, k_l]$ ；最大初始等待时间集合 $T_{wait} = [t_{wait}^1, t_{wait}^2, \dots, t_{wait}^k]$ ；时窗约束集合 $T_{win} = [t_{start}, t_{end}]$ 。实验 3.1 的初始数据见表 3-1。此外，目标函数中的缩放因子设定为 $\alpha = 2.5$ ， $\beta = 1.5(N \geq M)$ ，和 $\alpha = 1.5$ ， $\beta = 1(N < M)$ 。动态交叉率 CR 采用公式(3-14)进行计算，并设定指数 $\theta = 3$ 。在两组实验中其他的进化参数见表 3-2。其中“Pop”表示种群中个体的数量，“Gen”是进化迭代的代数，“Num”是实验重复的次数。

两组实验结果的统计数据在表 3-3 中列出。“最优代价”是多组实验中最优的总航程代价，“约束违背”表示多机协同时违反约束条件的惩罚效果，它是最优解中约束违背量总和占最优代价的百分比，“优解”表示陷入局部最优的次数和当前优于平均代价的优解次数，它是获得最优解的实验次数占实验总次数的百分比。“平均代价”和“最优代价”都是综合了优化目标和各种约束违背量的适应度分值，因此是无单位量纲。

从表 3-3 中，可以得到两个结论：1、改进的 DMDE 算法能够处理各种 MUCMTA 模型并得到合理的解；2、算法可以有效处理大尺度的 MUCMTA 问题。

对于第二组实验 3.2，尽管大尺度实验因增加了复杂性，降低了问题求解的效率，DMDE 算法还是可以在有效的时间内搜索到优解。而实验 3.1 和实验 3.2 的平均运行时间都很小，且在同一量级，由此说明统一的 DMDE 算法

表 3-1 实验 3.1 的初始数据
Tab 3-1 The initial data of experiment 3-1

模型	参数	1	2	3	4	5	6	7	8	9	10
N=M	U_{pos}	[78,20,15]	[93,31,12]	[31,20,13]	[112,32,15]	[134,26,17]	[45,52,12]	[36,63,13]	[67,34,16]	[21,85,15]	[2,62,13]
	P_{pos}	[70,181,12]	[15,133,13]	[19,151,12]	[160,192,13]	[101,120,23]	[160,113,12]	[82,101,11]	[173,140,12]	[182,65,14]	[28,156,12]
	$Radar$	[120,70,4,23][110,140,4,26][52,103,5,30]									
	$V(km/m)$	[1.2,1.8]	[1.2,2.4]	[1.8,3.0]	[1.2,1.8]	[1.8,2.4]	[1.8,3.0]	[1.2,2.4]	[1.8,3.0]	[1.2,2.4]	[1.8,3.0]
	$D(km)$	300	400	500	300	450	500	400	500	400	500
	W	1.0	0.4	0.5	0.7	0.9	1.0	0.6	0.8	1.0	1.0
	T_{sort}	[3,4]	[5,2]	[6,8]	[7,4]						
	U_{pos}	[78,20,15]	[93,31,12]	[31,20,13]	[112,32,15]	[134,26,17]	[45,52,12]	[36,63,13]	[67,34,16]	[21,85,15]	[32,62,13]
	P_{pos}	[70,181,12]	[15,133,13]	[19,151,12]	[160,192,13]						
	$Radar$	[120,70,4,23][110,140,4,26][52,103,5,30]									
N>M	$V(km/m)$	[1.2,1.8]	[1.2,2.4]	[1.8,3.0]	[1.2,2.4]	[1.8,2.4]	[1.8,3.0]	[1.2,1.8]	[1.2,2.4]	[1.8,3.0]	[1.2,2.4]
	$D(km)$	300	400	500	400	450	500	300	400	500	400
	W	0.8	1.0	0.6	0.9						
	T_{sort}	[2,3]	[1,4]	[1,2]							
	$T_{wait}(m)$	300	400	200	900	500	700	300	800	900	600
	U_{pos}	[78,20,15]	[93,31,12]	[31,20,13]	[112,32,15]						
	P_{pos}	[70,131,12]	[15,103,13]	[19,151,12]	[160,192,13]	[101,120,23]	[160,113,12]	[82,101,11]	[173,140,12]	[182,65,14]	[45,176,12]
	$Radar$	[120,70,4,23][110,140,4,26][52,103,5,30]									
	$V(km/m)$	[1.2,1.8]	[1.8,3.0]	[1.2,2.4]	[1.8,3.0]						
	$D(km)$	300	500	400	500						
N<M	W	1.0	0.8	0.6	0.7	0.9	0.8	1.0	0.7	1.0	0.8
	T_{sort}	[3,4]	[5,2]	[6,8]	[7,4]						
	$T_{win}(m)$	[100 600]									

表 3-2 两组实验进化参数设定
Tab 3-2 The evolutionary parameter of experiment 3.1 and 3.2

模型	Exp3.1					Exp3.2				
	UAV	Target	Pop	Gen	Num	UAV	Target	Pop	Gen	Num
N=M	10	10	50	1000	20	50	50	50	1000	10
N>M	10	4	50	1000	20	50	15	50	1000	10
N<M	4	10	50	1000	20	15	50	50	1000	10

表 3-3 两组实验分配结果的统计数据
Tab 3-3 The statistics results of experiment 3.1 and 3.2

实验	模型	平均时间(秒)	平均代价	最优代价	约束违背	优解
Exp3.1	N=M	28.67	3879.50	3867.90	7.73%	60%
	N>M	40.90	4963.80	4948.70	13.30%	60%
	N<M	50.18	2108.50	2108.30	9.40%	90%
Exp3.2	N=M	92.51	25589.00	25183.50	8.36%	50%
	N>M	81.83	33164.00	32284.30	7.10%	60%
	N<M	158.71	17843.30	16853.00	6.26%	80%

对各种分配模型都很高效，且适合求解大尺度的问题。此外，平均总代价非常接近最优代价，表明算法搜索的结果接近全局最优解。同时，较小的协同违背率证明解的协同能力较强，违背协同约束的机会较小。另外，较高的优解率也说明实验发现最优解的可能性较大。

为了直接表示分配的结果，表 3-4 展示了实验 3.1 中各种模型最优分配的结果，图 3-9 显示了在包括多个雷达威胁和多约束条件的复杂三维环境中的仿真结果。在表 3-4 中，“U”指 UAV，“T”指目标点，值为无人机和目标点对应的飞行航程代价。

表 3-4 Exp3.1 的分配结果
Tab 3-4 The assignment results of experiment 3.1

模型	参数	分配结果									
N=M	UAV	U(1)	U(2)	U(3)	U(4)	U(5)	U(6)	U(7)	U(8)	U(9)	U(10)
	Target	T(7)	T(5)	T(4)	T(9)	T(6)	T(8)	T(3)	T(10)	T(2)	T(1)
	Cost	458.1	276.2	574.7	137.8	143.8	391.7	307.8	482.0	124.3	447.7
N>M	UAV	U(1)	U(2)	U(3)	U(4)	U(5)	U(6)	U(7)	U(8)	U(9)	U(10)
	Target	T(1)	T(4)	T(3)	T(3)	T(2)	T(3)	T(3)	T(3)	T(2)	T(3)
	Cost	642.9	564.3	448.6	404.5	388.4	330.2	307.8	521.4	124.3	290.6
N<M	UAV	U(1)	U(2)	U(2)	U(3)	U(3)	U(3)	U(4)	U(4)	U(4)	U(4)
	Target	T(7)	T(5)	T(1)	T(2)	T(3)	T(10)	T(9)	T(6)	T(8)	T(4)
	Cost	458.1	276.2	164.2	185.0	142.2	201.7	137.8	61.5	39.0	87.8




图 3-9 三维环境中实验 3-1 的仿真结果

Fig 3-9 Simulation results of Exp3-1 in 3D simulation battlefield environment

在图 3-9 中，黄色的圆圈表示无人机起始点，黄色的星形表示目标位置。蓝色线代表垂直切面与地形的交线，红色的线表示无人机和目标的分配关系，它的长度就是无人机和目标之间的估计飞行航程代价。

从图 3-9 中，我们可以看出 DMDE 算法能在多雷达区域和目标点随机分布的三维环境中，有效处理不同模型的分配问题。此外，当雷达在战场分布不是很密集的情况下，估计航程代价更接近于真实情况，因此能够为下一阶段的航迹规划提供非常重要的参考依据。

3.6.2 DMDE 算法的性能

实验 3.1 中三种模型的收敛曲线和统计平均收敛曲线由图 3-10 给出。




图 3-10 实验 3.1 分配结果的单条和平均收敛曲线

Fig 3-10 The single convergence and average convergence curve by Exp3.1

由此，我们可以从以下三个方面分析 DMDE 算法的趋势：首先，图 3-10 中蓝色的线表示单次实验的收敛曲线，其中显示出进化迭代中的最优点。红色的线显示了多次实验统计的平均收敛曲线。不同模型的曲线具有相似的收敛趋势。所有的实验都能在 150 代左右收敛到最优解的附近，表明在搜索的初期收敛速度较快。因此 DMDE 算法有较好的收敛性能。

其次，图 3-10 中红色圆圈表示离散差分操作获得的当前种群最优解，蓝色星形表示代间变异随机获得的当前种群最优解。可以看出代间变异不仅增加了种群的多样性，还能够找到一些随机的最优位置。但是离散差分在搜索过程中起主导作用，另外，DMDE 算法利用有物理意义的映射规则，可以引导搜索快速向着全局最优前进。同时，混合策略降低了随机搜索的尺度，较大幅度提高算法的性能。

最后，图 3-10 还表明搜索执行到一半以后仍然有收敛过程，从而证明动态交叉率、代间变异和混合策略的共同作用，可以有效避免陷入局部最优，保证探测性和开发性的平衡。

另外，我们还比较了不同差分交叉策略的搜索能力。平均收敛曲线的比较见图 3-11。




图 3-11 不同差分交叉策略分配结果的平均收敛曲线

Fig 3-11 Average convergence curve of assignment result by different crossover strategies

从图 3-11 可以看出混合策略比单一的策略 ($DE/rand/1/bin$) 或者 ($DE/best/2/bin$) 更好。同时，如果采用 ($DE/rand/2$) 和 ($DE/best/1$) 策略，其结果和收敛曲线与之前非常相似。

3.6.3 DMDE 与同类目标分配算法的比较

我们将改进后的算法与 CMTAP-GA 算法^[65]、Sort-DE 算法^[105]和 PMX-DE^[105]算法进行了比较。实验采用相同的进化参数、种群规模、迭代次数。结果如表 3-5 所示。在表 3-5 中，变量 CR 是交叉率，变量 MR 是变异率，变量 GMR 为 DE 的代间变异率。基于统计数据平均收敛曲线见图 3-12。从表 3-5 和图 3-12 中可以看出，DMDE 算法比其他算法收敛到的最优解代价最小，收敛的速度最快，且执行时间最短。此外，尽管其他三种算法都能收敛接近最优解，但是它们需要更多的执行时间，因此比 DMDE 效率要差。

表 3-5 DMDE 和其他算法比较表
Tab 3-5 The comparison of DMDE and other algorithm

Model	Method	Num	Pop	Gen	Num	CR	MR	GMR	Best cost	Avg cost	Avg time(s)
$N=M$	DMDE	$N=M=10$	30	1000	10	CR	null	1-CR	3867.90	3890.20	17.48
	PMX-DE	$N=M=10$	30	1000	10	0.9	null	0.3	3869.80	3902.80	77.25
	Sort-DE	$N=M=10$	30	1000	10	0.9	null	0.3	3869.80	3898.60	38.93
	CMTAP-GA	$N=M=10$	30	1000	10	0.9	0.3	null	3892.00	3916.60	91.60
$N>M$	DMDE	$N=10 M=4$	30	1000	10	CR	null	1-CR	4954.20	4991.30	29.19
	PMX-DE	$N=10 M=4$	30	1000	10	0.9	null	0.3	4993.10	5012.50	184.63
	Sort-DE	$N=10 M=4$	30	1000	10	0.9	null	0.3	4993.10	5005.90	68.90
	CMTAP-GA	$N=10 M=4$	30	1000	10	0.9	0.3	null	4993.10	5031.10	194.75
$N<M$	DMDE	$N=4 M=10$	30	1000	10	CR	null	1-CR	2108.30	2108.50	45.08
	PMX-DE	$N=4 M=10$	30	1000	10	0.9	null	0.3	2274.10	2303.30	478.48
	Sort-DE	$N=4 M=10$	30	1000	10	0.9	null	0.3	2258.00	2297.00	471.13
	CMTAP-GA	$N=4 M=10$	30	1000	10	0.9	0.3	null	2258.00	2285.60	549.68




图 3-12 不同算法分配结果的平均收敛曲线

Fig 3-12 Average convergence curve of assignment result by different algorithm

从时间复杂度上进行分析，设 n, m 为个体基因的尺度(无人机与目标个数)； d, l 为差分进化的尺度(种群大小和迭代次数)。因为改进后的算法时间复杂度主要受初始化操作 $(n \cdot m + m)$ 、进化操作 $(d \cdot l)$ 、变异操作 $(n \cdot m + m) \cdot l$ 、适应度与约束计算 $(6n)$ 和反映射匹配操作 $(m \cdot d \cdot l)$ 几个部分影响，则算法总的执行次数为：

$$\begin{aligned}
 f(n) &= (n \cdot m + m) + (d \cdot l) + (n \cdot m + m) \cdot l + 6n + (m \cdot d \cdot l) \\
 &= 2n^3 + 3n^2 + 2n
 \end{aligned} \tag{3-20}$$

则算法性能损耗主要来源于进化过程中的反映射匹配操作和变异操作，差分进化因为是对代价值的直接计算，因此没有降低算法整体的效率，算法的时间复杂度为 $O(n^3)$ 。

相反，CMTAP-GA 和 PMX-DE 对离散序列的排序、交叉等操作均在每个

进化个体中完成，因此进化操作的执行次数主要为 $(d \cdot l \cdot (n \cdot m))$ ，则可以看出算法在进化操作过程中要有更多的性能损耗，算法的最坏时间复杂度为 $O(n^4)$ 。而 Sort-DE 的差分操作较其他两种方法简单，因此与 DMDE 有相似的执行时间，其时间复杂度为 $O(n^3)$ 。

由此可见，本章改进后的算法比其他算法具有更好的效果。此外，其他几种算法仍然是随机搜索的变体，过分依赖盲目的随机搜索不但导致算法执行效率底下，而且不适合大种群进化，加大种群规模会导致算法性能快速下降；而本章的 DMDE 差分映射方法，在一定程度上不受随机搜索的制约，可以有效适应大种群进化。

3.7 本章小结

为高效求解三维环境下的 MUAS 协同目标分配问题，本章提出了一种基于统一分配模型的协同多目标分配方法。首先，基于 UAVs、目标点序列和它们对应的航程代价，提出了一种统一的基因编码策略，该编码策略在一致的框架下处理各种目标分配模型，并将航程代价加入基因编码中，方便了从离散空间到连续空间的转换。然后，提出了适用于 DE 算法的映射和反映射规则，以解决离散的组合优化问题。改进的算法将无人机和目标对应的离散空间转换为连续的飞行航程代价空间，并用代价值进行差分操作。接下来，为了获得合理的子代个体，又根据反映射规则将差分操作的临时结果转换回无人机和目标的对应关系空间。在此方法中，采用距离信息指导搜索的方向，易于获取实际问题的最优解。最后，在进化过程中引入动态交叉率和混合进化策略，以平衡算法的开发性和探测性；同时，扩展了代间变异机制，提高了搜索种群的覆盖范围，确保算法能够有效跳出局部最优的陷阱。理论分析和实验结果验证了该算法优于同类方法，能够快速获得可行的最优解。

第 4 章 基于空间模糊表示的多机协同航迹规划方法

4.1 引言

多机协同航迹规划是 MUAS 任务规划的重要环节,是实现无人机自主飞行与任务执行的重要阶段。协同航迹规划问题是指在已知、部分已知或未知信息的环境中,预先规划出从各个 UAV 起始点到对应目标点,可以绕过途中各种威胁区和障碍物,安全、可靠、相互无碰撞,且同时满足 UAV 自身约束条件和协同约束限制的多条可行飞行航迹。该问题是一个复杂的 NP 完全问题,因此,求解难度大,是任务规划系统研究的难点之一。

在三维空间进行多机协同航迹规划时,要采用有效的空间约减方法降低三维空间的复杂度,才能使规划得以顺利进行。通常在三维栅格上进行航迹规划,能够较快处理三维规划的问题。然而,三维栅格上各个栅格点的信息量不足,是导致计算量增加的主要原因。实际上,在空间中不同位置的点,其反映规划问题的关键程度是不同的,因此考虑三维空间中栅格点的表示问题,是优化航迹规划的重要前提。

当前在 UAV 航迹规划的基础上,针对多机协同航迹规划的研究很多,但是仍有一些难题亟待处理,尤其是三维环境下的多机协同航迹规划问题,求解条件复杂、约束众多、目前研究仍然较少,其难点主要在于:

1) 与二维平面相比,三维空间结构表示更为复杂,要处理的信息量大,选择航迹关键点较为困难,因此,如何根据实际的任务和环境信息,对空间结构的表示建模,赋予空间某个点更多的与协同规划任务直接相关的信息,是可以优化航迹规划的重要方法。因此,如何选择空间结构的表示方法和有效约减空间是多机协同规划的难点。目前,航迹规划中常用的启发式算法和图搜索算法在三维空间的航迹规划上效果较差。智能优化算法虽然能有效进行三维空间中的搜索,但是规划空间的复杂性同样会严重降低算法搜索的效率,因此需要合理的空间表示方法来约减搜索空间,降低问题求解的复杂性。

2) 现有协同航迹的表示多基于空间栅格上关键路径点的连线,存在栅格覆盖范围有限、栅格点与点之间没有区别、栅格点与协同无关等不利于优化航迹搜索的重要问题,寻找航迹关键路径点时多基于随机搜索,利用大量的

循环迭代寻找优化路径，不但效率较低，且易于陷入局部最优。因此如何改进空间结构表示、探索栅格以外的领域知识，并收集搜索过程中的各种有效信息，使航迹关键路径点的寻优始终向着全局优化的方向发展，是航迹规划问题求解的难点。

3) 为了保证规划好的航迹符合无人机的机动条件，具有安全可飞性，还要解决航迹的平滑问题。在空间约减的基础上，获得的航迹通常是一组关键路径点的集合，这些路径点的连线会产生较多的折角和拐点，不适合无人机的飞行，需要采用平滑的方法对航迹进行最终的处理，但是平滑的过程可能带来新的问题，如平滑结果陷入威胁区、平滑导致协同失败等。因此如何保证平滑的航迹能够安全可飞是最终航迹是否可行的难点问题之一。

为解决以上问题，首先提出一种三维空间模糊表示方法，利用空间点的模糊信息表示其被关注的程度，以优选关键路径点；接着利用文化算法对规划问题进行建模，将空间点的模糊信息、历史信息和协同信息组合成算法的信念集，用以剪枝搜索的三维环境空间，为之后的进化操作提供领域知识；在算法的种群集上，则利用基于关键路径点的多目标差分进化算法(Multi-objective differential evolution, MODE)规划协同航迹，在求解的同时探索新的未知空间，并用未知空间的知识丰富原有信念集。此外，算法还保证了多条航迹既符合自身的约束条件，又符合复杂的协同约束条件，使规划的航迹组是多机协同的 *Pareto* 占优解。

4.2 基于任务属性的空间模糊表示

4.2.1 空间点的模糊集表示

模糊集合(Fuzzy Set)是将二值确定关系转换为连续化不确定描述的方法，它用隶属度函数评价某元素属于其所在集合的确定性程度。模糊集合扩充了集合中元素归属的程度信息，因此是从不完全数据中提取有价值信息的有效方法^{[116][117]}。根据文献[43]，其定义如下：

定义 4.1： 设 $x \in X$ 是论域 X 上的一个特定元素，则在 X 上的一个映射 $\mu: X \rightarrow [0,1]$ 可以确定论域 X 的一个模糊子集 A 。该映射 μ 即是模糊集 A 的隶属度函数。对于所有的 $x \in X$ ， $\mu_A(x)$ 表示 x 属于模糊集 A 的确定性。模糊集 A 一般可表示为集合形式：

$$A = \{\mu_A(x_i) / x_i \mid x_i \in X, i = 1, 2, \dots, n\} \quad (4-1)$$

或和形式：

$$A = \mu_A(x_1)/x_1 + \mu_A(x_2)/x_2 + \cdots + \mu_A(x_n)/x_n = \sum_{i=1}^n \mu_A(x_i)/x_i \quad (4-2)$$

或连续形式：

$$A = \int_x \mu(x)/x \quad (4-3)$$

通常 MUAS 协同执行作战任务时，飞行区域中的某个空间点对应一个明确的二值集合：

$$P_i(x, y, z) \rightarrow \{0 = \text{No waypoint}, 1 = \text{Waypoint}\} \quad (4-4)$$

即空间中的某点或者是可飞的路径点，或者是不可飞的点。规划的航迹是由一组可飞的、满足各种约束条件和协同关系的关键路径点组成的连线：

$$L_{ij} = (S_i, P_{i1}, P_{i2}, \cdots, P_{ik}, T_j), \quad i = 1, 2, \cdots, n, k = 1, 2, \cdots, s \quad (4-5)$$

其中 S_i 代表第 i 个 UAV 的出发点， T_j 代表第 j 个目标点，关键路径点 P_{ik} 的选取，完全依赖于约束条件，与其他未被选中的可飞路径点没有任何区别。因此，这种表示方法忽略了空间中不同位置的点与实际规划问题之间的联系。

利用模糊集的思想来优化三维空间上的网格点，将空间网格上的某个点从明确的可飞或不可飞关系拓展为根据实际任务和环境信息量化的可飞性度量关系，可以有效提高空间搜索的效率。因此，空间模糊表示就是利用与任务代价和约束相关的隶属度来表示 MUAS 规划空间上的网格点，形成空间模糊集合，并基于该模糊集合来衡量空间某点执行某个任务是否可飞的程度。设空间模糊隶属度函数为 $\mu_A(P_{ik})$ ，则利用模糊集表示的航迹为：

$$\begin{aligned} L_{ij} &= (S_i, \mu_A(P_{i1})/P_{i1} + \mu_A(P_{i2})/P_{i2} + \cdots + \mu_A(P_{ik})/P_{ik}, T_j) \\ &= (S_i, \sum_{l=1}^k \mu_A(P_{il})/P_{il}, T_j) \end{aligned} \quad (4-6)$$

因此，根据可飞性隶属度，在模糊化的空间中进行搜索，能够凸显有价值的空间点，快速筛选形成航迹的关键路径点，有效约减了空间搜索的范围。

4.2.2 模糊隶属度函数设计

考虑 UAV 与目标和飞行环境的综合因素，三维空间中任一点 $P(x, y, z)$ 是否适合作为航迹的关键路径点，可由点 P 与 UAV 起始点和目标点之间的三

角距离关系、点 P 与多个威胁区域的距离关系，以及点 P 与地形的距离关系体现出来。综合这些关系对空间点 P 进行模糊化，可以获得 UAV 规划空间的模糊集表示。模糊集表示的三维空间是具有一定分布特征的空间，其中隶属度较高的点，更适合作为 UAV 航迹的关键路径点，而隶属度低的点，则在搜索时趋于被淘汰。

由于三维空间的复杂性，计算模糊集时不可能覆盖空间中的所有点。因此，可用栅格法表示三维空间，仅对栅格上的点进行模糊化，构建三维空间的模糊子集，并在模糊子集上进行关键路径点的选取。此外，空间中低于地面的点和威胁区域内的点不具备可飞性，因此设定这些点的隶属度为 0，减少不必要的计算。对于栅格上可飞的点，定义综合的模糊隶属度函数如下：

定义 4.2 (最短航程关系隶属度)：在无障碍的条件下，UAV 执行任务的最短航程是从出发点到目标点之间的直线距离，而空间中某点与最短航程的关系可由该点与出发点和目标点的三角关系求得，当该点与出发点和目标点的距离之和接近最短航程时，该点适于作为关键路径点，其隶属度较大，否则较小，最短航程隶属度可表示为：

$$\tilde{\mu}_1(x) = \begin{cases} 0 & 10 \cdot d_{(s,t)} \leq (d_{(s,x)} + d_{(x,t)}) \\ \frac{d_{(s,t)}}{d_{(s,x)} + d_{(x,t)}} & 10 \cdot d_{(s,t)} > (d_{(s,x)} + d_{(x,t)}) \end{cases} \quad (4-7)$$

其中， x 表示空间中的某个点， s 表示 UAV 的出发点， t 表示执行任务的目标点， d 为距离。此外，因为离出发点和目标点较远的点不可能作为有效的关键路径点，因此设定当 x 与 s 和 t 的距离之和大于最短航程距离 10 倍时，该点的隶属度为 0。

定义 4.3 (多雷达威胁和禁飞区隶属度)：在 UAV 执行任务的区域通常存在多个探测雷达和禁飞区，这些区域可用威胁半径 r 表示其所覆盖的空间范围。某点与各个雷达威胁和禁飞区关系的隶属度，可用该点到威胁中心的距离与威胁半径的关系计算；对多个威胁，可将隶属度加权平均，其隶属度函数可用分段函数表示为：

$$\tilde{\mu}_2(x) = \begin{cases} 0 & d_{(x,\theta)} \leq r_\theta \\ \sum_{\theta=1}^n \left(\frac{d_{(x,\theta)} - r_\theta}{d_{(x,\theta)}} \right) / n & r_\theta < d_{(x,\theta)} \leq 2r_\theta \\ 1 & 2r_\theta < d_{(x,\theta)} \leq 3r_\theta \\ \sum_{\theta=1}^n \left(\frac{r_\theta}{d_{(x,\theta)} - 2r_\theta} \right) / n & d_{(x,\theta)} > 3r_\theta \end{cases} \quad (4-8)$$

其中, θ 表示威胁中心, $d_{(x,\theta)}$ 为点 x 到该威胁中心的距离, r_θ 为威胁半径, n 表示雷达和禁飞区的个数。

定义 4.4 (三维地形隶属度): 三维环境下执行任务时要求 UAV 不能撞到地面造成毁伤, 因此要降低毁伤概率, 必须考虑 UAV 与地形的关系。空间中某点与地形的关系可以转换成该点在坐标 x 、 y 、 z 方向上离地面最近的距离与安全距离的关系, 因此地形隶属度可由公式(4-9)表示:

$$\tilde{\mu}_3(x) = \begin{cases} 0 & \min(d_i, d_j, d_k) \geq d_m \\ \frac{\min(d_i, d_j, d_k) - d_m}{\min(d_i, d_j, d_k)} & d_m < \min(d_i, d_j, d_k) \leq 2d_m \\ \frac{d_m}{\min(d_i, d_j, d_k) - d_m} & \min(d_i, d_j, d_k) > 2d_m \end{cases} \quad (4-9)$$

其中, d_i, d_j, d_k 表示点 x 在坐标系 x 轴、 y 轴、 z 轴方向上与地面之间的距离, d_m 为 UAV 到地面的安全距离, 取最小值是为了利用点 x 与地形的最小分量和安全距离进行比较, 降低计算的复杂性。以上三种模糊隶属度的函数变化曲线如图 4-1 所示:




图 4-1 模糊隶属度函数曲线

Fig 4-1 Curve of fuzzy degree function

综合以上三种隶属关系的隶属度函数, 可用加权关系获得实际问题求解的综合隶属度为:

$$\tilde{\mu}_A(P_{ik}(x)) = (\alpha \cdot \tilde{\mu}_1(P_{ik}(x)) + \beta \cdot \tilde{\mu}_2(P_{ik}(x)) + (1 - \alpha - \beta) \tilde{\mu}_3(P_{ik}(x))) / 3 \quad (4-10)$$

其中, α 和 β 为综合隶属度的比例因子, 用来确定三种隶属度对空间点

的影响程度。当空间中某点的综合隶属度 $\tilde{\mu}_A(P_{ik}(x))$ 越大时, 该点就越适合作为备选航迹的关键路径点。

或者也可以将三种隶属度分别对应空间上三个独立的模糊子集, 利用模糊集的并表示隶属关系:

$$\begin{aligned}\tilde{\mu}_{A_1 \cup A_2 \cup A_3}(P_{ik}(x)) = & \tilde{\mu}_1(P_{ik}(x)) + \tilde{\mu}_2(P_{ik}(x)) + \tilde{\mu}_3(P_{ik}(x)) \\ & - \tilde{\mu}_1(P_{ik}(x))\tilde{\mu}_2(P_{ik}(x))\tilde{\mu}_3(P_{ik}(x))\end{aligned}\quad (4-11)$$

同样有 $\tilde{\mu}_{A_1 \cup A_2 \cup A_3}(P_{ik}(x))$ 越大, 该点就越适合作为备选航迹的关键路径点。

4.2.3 截集优选关键路径点

模糊集理论中, 利用 λ 水平截集来区分集合中元素的归类问题, λ 水平截集定义如下:

定义 4.5: 设 A 为 $X=\{x\}$ 中的模糊集, 其中隶属度大于 λ 的元素组成的集合, 称为模糊集 A 的 λ 水平截集, 即:

$$A_\lambda = \{x | \mu_A(x) \geq \lambda\} \quad (4-12)$$

截取后, λ 水平截集 A_λ 为普通集合, 它的特征函数为:

$$\mu_{A_\lambda}(x) = \begin{cases} 1 & \mu_A(x) \geq \lambda \\ 0 & \mu_A(x) < \lambda \end{cases} \quad (4-13)$$

因此, 在根据某个任务的综合隶属度求得该任务对应的空间模糊集后, 为了优选关键路径点, 可以通过截集法获得隶属度较大的部分点作为初始的最优关键路径备选点。设需要获取的关键路径点集合占整个模糊集的比例为 $s\%$, 则 λ 的取值和关键路径点的截集可由下式给出:

$$A_\lambda = \begin{cases} \{p_{ik}(x) | \mu_A(p_{ik}(x)) \geq \lambda\} \\ \lambda = \frac{\sum_{i=1}^k \mu_A(P_{il})}{2 \cdot s\% \cdot k} \end{cases} \quad (4-14)$$

截集 A_λ 是隶属度高于 λ 的空间点集合, 该集合占整个空间点集的 $s\%$ 。这些隶属度较高的点, 更适合在搜索过程中作为航迹的关键路径点, 因此受关注的程度也越高。

4.3 基于文化算法的 MUAS 协同航迹规划方法研究

4.3.1 空间模糊文化算法的航迹规划框架

文化算法(Cultural algorithm, CA)是 Reynolds^[118]提出的一个基于知识的对偶-继承进化系统^{[118]-[121]}，它模拟人类社会的演化，利用领域知识来指导搜索过程。文化算法中的“文化”通常指群体演化过程中逐渐积淀的各种知识、经验、信念、价值等行为习惯的总和^[118]。CA 由信念集和种群集构成相互影响的共同演化机制，信念集在演化过程中积累各类知识元素；种群集根据文化积累演化物种体系。与人类社会发展相似，物种在演化的过程中受到强烈的文化习惯刺激，可以加速新生代快速成长。由此 CA 保证了搜索过程中具有更强的方向性指导。其信息传递和系统演化过程如图 4-2 所示：




图 4-2 文化算法信息传递和系统演化过程

Fig 4-2 The information transfer process and system evolution of CA

与其他同类算法如 GA 算法、PSO 算法相比，CA 具有更明确的进化知识体系和方向指引，知识的积累不但能够加快群体演化的进程，还能有效跳出局部最优陷阱，保证进化过程始终向着全局最优的方向前进，因此文化算法在进化规划体系的表现更优异。此外，与标准的进化算法相比，文化算法的搜索过程是非偏置的，它充分利用领域知识来指导进化搜索，提升了种群中可行个体的被关注度。因此，可以对解空间的非可行部分剪枝，根据现有知识将进化个体从非可行区域移向可行区域，以达到优化种群搜索的范围。CA 的种群演化可以结合多种智能方法，如 GA、PSO 和 DE 等。如果采用 DE 算法，即有利于和目标分配阶段的方法统一，又能充分利用 DE 算法连续

实值差分的特性，在三维空间深度探索未知领域^{[118][121]}。因此，在种群集上引入 DE^[122]，可以有效提高算法的效率。

采用 CA 求解 MUAS 协同航迹规划问题，可将三维空间点的隶属度作为信念集存储的环境文化，利用空间点的隶属度筛选关键路径点，影响种群个体的多样性生成的；在种群集上对个体的关键路径点坐标进行差分，探索空间中的未知点，以搜索到种群未覆盖的位置。当进化搜索到更优的位置时，算法将该位置信息更新到信念集，形成系统知识。信念集和种群集相互影响和促进，不断积累领域知识，修正搜索方向，因此有效降低了求解的复杂程度，提高了全局寻优的能力。基于 CA 的多机协同航迹规划问题求解框架如图 4-3 所示。




图 4-3 基于文化算法的航迹规划框架图

Fig 4-3 Framework based on a cultural algorithm with spatial fuzzy set

图 4-3 显示了算法的三个组成部分和两个通信协议之间的关系，三维环境空间设定了系统的输入，同时，还能够提供 UAV 的各种约束条件。信念集和种群集之间由两个通信协议相互影响和制约：影响协议传播各种已经积累的文化习惯，以影响进化种群的生成和更新；接受协议则将进化产生的优解信息、阈值信息等传播到信念集，用来不断充实和完善信念知识库，为之后的进化迭代提供依据。算法在差分迭代的过程中融入信念集的影响，对算法搜索的方向进行更精细的控制，实现搜索的优化。

4.3.2 基于模糊表示的信念集构成和更新

4.3.2.1 信念集的构成

信念集可以理解为求解问题的知识仓库，存储着种群中个体的习惯模式，通常由多种知识源构成。在航迹规划求解中可描述为以下三个方面的知识源：

1) 环境知识：即是求解问题的较优解集合。可以表示为一系列的由关键路径点组成的飞行备选航迹，这些航迹形成了进化的初始种群。环境知识可由式(4-15)表示：

$$P_{enviro} = L_{kl}(x) = \{P_{k1}(x), P_{k2}(x), \dots, P_{ks}(x)\}, x=1, 2, \dots, n \quad (4-15)$$

其中， P_{ks} 为备选航迹上的 k 个关键路径点， x 为航迹的数量。在演化过程中，环境知识更新可以产生出更多覆盖新位置的个体，以提高多样性，扩充搜索覆盖的空间范围。

2) 历史知识：历史知识来自于进化算法迭代过程中对较优解的积累，文化算法利用接受函数将当前进化产生的部分较优解存储到信念集，扩充栅格以外的领域信息。这些差分产生的新个体就构成了算法的历史知识。历史知识更新公式如下所示：

$$P_{history} = \{P_{old}\} + s\% \cdot \{P_{result}(\phi)\} \quad (4-16)$$

$$\phi = f(i) / \sum_{j=1}^n f(j), i, j=1, 2, \dots, n \quad (4-17)$$

其中， P_{old} 是历代已经保留下来的个体， $s\%$ 是个体保留的比例。 P_{result} 是当前代差分操作后获得的结果种群，选择个体的概率 ϕ 由个体的适应度函数比率表示。

3) 协同知识：为了有效提高多机作战的协同性能，可以在信念集计算备选航迹的协同避碰性能，形成备选航迹的协同知识。计算备选航迹上某点的协同性能，可用该点执行当前任务与执行其他不同任务的隶属度差异来进行比较，如下公式所示：

$$\sigma^i(x) = \sum_{\lambda=1}^n |\tilde{\mu}^i(x) - \tilde{\mu}^\lambda(x)| / \sum_{j=1}^n \tilde{\mu}^j(x), \quad i=1, 2, \dots, n \quad (4-18)$$

其中， $\tilde{\mu}^i(x_i)$ 表示 x 点在任务 i 上的隶属度，它与该点对其他任务隶属度之差的总和，可反映出该点在协同时的性能。当 σ 为较大的值时，该点更适

合于当前任务，而不适合其他任务，因此协同能力较高；当 σ 较小时，该点可能同时成为多个任务的备选点而造成冲突，说明该点的协同能力较低。备选航迹的协同性能由备选航迹上所有关键路径点的协同性能之和获得。协同信息随备选航迹一起输出到种群集，在进化计算过程中，可利用该信息影响个体的协同适应度，使进化的结果向着协同性能更好的航迹方向前进。

此外，通过引入协同知识，可以判断航迹上某点的协同性能，当其对多个任务都适合时，其协同性能较低，因此规划航迹时，应该尽量避免利用这样的点作为关键路径点。这样做虽然会丢掉一些较好的位置，但是可以有效保证航迹的协同性能，因此是协同航迹规划必要的方法。

4.3.2.2 基于接受协议的信念集更新

在种群集上执行差分进化，可以通过接受协议更新信念集，使信念集的内容不断变化和丰富；并直接影响差分进化的进一步操作，强化算法搜索的能力。根据信念集的知识来源，其更新操作主要有以下三个方面：

1) 环境动态更新：为了尽可能全面的覆盖航迹的搜索空间，在进化过程中，可通过改变栅格的整体位置和栅格的空间结构来生成新的种群，扩大空间的覆盖范围。栅格的表示方法如公式(4-19)所示：

$$P(x, y, z) = \begin{cases} x = x_0 + \text{int}((U_x - L_x)/n) \\ y = y_0 + \text{int}((U_y - L_y)/n) \\ z = z_0 + \text{int}((U_z - L_z)/n) \end{cases} \quad (4-19)$$

其中， U 和 L 表示 x 、 y 、 z 分量上的取值范围， n 是网格的数量。为了保证进化充分搜索，并降低结构改变造成的大量计算，设定环境更新的阈值 ρ ，确保种群集在进化一定代数后才更新一次。随着迭代的深入，设定更大的阈值，以减少更新的内容，提高计算效率。网格更新的公式如下所示：

$$P_i(x, y, z) = \begin{cases} x = x_0 + \varepsilon \\ y = y_0 + \delta \\ z = z_0 + \gamma \end{cases} \quad \forall g \% \lambda = 0, i = 1, 2, \dots, n \quad (4-20)$$

其中， g 是当前进化的代数，当进化的代数与阈值的余数为0时，更新初始坐标位置和栅格的数量， ε 、 δ 和 γ 为坐标更新的分量， n 为一个大于2且小于网格上限 U 的整数。栅格位置的改变增加了空间搜索覆盖的范围，同时也保持了种群的多样性。

2) 历史选择更新：历史选择更新包括随机个体保留和最优解保留两个方面。

随机个体保留是按一定比例和选择概率提取当前搜索结果中的部分较优

个体，将其保存在历史信息中，记录进化过程中的部分状态。

最优解保留是将上一次迭代产生的最优解保留在历史信息中，并在下一次迭代和更新过程中作为群体必备的个体输入。最优解保留保证了之前搜索的最好结果始终参与进化，防止当前种群重复搜索或者搜索到次优的位置。历史选择更新可由公式(4-21)表示如下：

$$\begin{cases} p_{history} = \{p_{history}\} + s\% \cdot \{p_{result}(\phi)\} \\ p_{best} = \min(\text{fit}(p_{result})) \end{cases} \quad (4-21)$$

其中， $P_{history}$ 是历史信息种群，记录不同进化代中的部分个体， P_{result} 和 $s\%$ 的含义与公式(4-16)相同； P_{best} 为当前最优解，它是结果中适应度最好的个体。

3) 协同信息更新：当差分进化生成新个体时，要计算新个体的协同值并加入到适应度函数中，以便和种群中的父代个体进行比较。因此，在更新协同信息时，为避免重复计算，只要将接受函数获得的新个体的协同值保存下来，并计算其他新生成的初始个体的协同值即可。

4.3.3 种群集上基于 MODE 的协同航迹规划

4.3.3.1 基于影响协议的种群生成

将空间栅格分解成一组在 x 或 y 轴方向上垂直于地平面的面，则从 UAV 出发点到目标点之间的每一个栅格面上，利用轮盘赌法筛选出一个关键路径点，基于模糊隶属度选择的概率如下：

$$p_i = \tilde{\mu}_i / \sum_{j=1}^K \tilde{\mu}_j, \quad i=1,2,\dots,n \quad (4-22)$$

其中 P_i 表示栅格面上某点的选中概率，它由该点的隶属度占信念集隶属度之和的比来确定。隶属度较高的点，被选中的机会较大。通过轮盘赌法在不同的栅格面上选择关键路径点，然后将这些关键点连接起来，就形成了一条初始航迹个体。

基于以上的个体生成方法，可在空间栅格上产生 n 条备选的航迹，组成基于环境知识的进化种群 P_{enviro} 。同时，随着种群集上算法的迭代，利用差分进化搜索到的较优新个体，将通过接受协议保存到信念集的历史知识库中，通过知识积累形成基于历史知识的进化种群 $P_{history}$ 。因此考虑到环境知识和历史知识的共同作用，算法基于影响协议的种群生成可表示为：

$$P_{popsize} = \lfloor (1-g/Gen) \cdot P_{enviro} + (g/Gen) \cdot P_{history}(\phi) + P_{history}^{best} \rfloor \quad (4-23)$$

其中, (g/Gen) 表示当前代数占总代数的比例, 随着进化过程不断的增长, 历史知识积累的较优解在种群中所占的比例不断增加, 可以充分利用寻优的信息加快算法的收敛, $P_{history}^{best}$ 表示在种群生成时必须包含在历史知识中的当前最优解, 以防止进化算法重复搜索到次优的位置。此外, 还要计算种群中备选航迹的协同性能 $\sigma(x)$, 并将其传递给种群集的差分进化计算。

4.3.3.2 基于 MODE 的进化协同航迹规划

影响协议输出的种群中的个体, 是由一系列关键路径点连接的可行备选航迹段, 算法搜索的目标是从初始种群开始, 在空间中找到适合多种约束条件, 满足航迹目标最优的一组协同航迹, 因此该问题是一个多目标优化问题, 其优化的目标是找到所有任务的 *Pareto* 优解。*Pareto* 优解是各个任务相互制约平衡的一组较优可行解集合, 虽然其中某个单一任务的航迹并不是其最优航迹, 但是与其他任务相协同, *Pareto* 优解具有比单一任务最优解更好的协同和优化性能。因此, 多机协同航迹规划获得的一组航迹解集合并不是唯一的, 也不是各个任务的最优解集合, 而是符合协同约束条件的一组较优可行解, 该多目标优化问题的数学模型可定义如下:

$$\begin{aligned} V - \min_{x \in R^n} F(x) &= \min [f_1(x), f_2(x), \dots, f_k(x)]^T, k=1, 2, \dots, K \\ \text{s.t.} \quad &g_j(x) \leq 0, \quad j=1, 2, \dots, p \\ &h_k(x) = 0, \quad k=1, 2, \dots, q \end{aligned} \quad (4-24)$$

在式(4-24)中, 每一个 $f_k(x)$ 对应一个任务路径, 该路径由一系列有效的关键路径点组成, 这些点链接的路径尽量满足飞行距离代价最优, 并满足各种自身和协同的约束条件, 即有:

$$f_k(x) = \sum_{i=1}^{s-1} d_k(i, i+1) + \prod_{j=1}^M \alpha_{kj} c_k(j) + \prod_{l=1}^L \beta_{kl} c'_k(l) \quad (4-25)$$

其中第一项表示总航程代价, 它由全部关键路径点连线的距离之和组成; 第二项是 UAV 自身约束关系之和, 其中包括各种 UAV 必须满足的自身约束限制条件如: 最大燃油约束、最短飞行时间约束、威胁约束、最大最小速度约束、以及航向角约束等; 第三项是当前 UAV 与其他 UAVs 协同的约束关系之和, 其中包括各个任务之间的协同限制条件, 如: UAVs 之间的避免碰撞约束、同时到达目标约束等。以上这些约束由惩罚函数的形式对总的目标函数加以影响, α 和 β 是控制目标函数加权的比例系数。

标准差分进化是基于实数编码的并行搜索算法, 它通过个体基因之间的距离差距衡量后代进化的优劣, 因此非常适合基于坐标的路径点航迹进化操作。利用实际坐标位置进行差分的特殊性, 还可以通过栅格上关键路径点的

差分获取到栅格之外的位置。这样差分产生的子代个体的关键点可以脱离栅格本身的限制和束缚，在更广的覆盖空间上进行航迹的搜索，因此将差分方法用于航迹协同规划，具有优于其他现有规划方法的天然优势。本章在文献[118][120][122]的基础上，将差分进化应用于求解多目标优化问题，以提高多机协同航迹规划的效率。此外，根据之前的研究，在差分过程中采用 *DE/rand to best/1* 策略和 *DE/best/2* 策略的混合策略，可以有效融合当前种群最优解的信息，提高优化效率。因此，根据混合差分策略和三维空间中点的坐标值将 MODE 的差分操作扩展如下：

$$p'_k(x'_k, y'_k, z'_k) = \begin{cases} x_k^{best} + R_x \cdot (x_k^{best} - x_k^{r1}) + F_x \cdot (x_k^{r2} - x_k^{r3}) \\ y_k^{best} + R_y \cdot (y_k^{best} - y_k^{r1}) + F_y \cdot (y_k^{r2} - y_k^{r3}), & k=1,2,\dots,n \\ z_k^{best} + R_z \cdot (z_k^{best} - z_k^{r1}) + F_z \cdot (z_k^{r2} - z_k^{r3}) \end{cases} \quad (4-26)$$

其中， x_k, y_k, z_k 为第 k 个任务中某关键路径点 P_k 在三维坐标轴上的分量， R, F 是交叉率，一般取在 $[0,1]$ 范围内的值，初始父代航迹个体 $r1, r2, r3$ 均为三维栅格上的关键路径点， $best$ 为当前全局最优个体。由差分策略可见，通过差分计算可以获取到栅格以外的空间上的位置，如果新的位置产生的个体具有更好的适应度，则可以通过选择操作加以保留，其公式如下：

$$p'_k(g+1) = \begin{cases} p'_k(g), & \text{if } f_k(p'_k(g)) < f_k(p_k(g)) \\ p_k^{r1}(g), & \text{else} \end{cases} \quad (4-27)$$

其中， g 为迭代次数，当新获得解的适应度小于当前解的适应度，则在 $g+1$ 代中用新的解替换当前解，否则不变。

在公式(4-27)中， $f_k(x)$ 为任务 k 的适应度函数，它决定了进化选择个体的条件和进化前进的方向。为了充分利用信念集的模糊信息和协同信息来引导搜索，使规划的航迹更加符合进化和协同的需要，本章进一步扩充了适应度函数，该函数由三部分组成，第一部分是 UAV 自身的飞行代价和各类约束条件，保证规划的航迹首先是可飞的；第二部分是航迹关键点的模糊隶属度，体现了空间模糊化对航迹的影响；第三部分是航迹关键点的协同值，以满足 UAV 之间的协同需求，改进后的聚合适应度函数表示如公式(4-28)所示。

$$f(x) = \sum_{k=1}^n w_k \cdot (f_k^{cost}(x) + \eta \cdot (1 / \sum_{i=1}^S \tilde{\mu}_k(i)) + \chi \cdot (1 / \sum_{i=1}^S \sigma(i))) \quad (4-28)$$

其中, $f_k^{\text{cost}}(p)$ 表示 UAV 自身的飞行代价和约束关系, 由前面的公式(4-25)给出。 $\tilde{\mu}_k(i)$ 为当前航迹上关键路径点 i 的模糊隶属度, $\sigma(i)$ 为当前航迹上关键路径点的协同值, η 和 χ 是协调三者量级的比例因子, 它保证适应度能够合理体现三者的相互影响, 以反映出航迹的优劣程度。

4.4 算法理论分析和参数选择

4.4.1 空间模糊表示和文化算法理论分析

首先证明空间模糊化后, 空间模糊集取 λ 截集能够获得有效的备选关键路径点集合。

定义 4.6: 模糊集的并包含所有集合的元素, 但是隶属度取决于所使用的特定的并 (s -范数), 现取和作为 s -范数, 则模糊集的并可表示为:

$$\mu_{A \cup B}(x) = \mu_A(x) + \mu_B(x) - \mu_A(x)\mu_B(x), \forall x \in X \quad (4-29)$$

因为空间模糊化时考虑了三种情况的隶属度函数, 因此, 可以将其分别看成论域 X 上不同的模糊子集 A_1, A_2, A_3 , 当取 λ 截集时, 可考察空间某个点在三个不同模糊子集上的 λ 截集, 只有在所有模糊子集上均落入 λ 截集的点才是满足条件的截集点, 因此有:

$$A_\lambda = \{x | \mu_{A_1}(x) \geq \lambda, \mu_{A_2}(x) \geq \lambda, \mu_{A_3}(x) \geq \lambda\} \quad (4-30)$$

这样, 就确保了某点在个别模糊子集中隶属度过低而无法作为关键路径点的情况, 根据定义 4.6, 满足截集条件的点的并为:

$$\begin{aligned} \mu_{A_1 \cup A_2 \cup A_3}(x) = & \mu_{A_1}(x) + \mu_{A_2}(x) + \mu_{A_3}(x) \\ & - \mu_{A_1}(x)\mu_{A_2}(x)\mu_{A_3}(x), \forall x \in X \end{aligned} \quad (4-31)$$

又因为 $0 < \mu_{A_i}(x) \leq 1$, 所以公式(4-31)中的第一项求和递增量大于第二项求积递增量, 因此隶属度值越大的点一定会被截取。由此证明空间模糊集取 λ 截集能够获得有效的备选关键路径点集合。

根据之前的研究可知 MODE 算法本身是时齐 Markov 过程, 但是由于将该过程融入文化算法的框架之下, 而文化算法在每一代操作中都加入了不同文化信息的剧烈扰动, 导致各代的状态转移矩阵 $P(t)$ 不同, 因此文化算法是非时齐的, 很难用之前的分析方法进行分析。因此更适合从统计模型的角度

对文化算法进行分析。假设初始化种群集服从高斯分布，均值为 σ^0 ，方差为 Σ^0 ，初始种群分布为 $X^0 \sim N(\sigma^0, \Sigma^0)$ ，则有：

定理 4.1： 如果初始种群集满足高斯分布，并且在进化过程中包含信念集中的 *Pareto* 优解集 Γ ，那么在基于 MODE 的文化算法各代都满足高斯分布，且种群集均值收敛于优解集 Γ 。

证明：假设种群集在第 t 代也是高斯分布，则当前某个个体满足 $X^t \sim N(\sigma^t, \Sigma^t)$ ，现考察第 $t+1$ 代的种群集分布。因为文化算法的本质是在种群集进化过程中不断调整知识结构，使历史最优和相关信息都保留在种群内部，以指导搜索方向不产生偏离。因此 $t+1$ 代的差分操作可表示为：

$$X^{t+1} = \prod_{k=1}^m p_t(k) X' + (1 - \prod_{k=1}^m p_t(k)) X^t + F \sum_{i=1}^K (X_i^{r1} - X_i^{r2}), X' \in \Gamma \quad (4-32)$$

其中 $\prod_{k=1}^m p_t(k)$ 是文化算法影响种群的概率， X^t ， X_i^{r1} ， X_i^{r2} 是 t 代中不同的个体，都服从相同的 $N(\sigma^t, \Sigma^t)$ ， X' 是从信念集中获得的 *Pareto* 优解，且 $X' \in \Gamma$ 。因此， X^{t+1} 是几个独立高斯随机变量的线性组合，设为 x' 具体的 *Pareto* 优解，则条件期望为：

$$E(X^{t+1} | X' = x') = p_t x' + (1 - p_t) \sigma^t \quad (4-33)$$

因此有期望和方差为：

$$E(X^{t+1}) = p_t E(X') + (1 - p_t) \sigma^t \quad (4-34)$$

$$\text{Var}(X^{t+1}) = (1 - p_t)^2 \Sigma^t \quad (4-35)$$

则 X^{t+1} 的分布满足：

$$X^{t+1} \sim N(p_t X' + (1 - p_t) \sigma^t, (1 - p_t)^2 \Sigma^t) \quad (4-36)$$

则根据初始种群的分布，第 t 代种群期望的极限可表示为：

$$\begin{aligned}
\lim_{t \rightarrow \infty} E(X^t) &= \lim_{t \rightarrow \infty} (p_t \sum_{i=0}^{t-1} (1-p_t)^i E(X') + (1-p_t)^t \sigma^0) \\
&= p_t \frac{1}{p_t} E(X') + 0 \\
&= E(X')
\end{aligned} \tag{4-37}$$

由此可知种群集均值收敛于优解集 Γ ，证明完毕。

4.4.2 控制参数分析和算法流程

本章算法涉及的主要参数有空间模糊化的截集 λ ，坐标更新分量 ε 、 δ 和 γ ，影响协议的选中概率 P_i ，以及适应度函数中的比例因子 η 和 χ 。

其中截集 λ 的取值与设定的选择比例因子 $s\%$ 相关，如公式(4-14)所示，表示预选择空间模糊集中的 $s\%$ 个较优个体时，可按 λ 在模糊集 X 上进行截取。然而因为本文的模糊化空间同时满足三个隶属度模糊子集，因此，在取截集的并集时，会有部分个体不满足并集条件，因此可以将 $s\%$ 设的大一点，以抵消并集操作中消去的个体，通常取 $s\%=40\%$ 。

为了增加搜索空间覆盖的范围，文化算法的信念集上可以对空间坐标结构进行动态调整，其调整参数主要由坐标分量 ε 、 δ 和 γ 决定， ε 、 δ 和 γ 的大小决定了更新后空间坐标栅格的疏密程度，当栅格密度过高时，算法要搜索的空间位置就更多，算法性能必然降低；当栅格密度过低时，空间难以满足航迹连续性要求，无法找到合适的航迹。因此，坐标分量值可根据空间步长取值 $n = \text{rand}[2, U]$ 的数量来设定，其中 U 为步长的上限。

影响协议的选中概率 P_i 决定了信念集对种群集的影响强烈程度，本章选用轮盘赌法确定选中概率，使信念集输出到 $t+1$ 代的个体按归一化隶属度进行比例选择，选中概率大的点被选中的可能性就越大。同时，赌轮选择也有一定机会让隶属度稍差的点被选中，以平衡种群多样性。适应度函数中的比例因子 η 和 χ 主要用来协调空间模糊集和协同信息对算法适应度的影响，增加了这两个辅助项可以使适应度评价更接近多机协同的占优平面。 η 和 χ 的设定没有绝对的衡量尺度，通常通过大量的实验获取，反复实验的结果表明取 $\eta = f_k^{\text{cost}}(x) \cdot \bar{\mu}_k(i) \cdot 0.25$ ， $\chi = f_k^{\text{cost}}(x) \cdot \bar{\sigma}_k(i) \cdot 0.5$ 时，适应度评价与最后规划的 Pareto 占优解效果最好。

综合以上分析，多机协同航迹规划的空间模糊文化算法流程如算法 4.1 所示。

算法4.1 多机协同航迹规划的空间模糊文化算法
Alg.4.1 A cultural algorithm based on spatial fuzzy for
MUAS cooperative path planning

输入: 信念集大小 Q , 任务数量 S , 迭代次数 G , 栅格步长 K
输出: 满足任务集 S 的Pareto占优的全局航迹

```

01:  For  $x,y,z=1$  to 坐标最大值, 步长 $K$  do                                /*空间模糊化*/
02:      计算点 $(x,y,z)$ 的隶属度  $\tilde{\mu}_2(P_k(x))$ 、 $\tilde{\mu}_3(P_k(x))$ ;
03:      For  $i=1$  to  $S$  do
04:          计算点 $(x,y,z)$ 当前任务 $i$ 的隶属度  $\tilde{\mu}_i(P_k(x))$ ;
05:          计算点 $(x,y,z)$ 的综合隶属度  $\tilde{\mu}_A(P_k(x))$ ;
06:      End for
07:  End for
08:  用模糊化后的空间点集合初始化信念集 $Q(0)$ ;
09:  接受函数  $\zeta(x) \rightarrow \text{update}$  信念集;
10:  影响函数  $\psi(x) \rightarrow \text{update}$  种群集;
11:  For  $j=1$  to  $G$  do                                                        /*信念集操作*/
12:      If  $\zeta(x)$ 不为空 then
13:          If 满足阈值条件  $\rho$  then
14:              根据公式(4-20)更新栅格位置和结构;
15:          End if
16:          根据  $\zeta(x)$ 和公式(4-21)更新信念集  $Q(j)$ ;
17:          计算并更新较优解个体的协同值  $\sigma^i(x)$ ;
18:      Else
19:          初始化种群集中的初始种群;
20:      End if
21:      If  $\psi(x)$ 不为空 then                                                /*种群集操作*/
22:          执行  $\psi(x)$ , 产生当前 $j$ 代的进化种群 $P_j$ ;
23:          For  $k=1$  to  $P_j$  do
24:              根据公式(4-26)更新坐标点位置  $p'_k(x'_k, y'_k, z'_k)$ ;
25:              根据公式(4-27)选择  $g+1$ 代个体  $p'_k(g+1)$ ;
26:          End for
27:          执行  $\zeta(x)$ , 更新信念集;
28:      Else
29:          continue;
30:      End if
31:  End for

```

4.5 基于 B 样条拟合的 MUAS 协同航迹平滑

4.5.1 三维空间中的 B 样条拟合航迹平滑方法

虽然采用 MODE 算法能够快速规划出一组满足多个任务需求的协同

Pareto 最优航迹,但是这些航迹是由一系列路径关键点连接线段组成的,当路径点间距较大时,线段与线段的折角比较明显,因此不适合作为 UAVs 飞行的实际航迹。为了解决这一问题,必须对当前获得的航迹连线进行平滑处理,以使其能够满足 MUAS 中各类无人机飞行的需要。最常用的航迹平滑方法就是曲线拟合法,将离散的航迹关键路径点的连线进行曲线拟合,可以平滑航迹中的拐点,使航迹平滑可飞^[75]。因此通过差分进化规划出的协同航迹关键路径点组合,可以采用标准的三次 B 样条曲线对其进行平滑,将航迹中的关键路径点作为 B 样条曲线的控制点,就可以直接获得平滑的可行飞行航迹。

将航迹 $L_{ij} = (S_i, P_{i1}, P_{i2}, \dots, P_{ik}, T_j)$ 中的所有点均作为三次 B 样条曲线的控制点,通过迭代在三维空间进行曲线拟合,其中每一段曲线依次由四个关键路径点生成。根据 n 次三维曲线参数方程:

$$\begin{cases} x(t) = \sum_{i=0}^n x_i F_{i,n}(t) \\ y(t) = \sum_{i=0}^n y_i F_{i,n}(t) \\ z(t) = \sum_{i=0}^n z_i F_{i,n}(t) \end{cases} \quad (4-38)$$

其中, n 次 B 样条的分段混合函数为:

$$F_{i,n}(t) = \frac{1}{n!} \sum_{j=0}^{n-i} (-1)^j C_{n+1}^j (t+n-i-j)^n, 0 \leq t \leq 1, i=0,1,2,\dots,n \quad (4-39)$$

当 $n=3$ 时, B 样条的基函数可表示为:

$$\begin{cases} F_{(0,3)}(t) = 1/6(-t^3 + 3t^2 - 3t + 1) \\ F_{(1,3)}(t) = 1/6(3t^3 - 6t^2 + 4) \\ F_{(2,3)}(t) = 1/6(-3t^3 + 3t^2 + 3t + 1) \\ F_{(3,3)}(t) = 1/6(t^3) \end{cases} \quad t = 0,1,2,\dots,n \quad (4-40)$$

因此可以得到三维的三次 B 样条曲线的参数方程:

$$\begin{cases} x(t) = \frac{1}{6}(-t^3 + 3t^2 - 3t + 1)x_0 + \frac{1}{6}(3t^3 - 6t^2 + 4)x_1 + \frac{1}{6}(-3t^3 + 3t^2 + 3t + 1)x_2 + \frac{1}{6}t^3 x_3 \\ y(t) = \frac{1}{6}(-t^3 + 3t^2 - 3t + 1)y_0 + \frac{1}{6}(3t^3 - 6t^2 + 4)y_1 + \frac{1}{6}(-3t^3 + 3t^2 + 3t + 1)y_2 + \frac{1}{6}t^3 y_3 \\ z(t) = \frac{1}{6}(-t^3 + 3t^2 - 3t + 1)z_0 + \frac{1}{6}(3t^3 - 6t^2 + 4)z_1 + \frac{1}{6}(-3t^3 + 3t^2 + 3t + 1)z_2 + \frac{1}{6}t^3 z_3 \end{cases} \quad (4-41)$$

上式写成矩阵形式为:

$$P(t) = \frac{1}{6} [1, t, t^2, t^3] \begin{bmatrix} 1 & 4 & 1 & 0 \\ -3 & 0 & 3 & 0 \\ 3 & -6 & 3 & 0 \\ -1 & 3 & -3 & 1 \end{bmatrix} \begin{bmatrix} P_0 \\ P_1 \\ P_2 \\ P_3 \end{bmatrix} \quad t = 0, 1, 2, \dots, n \quad (4-42)$$

由矩阵方程(4-42)即可以原来离散的初始点、关键路径点和目标点作为样条曲线的控制点，逼近获得拟合的平滑航迹，如图 4-4(a)显示出某条航迹的拟合平滑效果。

从图 4-4(a)中可以看出，平滑后的航迹在转弯角较大的位置上脱离了关键路径点，其他位置基本与路径点连线相吻合，其平滑程度可以满足 UAV 的机动飞行。

4.5.2 反求控制点的三维 B 样条航迹平滑

B 样条曲线方法，虽然能够对获取的航迹进行平滑，但是这种拟合过程也使航迹偏离了关键路径点，这样获得的航迹无法体现出进化规划中获得的最优关键路径点的信息，因此降低了航迹优化的有效性^[123]。同时，控制点的偏离可能会使航迹接近威胁区，从而导致规划失效。为了解决这一问题，我们采用反求控制点的 B 样条曲线^[124]生成方法来平滑航迹，使平滑的路径能够经过全部关键路径点，而不是与路径点产生偏移。

若要点经过 $n-2$ 个路径点 Q_i ($i=0, 1, 2, \dots, n-3$) 作一条三次 B 样条曲线，就要先反求出三次 B 样条曲线的 n 个控制顶点 P_m ($m=0, 1, 2, \dots, n-1$)。此时，相邻曲线的连接点满足 $P_{i,3}(1) = P_{i+1,3}(0)$ ，则所求 B 样条曲线上的型值点为：

$$P_{i,3}(0) = \frac{1}{6} (P_i + 4P_{i+1} + P_{i+2}) \quad i = 0, 1, 2, \dots, n-3 \quad (4-43)$$

若令

$$Q_i = P_{i,3}(0) \quad i = 0, 1, 2, \dots, n-3 \quad (4-44)$$

这里，称 Q_i 为型值点。于是可得如下方程组

$$\begin{cases} 6Q_0 = P_0 + 4P_1 + P_2 \\ 6Q_1 = P_1 + 4P_2 + P_3 \\ \vdots \\ 6Q_{n-4} = P_{n-4} + 4P_{n-3} + P_{n-2} \\ 6Q_{n-3} = P_{n-3} + 4P_{n-2} + P_{n-1} \end{cases} \quad (4-45)$$

现在要解决的问题是：已知 $n-2$ 个型值点 $Q_i (i=0,1,2,\dots,n-3)$ ，计算逐点通过 Q_i 的三次 B 样条曲线的控制顶点 $P_m (m=0,1,2,\dots,n-1)$ 。用式(4-45)中的 $n-2$ 个方程计算 n 个未知量 $P_m (m=0,1,2,\dots,n-1)$ ，显然条件不充分，还需补充两个边界条件。

为了保证三次 B 样条曲线能够通过首末两个控制点，采用如下方式增加边界条件：在 B 特征多边形的首末两边延长线上外延一点，使得

$$P_1 = \frac{1}{2}(P_0 + P_2), \quad P_{n-2} = \frac{1}{2}(P_{n-3} + P_{n-1})。$$

由 $P_1 = \frac{1}{2}(P_0 + P_2)$ 推出 $P_0 = 2P_1 - P_2$ ，代入 $6Q_0 = P_0 + 4P_1 + P_2$ 得： $6Q_0 = 6P_1$ ；同理由 $P_{n-2} = \frac{1}{2}(P_{n-3} + P_{n-1})$ 推出 $P_{n-1} = 2P_{n-2} - P_{n-3}$ 代入 $6Q_{n-3} = P_{n-3} + 4P_{n-2} + P_{n-1}$ 得 $6Q_{n-3} = 6P_{n-2}$ 。将 $6Q_0 = 6P_1$ 和 $6Q_{n-3} = 6P_{n-2}$ 与式(4-45)所示方程组联立，得

$$\begin{cases} 6Q_0 = 6P_1 \\ 6Q_1 = P_1 + 4P_2 + P_3 \\ \vdots \\ 6Q_{n-4} = P_{n-4} + 4P_{n-3} + P_{n-2} \\ 6Q_{n-3} = 6P_{n-2} \end{cases} \quad (4-46)$$


写成矩阵形式为

$$\begin{bmatrix} 6Q_0 \\ 6Q_1 \\ \vdots \\ 6Q_{n-4} \\ 6Q_{n-3} \end{bmatrix} = \begin{bmatrix} 6 & 0 & & & \\ 1 & 4 & 1 & & \\ & \dots & \dots & \dots & \\ & & 1 & 4 & 1 \\ & & & 0 & 6 \end{bmatrix} \begin{bmatrix} P_1 \\ P_2 \\ \vdots \\ P_{n-3} \\ P_{n-2} \end{bmatrix} \quad (4-47)$$

用追赶法求解该三对角方程即可。最后，在反求得到 $P_m (m=0,1,2,\dots,n-1)$ 的情况下利用公式(4-42)，可获得经过全部关键路径点 $Q_i (i=0,1,2,\dots,n-3)$ 的拟合曲线，如图 4-4(b)所示：

从图 4-4(b)中可以看出，反求控制点的 B 样条曲线经过了全部的路径关键点，因此能够保证平滑后的航迹不会产生与关键路径点偏离较大的情况，但是此时的航迹也会变得更加曲折，其平滑的效果略差于 B 样条拟合，所以，UAV 在飞行过程中，会增加更多不必要的机动。因此，在实际规划过程中，可以将以上两个过程相结合，根据关键路径点与最近的威胁中心的距离来决定该点在平滑时采用那种平滑方式，在距离较小的区域用反求控制点的 B 样条拟合，而在距离较大的区域采用普通的 B 样条拟合，这样获得的航迹，可

以更好的满足 UAV 航迹平滑的需求。



(a)三次 B 样条曲线拟合

(b) 反求控制点的 B 样条曲线拟合

图 4-4 三次 B 样条和反求控制点的 B 样条曲线拟合航迹平滑

Fig 4-4 Smoothing path by cubic B-spline and reversely calculating the control vertexes of curve fitting

4.6 实验结果与分析

本章的实验建立在前两章 MUAS 目标分配的基础上，将其获得的目标分配结果作为本章协同航迹规划算法的输入，则 UAVs 与任务的数量和分配关系已经确定。在此前提下，本章在奔腾双核 2.80GHz、4GB 内存的 PC 机上，利用 Matlab(R2011b)仿真软件进行仿真实验，具体分析如下：

4.6.1 协同航迹规划可行性实验

针对本章算法规划航迹是否可行进行实验，首先，设定实验的环境参数与第三章的参数相同，其分配关系由第三章目标分配算法确定，如表 4-1 所示。

表 4-1 无人机与目标点的分配关系

Tab 4-1 The assignment relationship of UAVs and Targets

项目	分配关系									
UAV	1	2	3	4	5	6	7	8	9	10
Target	2	1	6	9	8	5	10	4	3	7

其次，设定实验群体集中差分进化的参数：种群大小($Pop=20$)、进化代数($Gen=500$)、变异率($R_x=0.7$, $F_x=0.5$)、比例因子($\alpha=200$)、比例因子($\beta=150$)、历史保留率($s=10\%$)。实验结果如图 4-5、图 4-6 所示，其中图 4-5(a)为仿真




图 4-5 MUAS 协同规划的航迹和算法收敛曲线

Fig 4-5 The trajectories by MUAS cooperative planning and convergence curve of algorithm




图 4-6 不同视角的航迹协同效果

Fig 4-6 The results of cooperative path planning by different view points.

实验规划的结果，其中不同任务的航迹用不同颜色标识；图 4-5(b)为单条航迹规划的收敛曲线，表示种群进化时的收敛效果。图 4-6(a)(b)(c)(d)为隐藏了地形和威胁区后，在不同视角上航迹的显示结果。从图 4-5(a)获得的结果可以看出，改进后的算法能够有效的生成多架 UAV 可行的飞行航迹，每条航迹均符合 UAV 自身的飞行约束条件，同时，还能够满足多机协同的需要，算法可以完成多个目标的协同规划。此外，图 4-5(b)收敛曲线中还可以看出算法针对各个任务的收敛能力强、速度快、在后阶段可以跳出局部最优。

从图 4-6 中不同视角综合显示的结果可以看出，规划后的航迹具有较好的协同避碰性能，航迹与航迹之间没有交叉点的情况存在，由此说明，改进的 MODE 算法具有较好的协同能力。

4.6.2 与常用协同规划算法的对比分析

文化算法通过与信念集共享全局领域知识，扩展了算法搜索的能力，为了验证文化算法搜索性能的提升，在基于上一节的环境和进化参数设定下，本节将基于 MODE 的文化算法与用 MOGA 算法^[68]、平行进化 PEA^[69]算法、和动态混合(Dynamic Hybrid)粒子群 DHPSO^[74]算法来规划多机协同航迹的方法进行了对比实验。实验的结果如图 4-7 和表 4-2 所示：

其中 MOGA 算法采用锦标赛选择和实值交叉变异方法，其中交叉率 $P_c=0.7$ ，变异率 $P_s=0.3$ ；粒子群算法的速度更新参数 $c_1=1.24$ ， $c_2=1.26$ ，速度 v 更新时不受范围限制。PEA 算法的参数和设置与 MODE 文化算法的设置相似。此外，由于各个任务的最优代价是结合了各种约束条件的综合适应度分值，因此是无量纲的，而总执行时间为完成全部任务所需的总规划时间。




图 4-7 规划算法的平均适应度收敛曲线比较

Fig 4-7 Average convergence curve of fitness by different planning algorithms

从图 4-7 中可以看出,本章改进后的文化算法在收敛性能上明显优于其他算法,且能在搜索空间中找到更优的解。从平均适应度曲线的走势可以看出在迭代进程中,文化的积淀和影响明显克服了算法陷入局部最优的问题,并且始终影响着搜索的方向。此外,从平均适应度曲线上还可以看出 MOGA 算法和 DHPSO 算法的收敛速度过快,导致陷入局部最优,而 PEA 算法优于其他两种方法,且执行速度较快,但是在没有文化信息指导的情况下,搜索的盲目性使其很难接近更优的解空间。从表 4-2 中可以看出,本章改进后的算法可以获得大部分任务的最优解,而总执行时间略高于 PEA 算法和 DHPSO 算法,这是由于对信念集的维护造成了时间开销,但是,与

表 4-2 规划算法的任务代价和执行时间比较

Tab 4-2 The task cost and execution time comparison of planning algorithm

	MOGA(最优代价)	DHPSO(最优代价)	PEA(最优代价)	MODE文化(最优代价)
任务1	142.5041	139.1461	136.7499	135.3138
任务2	202.9003	196.4157	200.6997	193.1318
任务3	168.1724	161.5477	156.8565	158.6844
任务4	220.7405	214.2737	211.6928	206.3204
任务5	228.3817	223.4982	220.7089	219.6355
任务6	174.2715	170.3553	168.1834	165.1613
任务7	142.8922	142.8922	132.1557	134.3619
任务8	210.7991	204.4029	205.6250	200.8816
任务9	137.0055	133.5543	130.1488	130.1443
任务10	187.0706	177.4917	171.5527	170.3513
总执行时间s	1120.7000	642.0845	574.5673	720.1006

MOGA 算法相比,仍相对较小,因此是可以接受的。此外,表中 MODE 文化算法的个别任务之所以代价较高,是因为仿真实验中这些任务避开了与其他航迹交叉的可能,说明航迹协同性较好。因此,完全可以用文化算法代替其他规划算法获得更好的解。

4.6.3 与其他文化算法的对比分析

标准文化算法是基于 GA 算法维持种群集进化寻优的,因此本章还与标准文化算法^[120]和非模糊空间下的标准文化算法进行了对比实验,实验结果如图 4-8 和表 4-3 所示。从图 4-8 可以看出,标准文化算法也能够有效利用信念集中的知识指导搜索的深入,然而 GA 算法的收敛存在早熟现象,因此搜索性能较基于 DE 算法的文化算法差很多,此外由于非模糊空间下的标准文化算法存在任务失效的情况,因此其平均适应度曲线不具备可比性。从表 4-3 可以看出,非模糊空间下的标准文化算法存在个别任务失效的情况,这是

由于此时算法搜索的空间过于庞大，且随机搜索依赖于更好的初始化表示和更多的迭代次数。因此，空间模糊化能够较大程度的提高关键路径点的关注度，减少随机搜索的搜索空间范围，有效提高协同航迹规划的性能。从总执行时间上也可以看出，改进后的 MODE 文化算法的执行时间要优于其他基于 GA 的文化算法。




图 4-8 MODE 与标准文化算法收敛曲线比较

Fig 4-8 Compare the convergence curves of MODE-CA and standard CA


表 4-3 规划算法的任务代价和执行时间比较

Tab 4-3 The task cost and execution time comparison of planning algorithm

	标准文化算法(最优代价)	非模糊空间标准文化算法(最优代价)	DE文化算法(最优代价)
任务1	142.5041	190.4987	135.3138
任务2	201.6525	257.1273	193.1318
任务3	168.1724	165.2901	158.6844
任务4	220.4687	无效	206.3204
任务5	226.2026	无效	219.6355
任务6	171.3782	173.1950	165.1613
任务7	142.8922	无效	134.3619
任务8	210.6500	223.6619	200.8816
任务9	137.0055	无效	130.1443
任务10	186.5900	无效	170.3513
总执行时间s	1245.9000	1341.4000	720.1006

4.6.4 航迹平滑效果与其他策略对比分析

用反求控制点的三次B样条曲线平滑协同航迹,采用N>M模型进行验证,设10架次UAVs打击6个目标点,并分别应用三种不同类型的变异策略与混合的新策略进行比较。实验结果如图4-9和表4-4所示:



(a) 平滑航迹的仿真结果 (b) 平滑航迹的控制点 (c) 不同进化策略的收敛曲线

图 4-9 MODE 与标准文化算法收敛曲线比较

Fig 4-9 Simulation results and convergence curves

图4-9(a)显示了平滑航迹的仿真结果,表明我们的方法可以在复杂的三维空间中对规划好的航迹进行有效的平滑处理,平滑的结果满足多个任务协同的需要,并且不会因为拟合产生的偏离落入威胁区。在图4-9(b)中,蓝色的点是反求B样条获得的控制点 R_j ,经过这些控制点,即可获得通过关键路径点的平滑B样条航迹曲线。图4-9(c)描述了不同进化策略对算法收敛的影响,从中可以看出,本章采用的混合策略具有较好的收敛效果,能够找到更好的解。

表 4-4 比较不同策略的任务代价和总运行时间

Tab 4-4 The task cost and total execution time comparision of different stargeies

任务	MODE Strategy	DE/rand/1	DE/best/2	DE/rand to best/1
Uav1	155.63	161.17	157.09	156.28
Uav2	196.62	204.81	197.18	197.45
Uav3	159.34	163.77	160.53	163.38
Uav4	150.33	149.29	151.22	151.99
Uav5	220.95	233.44	222.64	223.55
Uav6	168.36	164.12	171.14	171.89
Uav7	211.81	222.86	217.12	222.81
Uav8	205.08	212.88	203.41	206.69
Uav9	126.63	126.50	126.73	129.80
Uav10	170.27	176.53	170.44	170.78
总执行时间s	599.04	613.28	610.86	611.73

表 4-4 列出了各个任务采用不同的策略搜索获得的任务代价值和总的运

行时间，可以看出本章采用的策略在运行时间上也低于其他算法，因此证明改进的策略能有效提高算法的效率和搜索能力。

4.7 本章小结

本章提出了一种基于空间模糊表示的文化算法，用来求解三维环境下 MUAS 协同航迹规划问题。该方法首先定义了三种基于空间环境信息的模糊隶属度计算方法，并模糊化表示三维空间的网格点，形成空间模糊子集；其次采用文化算法对航迹规划问题进行整体建模，用空间模糊信息、历史信息和协同信息共同组成算法的信念集，剪枝航迹规划的搜索空间、保证种群多样性、并为深入搜索提供了全局信息；在种群集上改进差分进化算法，使其适用于求解航迹规划问题，并将获得的新个体按比例输入历史信息库，为之后的搜索积累更丰富的环境知识和协同知识，使搜索过程中的有效信息能够获得保留，降低搜索的盲目性；最后，本章还针对多机协同避碰问题，引入了协同信息量的计算，在适应度函数中加入协同信息量的影响，提高了航迹个体处理协同避碰的能力。

此外，为了使航迹规划的结果能够平滑可飞，本章还结合三次 B 样条曲线和反求控制点的三次 B 样条曲线优化三维空间中的协同航迹，使规划后的航迹能够较好的拟合于关键路径点，在保证航迹有效的前提下，减少了路径上的拐点和无效机动，平滑的航迹确保了 UAV 执行任务的可飞行性。

第5章 动态环境下多阶段多机协同航迹重规划方法

5.1 引言

在战场环境已知的情况下,可通过离线规划获得多机协同的一组全局最优航迹集合,所有的 UAVs 都按照集合中自身的预定航迹执行任务。整体任务被分解成多个子任务,UAVs 则通过互相交换信息和共享资源来实现协同^[59]。全局航迹规划为 MUAS 执行任务提供了重要的依据。但是,由于 UAVs 执行任务时的环境可能是动态变化的,离线的全局航迹往往会错误引导 UAVs 进入动态改变的威胁区域,从而导致任务失败。因此,为了保证 UAVs 飞行的安全性并降低任务失效概率,还需要在执行任务期间对航迹进行在线的规划。在线航迹规划比离线航迹规划具有更高的难度,但也具有更重要的意义,它是确保飞行安全和任务成功的关键。

在线航迹规划分为实时航迹规划和航迹重规划两类问题,其中实时航迹规划是在环境完全未知和无全局信息指导的空间中进行航迹探索和目标跟踪的问题;而航迹重规划则是根据已知的全局规划结果,通过采集更新环境信息的改变(如雷达的移动或新威胁的出现等),对全局航迹中失效的部分进行重新规划来调整已有飞行航迹,保证 UAV 能够安全完成任务的问题。实时航迹规划常根据实时探测到的有限范围内的空间变化,对 UAV 未来的状态转移进行逐步决策,该问题求解对时间依赖程度较高、成功概率较低、很难保证任务安全执行。而航迹重规划则侧重于局部问题的状态变化,通过动态处理局部失效来调整 UAV 飞行的航迹,该问题求解的难易程度取决于重规划的时机和规模,相对于实时航迹规划更容易实现。此外,由于在线航迹规划是随时间动态改变的问题求解过程,且均满足无后效性,所以以上两类问题都可以归结为动态规划的问题,因此也可利用约减的实时航迹规划方法来处理局部重规划的问题。

多机协同航迹重规划是指在已有全局航迹的基础上,根据当前执行任务环境的变化,适时调整多条航迹或在局部快速重新规划多个子航迹的问题,新规划的航迹与原航迹保持有效衔接的同时,还要满足新出现的局部环境改变、新威胁产生、约束调整和协同保持等条件限制要求,同时还要考虑时间演变的影响和多机之间协同的性能。因此是一个具有协同约束限制的多目标、

多阶段动态规划问题^[80]。多机协同航迹重规划是任务规划问题的关键技术之一，它是确保任务规划执行成功与否的重点，是对全局规划的有力补充和调整。合理的局部重规划可以降低系统的能耗、提高执行航迹的准确适用性、并保证协同的实时性。然而，因为任务空间变化的不确定性和复杂性，单机的航迹重规划就已经是较难处理的问题，多机协同的航迹重规划就更为困难。虽然已有很多方法针对 UAV 在线重规划问题进行求解，如蚁群算法和随机搜索树法^{[80][79][86]}等，但这些方法主要针对单机重规划展开研究，而对 MUAS 的重规划，仍有诸多难点需要进一步解决，主要在于以下几个方面：

1) 通常采用的多机协同航迹重规划方法，效率较低，只有降低重规划的复杂性，才能确保重规划的有效性。如何有效约减重规划的规划空间，使规划空间能够在满足协同约束的基础上按任务划分成多个任务子空间，那么重规划在更新时，就会尽可能小的浪费有限的资源，以确保在有效的时间窗口内，重规划多机协同的动态航迹。

2) 空间模糊子集上的某个关键路径备选点，除了与某个任务有直接的隶属关系外，如果同时考察该点对所有任务的隶属程度，就可以得出该点是否适合用来进行协同的相关性。因此，如何表示空间某个点与协同任务的相关性，是更深入的扩展空间点和空间结构表示的关键和难点所在。在环境变化时，协同相关性能够有效降低重规划时多航迹协同的复杂性，提高协同重规划的效率。

3) 如何处理重规划的效率和航迹优化之间的平衡。多机协同航迹重规划的结果应更注重快速有效的可行性，而不是全局或局部的最优，因此可以从多目标优化的角度考虑重规划的 *Pareto* 占优解，而不是具体的全局最优解。全局规划的方法虽然能保证重规划后航迹的最优，但效率较低，因此很难应用于重规划阶段。

在上一章，我们已针对全局规划建立了基于模糊集的三维空间表示方法和多约束多目标优化的协同航迹规划算法，并获得了全局最优的航迹组。本章在此基础上，继续深入研究当环境中威胁区域产生移动或者新增威胁区域时，多机协同的局部航迹重规划问题。为有效解决此问题，提出了一种基于协同模糊 C 均值聚类划分规划空间的多阶段多 Q 学习协同航迹重规划方法。该方法首先对当前时刻的飞行状态、环境变化、航迹失效等情况进行监测；然后在原有模糊空间表示的基础上，增加了空间点对应各个任务之间的协同相关性描述，并由此构建了空间模糊协同矩阵；接下来在模糊协同空间的各

步长面上进行模糊 C 均值聚类, 根据任务属性和协同相关性将空间中的点划分成适应不同任务的分类; 最后, 在每个任务的状态空间应用多阶段多 Q 学习方法, 迭代优选最优动作策略, 生成多机协同的重规划航迹。

5.2 MUAS 协同航迹重规划任务模型


5.2.1 重规划问题描述和难点分析

在离线航迹规划阶段, 已经用基于模糊空间表示的文化算法规划出一组可行的全局协同航迹, 然而, 当 UAVs 从初始位置出发向着执行目标飞行时, 该区域内的雷达威胁并不是固定不变的, 它们会以一定的速度向着未知的方向移动, 此外还有可能出现新的雷达威胁, 因此, 部分航迹会陷入动态变化的威胁区域, 具有被雷达侦测打击的风险。所以在任务执行阶段, 必须对可能失效的航迹段进行重新规划, 以保证航迹的安全性。航迹局部重规划的问题可描述为与时间相关的多阶段、多目标协同优化问题。在此过程中, 需要每个任务以全局航迹 $L_k = \{s_k, p_{k1}, \dots, p_{ki}, \dots, t_k\} \quad k \in [1, N]$ 为依据, 在时刻 t 对关键路径点进行不断的调整和修正, 确保 UAVs 执行任务时能够响应环境中威胁区域的变化, 始终保持航迹的安全可靠性、协同性和 *Pareto* 最优性。重规划的航迹可表示成时间 t 的函数, 即:

$$L'_k(t) = \{s_k, p_{k1}(t), \dots, p_{ki}(t), t_k\} \quad k = 1, 2, \dots, n \quad (5-1)$$

其中, 第 k 个任务执行航迹上的关键路径点 p_{ki} 随时间 t 改变位置, 确保航迹执行阶段 UAVs 能够绕过变化的威胁, 同时还保持与其他任务的协同。考虑时间 t 的变化因素, 该问题是一个不确定条件下序贯决策的多目标优化问题。在重规划的过程中, 按一定时间间隔将实时问题转换为多阶段问题, 则每一阶段的规划都是建立在上一阶段重规划的航迹基础之上, 全局航迹随各个阶段的状态迁移逐渐调整。随着 UAV 飞行位置的前进, 之前的航迹调整不会影响之后的重规划, 而重规划的空间范围不断缩小。因此, 该问题可从动态规划角度展开研究, 其多阶段动态重规划的过程如图 5-1 所示。

在图 5-1 中, 灰色区域表示变化或新产生的威胁区。T1...T3 表示不同阶段对应的重规划航迹段。从图 5-1 中可以看出, 重规划的可行航迹是各个阶段规划后的航迹段的组合。多阶段重规划问题的难点在于合理的规划时间范围和规划效率两个方面的制约。如果用全局规划的方法, 很可能在某个时间段 t 内, 没等规划结束就已经进入下一个阶段了。这样重规划的结果就变得



(a) T2 时刻的动态重规划航迹

(b) T3 时刻的动态重规划航迹

(a) The dynamic path re-planning of T2

(b) The dynamic path re-planning of T3

图 5-1 多阶段航迹动态规划过程示意图

Fig 5-1 The schematic drawing of multi-step dynamic path re-planning

毫无意义。因此只有用动态的规划方法，边执行边规划，即使当前阶段没有真正规划出达到目标点的完全可行航迹（如图中虚线所示），但是先期已经获得了一部分重规划的结果，这个结果可以有效指引当前 UAVs 协同飞行。而下一个阶段 $t+1$ 将会在 t 之后所处的位置和目标点之间进行新的动态规划。

由此可见，在离线阶段采用的进化规划方法，很难适用于重规划，即使减少了种群的规模和迭代次数，保证可以在时间段 t 内获得可行解，但是这样的解中也必然存在部分无用的规划，而且规划过程中 UAV 存在无新信息指引的运动危险期。相反，基于启发式的动态规划思想，可以有效解决边走边规划的问题，规划范围小、速度快、阶段跨越过程中不会盲目行动，但是由于常用的动态规划方法存在“维数灾难”的问题，因此很难用于多机协同的航迹规划。如何有效降低多机协同的任务规划空间，避免“维数灾难”，是多阶段多机协同航迹重规划的难点所在。

5.2.2 基于 CFCM 和多 Q 学习的重规划模型

为了在多机协同的重规划过程中快速动态重规划环境改变后的有效航迹，解决可能存在的“维数灾难”等问题。本章首先应用协同模糊 C 均值聚类(Cooperative Fuzzy C means, CFCM)^[125]对多任务空间进行合理划分，有效约减任务搜索的状态空间，在此基础上，扩展 Q 学习算法，将空间模糊集作为学习回报率进行快速规划，可以有效解决三维环境下多机协同的在线航迹重规划问题。

Q 学习算法由 Watkins 提出，是一种无模型的异步动态规划方法^[128]。该方法将动态规划与学习机理相互结合，以求解具有延迟回报的多阶段优化决

策问题。Q 学习有效克服了动态规划的“维数灾难”^[129]。它强调在与环境的交互中学习，不需要环境的模型信息，因此可以求解模型未知的多阶段动态规划决策问题^[130]。实验已经证明 Q 学习算法对于马尔科夫决策过程是收敛的^{[99][129]}。因此将其应用于未知环境下的 UAV 在线航迹规划是非常合适的。

然而 Q 学习方法与其他动态规划方法一样，仍然存在“维数灾难”的问题，因此要将其应用于多机协同的在线重规划问题，就必然要优化约减协同任务的搜索空间和表示形式，从而保证算法能够有效处理动态改变的环境

根据之前的研究，将离散的空间网格点表示成与任务和威胁相关的模糊集，能够有效提高空间点的被关注程度。在此基础上，利用协同模糊 C 均值聚类算法^[125]进一步探查多维数据的结构，可以找到合理的分类空间，适合环境变化时多机协同的状态空间的结构划分。因此，利用 CFCM 算法将空间的点集划分成具有协同属性的不同任务类别，并将这些类别作为多 Q 学习时各任务独立安全的状态空间，可以有效约减搜索范围，提高协同规划的效率。此外，空间模糊集表示了各个空间点对系统任务的隶属程度，因此将模糊集作为多 Q 学习的回报矩阵，也可提高学习搜索的针对性，有效改善强化学习初期的盲目性和随机性。本章将这两种方法有机结合，可以提高多机协同航迹重规划的效率，其规划模型的流程如图 5-2 所示。




图 5-2 协同航迹重规划流程图

Fig 5-2 The flow chart of cooperative path re-planning

5.3 基于 CFCM 聚类的多任务状态空间划分

5.3.1 协同相关系数和模糊协同矩阵

为了能够更好的处理多个任务之间的协同，除了考虑空间点对所有任务的隶属度评价外，还可以从任务协同的角度分析空间点作为某个任务关键路径点的可靠性。协同聚类方法用协同系数表示不同分类的相似性程度，可以更好的区分具有协同关系的分类^[125]。因此在多机协同航迹规划时，也可以通过引入协同属性的相关系数，来更具体的描述空间中某个点作为任务关键路径点的协同性能。

MUAS 中多机间的协同主要取决于 UAVs 空间和时间上的相关性程度。协同相关性可由当前路径点执行不同任务的隶属度相似性获得，当某个点执行某个任务的隶属度远高于其他任务时，这个点就仅适合作为该任务的关键路径点，其他任务选择该点的几率远低于当前任务，因此该点不会造成多个任务的竞争，即认为该点的空间协同性能较高；时间协同的相关性则可由当前路径点执行不同任务的时间差来进行比较，当某个点执行某个任务的时间与执行其他任务的时间差距较大时，该点同样仅适合时间较短的那个任务，而不会同时满足多个任务的需要，造成多任务的竞争，因此该点的时间协同性能较高。由此分析，可以定义空间路径点的空间和时间协同相关系数，以增强选择路径点时对协同性能的衡量，协同相关系数定义如下：

定义 5.1(空间隶属度协同相关系数):考察空间中某点 p 对不同任务的隶属度集合 $\{\tilde{\mu}_1, \tilde{\mu}_2, \dots, \tilde{\mu}_i, \dots, \tilde{\mu}_j, \dots, \tilde{\mu}_k, \dots, \tilde{\mu}_n, i \neq j\}$ 的关系，其中隶属度的差 $|\tilde{\mu}_i - \tilde{\mu}_j|$ 可以反映出该点对任务 i 和任务 j 的协同相似性。当差值较大时，该点适合执行 i 任务而不适合执行 j 任务，因此有利于任务 i 与 j 的协同；而当差值较小时，该点同时适合执行任务 i 和 j ，因此不利于协同。由于隶属度集合中的最大值被关注的程度最高，因此协同相关系数可以通过最大值与其他隶属度值的差来获得，即：

$$\beta_1^{ki} = \min \left(\max \left(\frac{\tilde{\mu}_{ki}}{\sum_{i=1}^n \tilde{\mu}_{ki}} - \left(\frac{\tilde{\mu}_{kj}}{\sum_{i=1}^n \tilde{\mu}_{ki}} \right) \right), i, j = 1, 2, \dots, n, i \neq j \right) \quad (5-2)$$

定义 5.2(最小时间差协同相关系数):与定义 5.1 相似，协同最小时间差相关系数可由空间某点执行不同任务的时间相似性获得，因此在获得该点全

部执行时间之后，可以定义最小时间差协同相关系数为：

$$\beta_2^{ki} = \min \left[\max \left(\frac{t_{ki}}{\sum_{i=1}^n t_{ki}} \right) - \left(\frac{t_{kj}}{\sum_{i=1}^n t_{ki}} \right) \right], \quad i, j = 1, 2, \dots, n, i \neq j \quad (5-3)$$

定义了空间点的协同相关系数后，规划空间中的点可以扩展为用坐标位置、任务隶属度值和协同相关系数共同表示的形式，这样的表示使规划空间中路径点的信息更加完整，关键路径点的被关注度更强，协同分类的依据更加明显。因此，可建立规划空间点集的模糊协同矩阵为：

$$\mathbf{s} = \left\{ \begin{array}{ccc|ccc|cc} \overbrace{x_1 \ y_1 \ z_1}^{a1} & \overbrace{\tilde{\mu}_1^1 \ \tilde{\mu}_2^1 \ \cdots \ \tilde{\mu}_n^1}^{a2} & \overbrace{\beta_1^1 \ \beta_2^1}^{a3} \\ x_2 \ y_2 \ z_2 & \tilde{\mu}_1^2 \ \tilde{\mu}_2^2 \ \cdots \ \tilde{\mu}_n^2 & \beta_1^2 \ \beta_2^2 \\ \vdots \ \vdots \ \vdots & \vdots \ \vdots \ \vdots & \vdots \ \vdots \\ x_k \ y_k \ z_k & \tilde{\mu}_1^k \ \tilde{\mu}_2^k \ \cdots \ \tilde{\mu}_n^k & \beta_1^k \ \beta_2^k \end{array} \right\} \quad (5-4)$$

其中， $\mathbf{s}$ 表示规划空间中的栅格点集合， $a1$ 为点的空间坐标值， $a2$ 为该点执行各个任务的隶属度值， $a3$ 为该点的协同相关系数。从该矩阵中可以看出，经过处理的空间点增加了更多与协同相关的信息，因此如果用聚类的方法对当前的模糊协同矩阵进行分类，就可以把最符合某个任务特征点归结为一类，从而更有效的进行路径点的决策选择。多个分类间保持了良好的协同性，并互相独立，因此能够在各自的分类空间中更快的规划出合理的协同航迹。此外，从 Q 学习算法的角度分析，各个分类中的点都是最适合该类任务的可行路径点，因此可将这些点作为算法搜索航迹过程中的状态空间。

5.3.2 聚类空间优化和初始中心设定

在 $t+1$ 时刻对空间聚类时，首先更新当前空间的威胁区域信息集合：

$$Tp(t+1) = \begin{cases} [Tp_{center}(t) + D_{rand} \cdot v(t), R] \\ [Tp'_{center}(t+1), R'] \end{cases} \quad (5-5)$$

式中 D_{rand} 表示威胁区随机移动的方向， $v(t)$ 为移动的速度， $Tp'(t+1)$ 和 R' 表示新增的威胁。根据更新的空间信息，对当前威胁区覆盖的范围和地形之下的点，设置其模糊和协同信息为负值，在聚类时首先摒除这些点的影响。

然后，聚类结果是否能够合理表示航迹关键路径点的划分，与空间点样本集的选取有着密切的关系。当空间点远离所有任务时，其对所有任务分类

的平均影响，会削弱其他空间点的任务分类关系，因此要将这些与任务关系较弱的点进行剔除，以优化聚类的样本空间。因此样本选取函数为：

$$x' = \{x | d_{jv_i} \leq \delta\}, \quad j=1,2,\dots,k, i=1,2,\dots,n \quad (5-6)$$

其中 d_{jv} 为空间点 j 到第 i 个任务聚类中心的距离，该距离不超过限定范围 δ 。

因此，可设定当前已规划的协同航迹关键路径点为初始聚类中心，从当前航迹关键路径点出发进行聚类，可以快速响应当前环境改变对类别的扰动影响，当环境改变不明显时，聚类的结果也不会受随机搜索的影响产生过度的改变，因此，利用已有的多个航迹关键路径点为初始聚类中心，能够使聚类效果更好。

5.3.3 基于模糊协同矩阵的 CFCM

在聚类中引入协同关系的度量，可以有效提高聚类的分类率^[129]。因此，利用模糊协同矩阵，在规划空间中对各步长面上的栅格点进行 CFCM 聚类，使该步长面上的点按隶属度和协同相关性进行分类，可产生适合不同任务协同的类别划分。其中数据样本为空间点的坐标集合 $S(a1)$ ；划分任务类别的隶属度可由 $S(a2)$ 归一化获得，用 $S(a2)$ 作为任务分类的隶属度，可直接反映出空间点与任务的对应关系，且归一化后满足条件：

$$\sum_{i=1}^n \mu_i(x_j) = 1, \quad j=1,2,\dots,k \quad (5-7)$$

结合协同相关系数的协同目标函数为：

$$J_b(U, v) = \sum_{j=1}^k \sum_{i=1}^N (\tilde{\mu}_{ji})^b (d_{ji})^2 + \sum_{m=1}^M (\beta_m) \sum_{j=1}^k \sum_{i=1}^N (\tilde{\mu}_{ji} - \tilde{\mu}_{ji})^b (d_{ji})^2 \quad (5-8)$$

式中的第二项为空间和时间协同目标项之和， d_{ji} 是空间点的欧氏距离，用来度量样本 x_j 与第 i 类中心之间的距离， β 是协同相关系数。

因为已知全局航迹和上一时刻 t 重规划的航迹，所以可获得航迹在不同的步长面上的交点，采用这些交点作为初始的聚类中心，能够保证分类更符合重规划时航迹的需求。因此，可以确定初始聚类的中心和类别数，更快速的对空间点集进行划分。此外用任务隶属度矩阵 $S(a2)$ 作为初始的划分矩阵 u ，并在 u 更新的过程中保留初始隶属度的影响，也是提高分类准确性的方法，因此设定划分矩阵的更新函数为：


$$\begin{cases} \mathbf{u}' = \frac{1}{\sum_{i=1}^N (\frac{d_{ik}}{d_{lk}})^{\frac{2}{b-1}}} \\ \mathbf{u}_{ik} = s \cdot \mathbf{U} + (1-s) \cdot \mathbf{U}', \quad 0 \leq s \leq 1 \end{cases} \quad (5-9)$$

其中，新的划分矩阵由原有隶属度和更新的隶属度按比例系数 s 进行组合。

协同聚类中心更新的方法为：

$$v_{ji} = s' \frac{\sum_{j=1}^k (\mu_{ji})^b x_{ji}}{\sum_{j=1}^k (\mu_{ji})^b} + (1-s') \frac{\sum_{j=1}^k \sum_{m=1}^M (\beta_{mi})^b x_{ji}}{\sum_{j=1}^k \sum_{m=1}^M (\beta_{mi})^b}, \quad 0 \leq s' \leq 1 \quad (5-10)$$

式中第二项为协同相关系数对聚类中心的影响。根据式(5-9)和式(5-10)反复修改聚类中心和划分矩阵，当算法收敛时，就得到了符合隶属度分布和协同相关性的任务空间类别划分。最后，将各个步长面上的分类组合在一起，就可以在整个规划空间获得各个任务的重规划状态空间，如图 5-3 所示：



(a)某步长面上的聚类

(b)任务空间的聚类划分

图 5-3 CFCM 重规划的聚类空间和划分

Fig 5-3 Clustering space based on CFCM re-planning and classification

5.3.4 CFCM 的参数选择准则

模糊 C 均值聚类算法的有效性，很大程度上受到类内距离 $\|v_i - x_j\|$ 、类间距离 $\|v_i - v_j\|$ 和隶属度 $\tilde{\mu}_{ij}$ 的影响^[125]。而改进后 CFCM 的有效性还要受到

协同相关系数 $\beta_{mi} \|\tilde{\mu}_i - \tilde{\mu}_j\|$ 的影响。根据类内紧凑度和类间分离度的比例，可以定义 CFCM 的有效性指标函数如下：

定义 5.3: 设给定聚类类别 C 、聚类中心 V 和隶属度矩阵 U ，聚类的类内紧凑度为 $\sum_{i=1}^C \sum_{j=1}^n \mu_{ij} \|v_i - x_j\|^2$ ，类间分离度为 $\min_{i \neq j} \|v_i - v_j\|^2$ ，协同相关度 $\sum_{i=1}^C \sum_{m=1}^M \beta_{mi}^2$ ，则 CFCM 聚类的有效性指标 $H(U, V, C)$ 定义如下：

$$H(U, V, C) = \frac{\sum_{i=1}^C \sum_{j=1}^n \mu_{ij}^m \|v_i - x_j\|^2 + \frac{1}{C} \beta_{mi} \sum_{i=1}^C \sum_{j=1}^n \|\mu_i - \mu_j\|^2}{\min_{i \neq j} \|v_i - v_j\|^2} \quad (5-11)$$

$H(U, V, C)$ 是基于类内紧凑度与类间分离度的比例，是模糊集理论中比较常用的有效性衡量标准，在式 (5-11) 中引入协同相关度惩罚函数 $\frac{1}{C} \beta_{mi} \sum_{i=1}^C \sum_{j=1}^n \|\mu_i - \mu_j\|$ ，提高协同关系对有效性的影响。根据这一指标，最小的指标值指示出最优的分类，从而具有最好的聚类效果。

根据 CFCM 算法的有效性指标，可以给出算法参数选择的准则为：

准则 5.1: 在已知分类类别数量 n 时，当能够给定 n 个初始聚类中心，且这 n 个中心为聚类可依据的当前类别最优位置时，CFCM 在聚类后产生的新分类具有最好的聚类效果。

证明，如果提前已知 n 个任务大致的区别和这些区别所处的核心 s ，那么根据式 (5-11) 可知，这些核心 s 所影响的分类之间具有最低的 $H(U, V, C)$ ，在此基础上进行数据的新聚类，聚类中心从 v_i 到 v'_i 的变化过程中，类间距离 $\|v'_i - v'_j\|$ 最大，类内紧凑度 $\|v'_i - x_j\|$ 和协同相关度 $\|\mu'_i - \mu'_j\|$ 最小，因此 $H(U, V', C)$ 始终保持最小，从而保证分类效果最好。

根据准则 5.1，利用栅格面上已知的协同航迹关键路径点作为聚类的初始中心，可以保证关键路径点的类间距离最大，类内紧凑度和协同相关度最小，因此能够保证聚类效果接近最优，可以获得较好的关键路径点任务分类。综上所述，本章采用的基于模糊 C 均值聚类的多任务状态空间划分算法的流程如算法 5-1 所示：

算法5-1 多任务状态空间划分的CFCM算法

Alg 5-1 A CFCM algorithm for multi-task state space clustering

输入： 样本集 C ，幂指数 b ，聚类数 n ，迭代次数 G
输出： 相似分类矩阵 U ，聚类中心，聚类集

01： 初始化相似分类矩阵 U ; /*初始化*/
02： 根据隶属度计算归一化相似分类矩阵： $\sum_{i=1}^n \mu_i(x_j) = 1, j = 1, 2, \dots, k$;
03： 初始化聚类中心 $Center$;
04： **For** $i=1$ to G **do** /*聚类操作*/
05： **For** $j=1$ to $size(Center)$ **do**
06： 根据已知的 $Center$ 计算距离 d_{ij} ;
07： 计算各个点的协同相关系数;
08： **End for**
09： 根据公式(5-9)更新分类矩阵 U ;
10： 根据公式(5-8)计算协同目标函数 $J_b(U, v)$;
11： 根据公式(5-10)更新当前的聚类中心 v_{ji} ;
12： **End for**

5.4 基于 CFCM 的多 Q 学习航迹重规划

5.4.1 环境更新和重规划区域设定

环境信息的更新和重规划区域的设定，是航迹重规划的前提。设定合理的重规划区域，可以有效降低求解的冗余，突出局部问题的特征。因为任务执行是随时间变化的，因此可以利用多阶段的方法降低实时变化的求解难度，将 UAV 打击目标的任务分成若干个阶段，在每一个阶段检测出需要重规划的区域，进行局部的协同航迹重规划，即可方便快速的处理在线产生的航迹失效问题。

按分段数 k 求取每个阶段的时间 t_k ，则航迹重规划就可在各个阶段 $t_k = \{t_1, t_2, \dots, t_k\}$ 中执行，每个阶段完成后，更新重规划的航迹和时间，设定分段数 $k=k+1$ ，并继续执行新阶段 t_{k+1} 的重规划。在当前阶段 k ，环境的更新包括 UAV 飞行位置的确定，威胁区域的位置和数量的确定，以及当前位置到目标点的上一阶段已知航迹。

此外，还可以在更新时探测更具体的失效航迹段范围，以进一步优化重规划区域的选择，提高重规划的针对性。即在更新区域时，计算已知航迹上所有路径点的可行程度或模糊隶属度，如果某个路径点落入新的威胁区导致可行程度变为 0，或新的模糊隶属度远小于上一时刻的隶属度分值，则该点处的航迹就需要进行重规划。把所有需要重规划的点组织起来，就是当前时刻该航迹重规划的区域。然而，当环境变化复杂时，这样的重规划区域可能

存在多个,从而导致求解的繁琐和困难。为简化计算,可以在 t 时刻从首个变化较大的路径点到目标点之间的全部区域作为重规划区,以降低求解难度。

5.4.2 基于协同模糊回报函数的 Q 学习

求解在线协同航迹重规划问题,需要快速有效的动态规划方法,以适应随时间 t 不断变化的环境;而增强学习方法中的 Q 学习算法是对即时差分(TD)学习和动态规划的联合和扩展,是在即时 TD 学习的基础上,学习折扣期望的增强回报价值,因此其具有不依赖于模型、在线更新策略的优点^[130],适合解决在线的航迹重规划问题。

Q 学习通常基于马尔科夫决策过程(Markov Decision Process, MDP)的理论框架。因此可以利用离散的、有限状态的马尔科夫决策过程对 Q 学习进行建模。Q 学习过程的马尔科夫模型由以下定义给出:

定义 5.4: Q 学习过程可由一个五元组 $\{S, A, P, r, \gamma\}$ 构成,其中: S 为所有可能状态组成的状态空间; A 为所有可能动作的行为空间; $P: S \times A \rightarrow [0,1]$ 为状态 s 时执行动作 a ,从而转移至 $s+1$ 的状态转移概率; $r=r(s,a,s+1)$ 是回报函数,表示该状态转移过程的优劣程度; $\gamma \in [0,1]$ 是折扣率。动作选择的随机策略 $\pi(a|s) = p(a|s)$ 。

根据 Q 学习算法特征,设定 UAVs 可行的空间路径点集为规划的状态空间 $S=(s_1, s_2, \dots, s_t)$,表示 UAVs 飞行时经过的全部环境状态;动作集 $A=(a_1, a_2, \dots, a_t)$ 表示 UAVs 经过某个路径点时可能的机动行为,该行为产生的结果是从当前步长面上的关键路径点到下一步长面上可能的关键路径点对应的集合; $T(s_t, a, s_{t+1})$ 是当前状态到下一状态选择动作 a 的状态迁移概率; $R=(r_1, r_2, \dots, r_t)$ 则表示执行行为 a 产生的回报或奖惩。当 UAV 从当前状态或空间位置向下一个状态或下一位置运动时,确定一个优化策略 π ,则状态 s 的值是:

$$V^\pi(s_t) = r(s_t, \pi(s)_t) + \gamma \sum_{s'} T(s_t, \pi(s), s_{t+1}) V^\pi(s_{t+1}) \quad (5-12)$$

其中第一项是 UAV 执行动作时得到的回报奖励,第二项是根据概率 $T(s_t, a, s_{t+1})$ 迁移到下一状态。根据动态规划(DP)理论,至少存在一个最优的策略 π^* ,其总折扣期望的回报最大。考虑算法的不确定性和目标达成期望,根据 Bellman 最优性方程,可定义选择最优策略 π^* 时的状态值函数和行为值函数分别为:

$$V^*(s_t) = \max_{a_t} E[r(s_t, a_t) + \gamma \sum_{s'} T(s_t, a_t, s_{t+1}) V^*(s_{t+1})] \quad (5-13)$$

$$Q^*(s_t, a_t) = E[r(s_t, a_t) + \max_{a_{t+1}} \gamma \sum_{s'} T(s_t, a_t, s_{t+1}) Q^*(s_{t+1}, a_{t+1})] \quad (5-14)$$

其中 $V^*(s_{t+1})$ 是下一时刻状态效用的值, $r(s_t, a_t)$ 是回报奖励。Q 学习的目标就是要迭代更新 Q 值, 以逼近最优策略选择, Q 值的更新公式为:

$$Q(s_t, a_t) = (1 - \alpha_t) Q(s_t, a_t) + \alpha_t (r(s_t, a_t) + \gamma \max_{a_{t+1}} [Q(s_{t+1}, a_{t+1})]) \quad (5-15)$$

其中 γ 是折扣系数, α_t 是随时间 t 不断衰减的学习率, 且 $0 \leq \alpha_t \leq 1$ 。在航迹重规划时, Q 值的状态空间是随时间 t 动态改变的; 在每一次迭代循环中都要观测 $t+1$ 时刻的状态和已更新的全部行为, 根据 t 时刻和 $t+1$ 时刻的折算累积回报, 并更新当前状态一行为对的值函数估计 $Q(s_t, a_t)$, 从而选择当前位置上最优的关键路径点策略, 最终获得重规划的可行航迹关键路径点集合。当状态 s 的行为可无限次执行, 且当 α_t 满足条件(5-16)时, Q 值将以概率 1 收敛到 Q^* 。

$$\begin{cases} \sum_{t=0}^{\infty} \alpha_t(s, a) = \infty, & 0 \leq \alpha_t(s, a) \leq 1 \\ \sum_{t=0}^{\infty} \alpha_t^2(s, a) < \infty, & 0 \leq \alpha_t(s, a) \leq 1 \end{cases} \quad (5-16)$$

此外, 虽然 Q 学习算法是无模型的, 在计算时不需要预先获知回报函数 $r(s, a)$, 然而缺乏先验知识的 Q 学习算法在探索过程中具有很大的盲目性和随机性, 尤其是在学习初期容易陷入局部最优。因此依据先验知识设定 Q 学习的回报函数, 可以有效降低学习搜索的盲目性。

在航迹协同重规划问题中, 某一任务对应的规划空间中的点集的隶属度值和协同相关系数可以有效反映出航迹规划搜索时的被关注程度, 因此可将其组合在一起, 作为 Q 学习的回报值。设定该回报值后, 当 Q 学习算法在某关键路径点 S_t 选择行为 a 转移至下一步长面上的关键路径点 S_{t+1} 时, 下一步长面上具有较高隶属度和协同相关系数的点被选择的概率就高, 由此可以降低学习的盲目性, 有效提高搜索的效率。因此, 结合空间点的协同模糊矩阵, 可以设定回报函数为协同模糊矩阵的形式, 且随矩阵的更新而更新, 即:

$$\begin{cases} r(s_t, a_t, s_{t+1}) = \left[\omega_1 \tilde{\mu}_i^j(t+1) + \omega_2 \sum_{m=1}^M \beta_m^j(t+1) \right], & i=1,2,\dots,n, j=1,2,\dots,k \\ r(T) = \infty \end{cases} \quad (5-17)$$

其中, ω_1 和 ω_2 是和为 1 的加权系数, 该值可根据经验进行设置; $r(T)$ 表示任务目标点处的回报, 该回报设置为比其他位置大很多的值或 ∞ 值, 以确保 Q 学习搜索能够最终找到目标位置。图 5-4 中展示出了在 Q 学习航迹重规划时, 采用协同模糊矩阵为回报函数对航迹搜索过程的影响, 其中红色栅格区域为威胁区, 彩色线为 Q 学习迭代过程中搜索的位置, 红色实线为最优结果。图中可以看出, 采用模糊协同矩阵作为回报函数, 可以有效优化搜索性能, 降低搜索初期的盲目性。




图 5-4 回报矩阵对学习的影响

Fig 5-4 Influence of return matrix on learning

5.4.3 改进的状态转移动作集设定

传统的 Q 学习算法是在网格上利用不同方向上的步长移动进行动态搜索的, 这种状态转移的动作设定简单易行, 适合于信息较全的全局空间搜索。然而, 我们根据多机协同的任务, 利用模糊 C 均值聚类对现有的规划空间进行划分, 这种划分在很大程度上约减了搜索的空间, 因此, 采用传统的步长移动作为动作集, 不但搜索效率较低, 还因为空间的不完整性和不连贯性而造成规划失败。为了解决这个问题, 使 Q 学习算法能够在约减的空间中充分进行学习, 我们根据公式(5-14)计算分类空间点集合的回报矩阵 Rew , 并根据 Rew 改进了算法的动作集设定, 保证动作执行的有效性, 使其更适合在各分

类状态空间上学习规划。改进后的动作集设定如下：

Action 1: 该动作取下一步长面上 Rew 中值最大的点，并作为状态转移后下一时刻 $t+1$ 的状态 S_{t+1} ，因此有：

$$S_{t+1} = \operatorname{argmax}(Rew(S_{t+1})) \quad (5-18)$$

Action 2: 根据当前状态 S_t ，该动作取下一时刻分类空间中 Rew 值与 S_t 的 Rew 值最接近的点，作为状态转移后的点 S_{t+1} ，即：

$$S_{t+1} = \operatorname{argmin}(\operatorname{abs}(Rew(S_{t+1}) - Rew(S_t))) \quad (5-19)$$

Action 3: 取下一时刻分类空间中与 S_t 距离最近的点，作为状态转移后的点 S_{t+1} ，即：

$$S_{t+1} = \min(D(S_t, S_{t+1})) \quad (5-20)$$

Other Actions: 传统基于步长的网格动作，如 $S_{t+1} = (x+1, y+1)$ 或 $S_{t+1} = (x-1, y-1)$ 等，这类动作使 UAV 能够在前进方向 S_{t+1} 上继续移动。

其中 Action1-3 利用空间点的协同模糊值和距离关系引导 UAV 的飞行状态转移，可以保证在约减的分类空间中获得重规划的航迹，并有效提高学习的效率。传统的位移 Action，则是对其他动作的合理补充，虽然这些动作可能会导致无法搜索到正确的位置，但是能够增加选择的多样性。

5.4.4 基于 CFCM 的多 Q 学习协同航迹重规划

对多机协同航迹重规划问题，如果所有任务都在整个空间中进行规划，则 Q 学习算法的计算空间复杂、冗余度大、不适合与其他任务协同，因此很难将其应用于多机协同的航迹重规划。

为了合理约减规划空间、降低问题求解的复杂性和提高多机协同性能，在航迹重规划时，可以首先利用 CFCM 算法对全局空间按任务归属和协同相关性进行划分，将适于协同执行某一任务的路径点集合归为一类；然后将这一集合作为该任务 Q 学习算法的状态空间，使航迹重规划在约减的空间范围内进行，并保证了各任务之间较好的协同性；最后，多个任务在各自的状态空间进行重规划，互不干扰，且可共享当前的分类信息和回报矩阵。

在分类后多任务的独立状态空间中，可采用多 Q 同时学习的方法，在同一个学习过程中，并行规划多个任务的航迹。因为 CFCM 已划分了多任务的

状态空间，且各个任务的状态空间相对独立，因此，多 Q 学习只要考虑 Q 值更新方式为多个任务的动作集合 $[a_t^1, \dots, a_t^n]$ 同时更新即可，因此多 Q 更新公式为：

$$Q(s_t, a_t^1, \dots, a_t^n) = (1 - \alpha_t)Q(s_t, a_t^1, \dots, a_t^n) + \alpha_t(r(s_t, a_t^1, \dots, a_t^n) + \gamma \max_{a_{t+1}} [Q(s_{t+1}, a_{t+1}^1, \dots, a_{t+1}^n)]) \quad (5-21)$$

根据以上分析，将 CFCM 与多 Q 学习相结合的协同航迹重规划方法，是利用 CFCM 对环境信息进行分类和更新，形成约减的多任务规划状态空间；在各状态空间中用多 Q 学习算法搜索各个任务下一时刻的最优动作策略和该策略对应的关键路径点。算法还利用当前的模糊协同矩阵作为即时回报函数，以适应环境状态的实时改变，使产生的航迹适合各种环境的变化。最终，当搜索到达任务目标时，多 Q 学习即可规划出适合环境变化的动态重规划航迹组。

多 Q 学习协同航迹重规划的执行过程，主要受折扣因子 γ 、学习率 α_t 、最大尝试次数 K 、最大步数 S 等参数的影响，折扣因子和学习率主要影响算法的搜索效率，折扣因子决定了奖励对未来影响的重视程度。折扣因子越接近 1，其对未来的重视程度越强。通常根据经验设定较长的未来奖励，即折扣因子 $\gamma=0.95$ 。当确定了折扣因子，学习率就决定了新的信息覆盖老信息的程度。为了保持算法的收敛性，还要在算法执行过程中，不断降低学习率。通常常用 $\alpha_t=0.45$ 。此外，最大尝试次数和最大步长都不要设置过小或过大。过小可能陷入局部最优，过大则严重降低算法执行的速度。

另外，本文基于协同模糊矩阵的回报函数，利用空间点的协同模糊隶属度值作为多 Q 学习动作转移时的回报评价标准，能够更精确的度量动作执行后所产生的补偿奖励，并可以在学习初期为算法提供先验知识，降低搜索的盲目性，因此有效提高了航迹规划的搜索效率。该算法具体流程如算法 5-2 所示：

从以上算法流程可以看出，CFCM 从已知的初始聚类中心出发，生成当前环境下路径点的任务分类，使不同的任务之间不会相互干扰，能够同时求解；多 Q 学习将不断更新的模糊集作为回报矩阵，在迭代中动态规划航迹，可以降低搜索的盲目性，提高重规划的效率。

算法5-2 多Q学习协同航迹重规划算法

Alg 5-2 A path re-planning algorithm of multi Q learning

输入： 初始位置 K ，目标位置 E ，威胁区 T_p ，回报集 R ，学习率 r
输出： 重规划后的协同航迹集合

```

01:  While  $t < T$  do
02:     更新当前威胁区域信息 $T_p$ ，设定重规划区域；           /*环境更新*/
03:     更新空间模糊协同矩阵 $S$ ；
04:     执行CFCM聚类，获得协同任务路径点的分类集合；
05:     根据公式(5-17)更新回报矩阵 $r(s_t, a_t, s_{t+1})$ ；
06:     While 搜索没有达到目标位置集 $[r_1(T_1), \dots, r_n(T_n)]$ 时 do           /*多Q学习算法*/
07:         Update(Q);                                           /*获取最新的Q表*/
08:         设置状态迁移动作集  $A = [a_t^1, \dots, a_t^n]$ ；
09:         For  $j=1$  to step do
10:             观察空间步长面 $j$ 的状态 $[s_j^1, \dots, s_j^n]$ ；
11:             选取并执行各任务对应的动作集 $[a_j^1, \dots, a_j^n]$ ；
12:             计算下一步长面 $j+1$ 上对应 $[a_j^1, \dots, a_j^n]$ 的状态 $[s_{j+1}^1, \dots, s_{j+1}^n]$ ，并获取回报集 $[r_j^1, \dots, r_j^n]$ ；
13:             根据 $[r_j^1, \dots, r_j^n]$ 和公式(5-21)更新  $Q(s_t, a_t^1, \dots, a_t^n)$ ；
14:             更新状态集并判断当前最优状态航迹路径点列表 $list$ ；
15:         End For
16:     End While
17: End While

```

5.5 实验结果与分析

本章实验在全局航迹规划的基础上，将离线航迹作为算法的初始输入，环境中威胁的移动和变化随时间 t 改变。实验设定的参数如表 5-1 所示。其中，威胁区域的中心位置以一定的速度按随机的方向移动，在空间中还可以随机出现新的威胁区。在此环境下，本章在 Intel core i5 四核 3.20GHz、16GB 内存的 PC 机上，利用 Matlab(R2015a)仿真软件环境进行实验，验证了算法的可行性，并分析了改进后的执行效果，具体如下：

5.5.1 协同航迹重规划可行性实验

针对重规划航迹的可行性进行实验，为了说明重规划的细节，图 5-7 中显示了利用多阶段模糊 C 均值和 Q 学习算法对单个任务进行航迹重规划的结果。其中，深蓝色的航迹是全局规划的航迹，黄色的航迹是第一阶段重规划

表 5-1 实验设定的环境参数


Tab 5-1 The parameter set of experiment

项 目	参 数
规划空间范围	180km×220km×50km
初始威胁中心	(120,70,4); (110,140,4); (52,103,30)
初始威胁半径	r1=2.3km; r2=2.6km; r3=3.0km
聚类迭代次数	200
聚类更新时间间隔	20s
Q学习迭代次数	5000
学习率	1.0~0.1
折扣系数	0.7
动作数量	6


的航迹，浅蓝色的航迹是第二阶段重规划的航迹，而红色的航迹是最后阶段获得的重规划航迹，半圆形区域为空间中运动变化的雷达威胁区，其中半透明的黄色半圆显示的是最后时刻雷达威胁区所在的位置，其他颜色半透明的半圆则表示各个阶段雷达经过的位置。图 5-5(a)一(c)表示的是各个阶段航迹重规划的效果。从图中可以看出，本文采用的方法在不同阶段可以规划出适应环境变化的，从 UAV 当前位置到目标点的有效重规划航迹。每一阶段的规划都是建立在上一阶段重规划的航迹基础之上，重规划航迹随各阶段的状态迁移逐渐调整，保证最终执行的航迹能够根据威胁区的移动动态做出响应，使动态规划的航迹始终安全可靠。此外，经过模糊空间聚类和 Q 学习优化搜索，可以快速获得有效的重规划航迹。

图 5-6 显示了多个任务协同时，不同阶段协同航迹重规划的效果。图 5-6 中显示不同阶段的航迹的颜色与图 5-5 中相同。从图 5-6 中可以看出，多机协同航迹重规划时，由于采用了空间模糊 C 均值聚类来划分各个任务的状态空间，因此各个任务重规划时都是在自己的状态空间中进行航迹的重规划，因此相互之间具有较好的协同性，重规划的航迹能够有效避免 UAV 之间的碰撞冲突。同时，各个任务重规划的航迹都符合动态规划的结果，因此可以确保重规划的航迹适应各阶段环境的动态变化。然而，部分任务在某个阶段重规划时的机动性比较大，这是因为此时威胁所在位置造成的影响，当威胁区域移出之后，下一阶段的重规划航迹就会有效避免之前的机动，保证 UAV 能够在较优的重规划航迹上执行任务。此外，尽管重规划的航迹虽然不如全局航迹的优化效果，部分位置产生的机动相对较多，但是可以满足在线重规划的时间要求，且可保证各个任务航迹的协同性能。从不同的阶段来


看，随着阶段的递增，航迹重规划的改变逐渐变小，重规划的航迹可以适应环境的动态改变，因此该方法对多机协同的航迹重规划是可行的。



(a) 第一阶段重规划航迹




(b) 第二阶段重规划航迹




(c) 第三阶段重规划航迹

图 5-5 多阶段单机航迹重规划结果


Fig 5-5 The result of multi steps re-planning paths for single UAV



(a) 第一阶段重规划航迹



(b) 第二阶段重规划航迹



(c) 第三阶段重规划航迹

图 5-6 多阶段多机协同航迹重规划结果

Fig 5-6 The result of multi steps re-planning paths for UAVs cooperation

图 5-7 显示了不同阶段, 用 CFCM 聚类划分任务分类的状态空间时, 其目标函数的收敛曲线结果。在任务执行的不同阶段进行 CFCM 聚类, 可以动态反映出当前环境的更新。从图 5-7 中可以看出, 算法重复使用 CFCM 聚类更新空间结构时, 均可以快速收敛到最优的聚类中心, 收敛过程基本相似, 因此在任意阶段, CFCM 均可对规划空间产生较好的任务划分。同时, 较快的收敛速度能够提高聚类算法的效率, 使环境更新时重新聚类不会过多占用算法的执行时间。

表 5-2 显示了各阶段重规划任务的执行时间。从表中可以看出本章采用的算法重规划的执行速度较快, 因此适合于处理航迹重规划问题。此外, 随着阶段的发展, 重规划的时间越来越短, 这是因为阶段递进使重规划的空间逐渐减少的缘故。




图 5-7 多阶段 CFCM 聚类目标函数收敛曲线

Fig 5-7 The convergence curve of objective function for multi steps CFCM clustering

表 5-2 各阶段重规划任务的执行时间

Tab 5-2 The exection time of re-planning on every step

阶 段	任务执行时间(s)								
	t1	t2	t3	t4	t5	t6	t7	t8	t9
阶段1	7.82	10.41	9.20	6.89	11.78	5.80	10.37	8.52	5.41
阶段2	7.21	9.84	8.56	6.90	11.09	5.36	9.79	7.19	5.27
阶段3	5.39	7.19	6.61	6.67	10.61	4.88	8.64	7.88	5.27

5.5.2 比较采用不同回报函数的 Q 学习算法效果

针对空间中某个任务重规划的效果进行比较分析, 将改进的 CFCM 与 Q 学习相结合的重规划方法, 分别与基于标准回报函数的全局 Q 学习方法, 和

基于模糊协同回报函数的全局 Q 学习方法进行了比较。从执行时间上对比这三种方法，并与之前离线全局规划的执行时间进行比较，表 5-3 中给出了比较的结果：

表 5-3 离线规划与重规划执行时间比较

Tab 5-3 The execution time comparison of re-planning and offline planning

方 法	任务执行时间(s)									
	迭代次数	t1	t2	t3	t4	t5	t6	t7	t8	t9
全局标准重规划	5000	8.93	11.53	11.20	6.73	12.82	7.53	11.81	9.33	7.02
全局模糊协同重规划	5000	9.10	11.93	12.14	7.22	13.06	7.98	11.96	10.02	7.64
CFCM模糊协同重规划	5000	7.82	10.41	9.20	6.89	11.78	5.80	10.37	8.52	5.41
全局离线规划	2000	84.33	87.42	79.02	83.01	104.21	77.02	78.76	90.65	75.27

从表 5-3 可以看出，与全局离线规划的执行时间相比，所有重规划的方法执行的速度都非常快，能够满足在线阶段对重规划时间的需求。而本章提出的结合 CFCM 聚类 and 模糊协同回报的 Q 学习重规划方法具有最快的执行时间，这是由于规划空间的约减抵消了聚类算法的执行，保证了算法执行的效率。此外该方法还具有较好的协同性能，因此适合于处理多机的协同航迹重规划问题。

5.5.3 与其他动态规划方法的比较

基于 CFCM 的多 Q 学习算法可以有效对状态空间进行协同划分，提高学习回报准确性，因此可以有效提高航迹重规划的时间性能。为验证其性能的优越性，本节将 CFCM-MQL 算法与 PGA 算法^[77]和部分可测马氏链 POMDP^[95]算法进行航迹重归做了对比实验。各种方法执行重规划的效率和代价如表 5-4 所示。

从表 5-4 中可以看出，本章的 CFCM-MQL 算法在重规划的执行时间上明显优于其他航迹重规划的方法。基于智能优化的 PGA 方法在执行时间上效率最低，因此不适合对时间标准要求高的重规划情况。但是，从重新规划航迹的航程代价上来看，基于智能优化的重规划方法可以获得较优的重规划代价，而 CFCM-MQL 和 POMDP 方法重规划的航迹代价略高，然而对于时间要求更高的重规划问题，这些重规划的代价也是可以接受的，且本章的方法明显优于 POMDP 方法，因此可以看出，改进后的 CFCM-MQL 算法具有较好的重规划性能和较高的效率。

表 5-4 重规划算法的任务代价和执行时间比较

Tab 5-4 The task cost and execution time comparison of re-planning algorithm

任务	CFCM-MQL		PGA		POMDP	
	代价值(km)	时间(s)	代价值(km)	时间(s)	代价值(km)	时间(s)
UAV1	148.38	7.92	140.07	23.21	194.48	11.93
UAV2	221.52	10.31	210.63	32.80	264.73	13.35
UAV3	179.97	9.23	190.32	30.12	182.21	11.20
UAV4	242.33	6.88	220.47	31.55	246.90	6.78
UAV5	301.67	12.01	238.15	38.73	287.19	12.84
UAV6	198.41	6.22	177.82	25.24	223.61	9.34
UAV7	150.16	10.54	149.09	35.06	137.34	15.67
UAV8	249.48	8.47	218.83	28.49	254.38	11.06
UAV9	141.35	5.39	137.59	24.60	140.06	7.64

5.6 本章小结

本章提出了一种结合协同模糊 C 均值聚类划分重规划的任务状态空间，并应用模糊协同矩阵作为回报函数的多 Q 学习协同航迹重规划方法。该方法首先用 CFCM 算法对空间进行聚类划分，然后将不同的分类集合作为对应任务的 Q 学习状态空间，由此降低各个任务重规划的空间复杂程度，并可同时进行多个任务的协同规划，以提高重规划的效率。其次，定义了空间点针对不同任务协同的相关系数，增加了关键路径点的协同性能信息，并将空间点对应的模糊协同矩阵作为 Q 学习的回报函数，以有效指导学习迭代的方向，从而降低了算法搜索的盲目性。最后，针对多机协同问题，采用多 Q 学习的更新公式优化算法的协同执行能力，使算法能够在有效的执行时间内，同时处理多个在线重规划任务。实验结果证明了本方法的有效性。

结 论

多机协同的多目标分配和多航迹规划是 MUAS 任务规划中的重点和难点所在。合理的分配结果、准确的满足全局约束和动态更新的协同航迹组,是确保 MUAS 协同合作、共同完成目标的关键。本文针对 MUAS 多目标分配的统一建模、多目标分配算法的优化、多机协同航迹的快速规划,以及在线阶段的重规划展开研究。通过统一目标分配建模、离散映射差分进化、模糊空间文化算法和协同模糊多阶段多 Q 学习等方法来进行多目标分配和多航迹规划与重规划,能够保证目标分配与航迹规划的结果可行,确保多无人机在执行复杂环境时,有效的协同完成多个复杂任务。本文取得了如下创新性成果:

(1) 建立了基于最优化理论的多机协同目标分配和航迹规划的统一模型,并研究了多种约束和协同约束条件的处理方法。在此基础上扩展指派模型,对各种分配模型统一建模,将不同类型的 MUAS 协同分配问题统一在一致的框架下进行处理;提出基于垂直切面的三维航程代价估算方法,并利用航程代价矩阵优化目标分配算法,提高代价计算的合理性;综合考虑各种多机协同的约束条件,在目标函数中计算约束违背量,提高多机执行多任务的协同性能,保证分配结果更准确更合理;在求解过程中引入部分交叉映射算子,确保差分结果的合理性。

(2) 针对不同模型的协同多目标分配问题,提出了一种适合多种目标分配模型的统一基因编码策略,并通过在基因编码中加入航程代价有效解决了从离散空间到连续空间的转换问题。基于映射和反映射规则提出了适于解决离散组合优化问题的 DMDE 算法,并用能够反映分配关系物理属性的航程代价值进行差分操作。同时根据反映射规则将差分操作的临时结果转换回无人机和目标的对应关系,以获得合理的子代个体。在进化过程中引入动态交叉率和混合进化策略,有效平衡算法的开发性和探测性,并通过引入代间变异机制提高种群的空间覆盖范围,确保算法不会陷入局部最优。结合理论分析与当前常用的算法相比较,改进的 DMDE 算法具有更高的效率,结合航程代价的分配结果更加客观合理,因此,可以在有效的时间内进行 MUAS 协同多目标分配问题求解。

(3) 提出一种基于空间模糊表示的多无人机协同航迹规划方法。定义了基于空间环境信息的模糊隶属度,通过对三维空间的网格点进行模糊化形成空间模糊子集;采用文化算法对航迹规划问题进行建模,在信念集中不断积累空间

模糊信息、历史信息和协同信息,以剪枝航迹规划的搜索空间、保证种群多样性、并为规划提供文化指导依据;在种群集上结合文化信息,利用多目标差分算法快速搜索航迹的关键路径点;通过在子代个体中提炼新的文化信息并积累,降低搜索的盲目性;为使航迹平滑、确保 MUAS 执行任务的可飞行性,提出结合三次 B 样条曲线和反求控制点的三次 B 样条曲线优化三维空间中的协同航迹,使规划后的航迹能够较好的拟合于关键路径点,在保证航迹有效的前提下,减少了路径上的拐点和无效机动。

(4) 提出一种结合协同模糊 C 均值聚类的多机多阶段 Q 学习协同航迹重规划方法。通过对现有规划空间进行聚类划分,将不同的分类集合作为对应任务的规划状态空间,有效降低了重规划的空间复杂程度和多任务协同的复杂性,以提高重规划的效率。定义了空间点针对不同任务协同的相关系数,以增加关键路径点的协同性能表示;同时,将模糊协同矩阵作为 Q 学习的回报函数,有效指导学习迭代的方向,降低算法初始阶段搜索的盲目性。为适应环境的动态改变,有效约减任务规划空间,提出多阶段多 Q 学习优化方法,使算法能够在有效的执行时间内,可重规划出有效的多机协同航迹。

在本文工作的基础上,还有以下工作有待于进一步研究:

(1) 本文提出了统一模型下的多机协同目标分配算法,其中处理问题的重点是满足多机的协同约束和保证目标分配的合理性,虽然统一的模型能够有效处理多机协同的目标分配问题,但是对于目标之间的依赖关系分析较少,需要进一步从目标之间来明确分配的有效性和合理性,从而能够更全面的对分配结果进行有效评估;

此外,当前的方法虽然都能处理一定程度的较大数量分配问题,但是对于未来微型无人机集群化的发展方向来说,实验中设置的无人机和目标点的数量还是不够的,而现有方法对大量、超大量无人机协同的能力依然有限。因此需要在进一步的研究中,着重处理关系和数量的问题。

(2) 本文提出了多机协同的航迹规划和重规划方法,通过模糊集理论对任务规划空间进行更合理的表示,约减了协同航迹规划的规划空间,提高了规划的性能;针对重规划问题,采用动态规划的机器学习模型,保证任务执行过程中实时对环境变化做出响应。在这些研究的基础上,下一步的研究目标是如何利用有选择的通信策略提高实时协同的性能,并侧重于对重规划航迹机动性的优化,以及大幅度增加空间维度和任务数量时的复杂重规划问题的处理。

参考文献

- [1] Office of the Secretary of Defense (OSD), Unmanned aircraft systems (UAS) roadmap 2005-2030 [M]. Defense Technical Information Center, 2005.
- [2] Anthony J M. Control of cooperative and collaborative team tactics in autonomous unmanned aerial vehicles using decentralized model predictive control [D]. Canada: Royal Military College. 2012.
- [3] Department of Defense (DOD). Unmanned systems integrated roadmap FY2013-2038 [Z]. Department of Defense: Office of the Secretary of Defense Unmanned Systems Roadmap, USA. Washington. 2013.
- [4] Kim D H, Lee K, Park M Y, et al. UAV-based localization scheme for battlefield environments [C]. Military Communications Conference, MILCOM 2013-2013 IEEE, 2013: 562-567.
- [5] Joshua A L. Network level control of collaborative UAVs [D]. Berkeley: University of California, 2011.
- [6] Connie N K K, Hugh H T. Dynamic mapping of forest fire fronts using multiple UAVs [C]. AIAA Guidance, Navigation, and Control Conference. 2010.
- [7] Rejas J I, Sanchez A, Glez-de-Rivera G, et al. Environment mapping using a 3D laser scanner for unmanned ground vehicles [J]. Microprocessors and Microsystems, 2015, 39(8): 939-949.
- [8] Martin A Y. Unmanned maritime vehicles: Technology evolution and implications [J]. Marine Technology Society Journal, 2013, 47(5): 72-83.
- [9] Dustin M G. A decentralized cooperative control framework for multiple UAVs [D]. Morgantown: West Virginia University, 2007.
- [10] Sujit P B, Sinha A, Ghose D. Multiple UAV task allocation using negotiation [C]. Proceedings of the Fifth International Joint Conference on Autonomous Agents and Multiagent Systems. ACM, 2006: 471-478.
- [11] Haque M, Egerstedt M, Rahmani A. Multilevel coalition formation strategy for suppression of enemy air defenses missions[J]. Journal of Aerospace Information Systems, 2013, 10(6): 287-296.
- [12] Pikner I, Sivasundaram S. New approaches to the development and

- employment of the UAV [C]. Proceedings of AIP Conference on American Institute of Physics. 2012, 1493(1): 752.
- [13] Baser M, Yorulmaz S, Akgül S. The role of unmanned aerial system (UAS) in decision process by operational environment's risk level[C]. Proceedings of 2013 International Conference on Unmanned Aircraft Systems (ICUAS), IEEE, 2013: 160-166.
- [14] Jeremiah Gertler. U.S.Unmanned Aerial Systems [C]. Library of Congress Washington DC Congressional Research Service, 2012.
- [15] Peng P F, Gong L, Yu Q. Research on architecture for multi-UAV systems based on autonomous cooperation[C]. Proceedings of Trans Tech Publications on Applied Mechanics and Materials. 2015, 713: 825-828.
- [16] 陈小双, 翟为刚, 赵万里. 美国及中国军用无人机的新发展与性能分析[J]. 舰船电子工程, 2011, 31(7): 26-28.
- [17] Tian J, Shen L, Zheng Y. Genetic Algorithm Based Approach for Multi-UAV Cooperative Reconnaissance Mission Planning Problem[J]. Lecture Notes in Computer Science, 2006, 4203:101-110.
- [18] 朱毅, 张涛, 程农, 宋靖雁. 多 UAV 协同任务规划研究[J]. 系统仿真学报. 2009, 20:194-199.
- [19] 赵振宇, 卢广山, 廖沫, 陈宗基. 基于 DTC 和 GPDP 的多 UCAV 任务规划方法[J]. 北京航空航天大学学报. 2011, 37(3): 305-310.
- [20] 郑昌文, 严平, 丁明跃,等. 飞行器航迹规划研究现状与趋势[J]. 宇航学报, 2007, 28(6): 1441-1446.
- [21] Kuriki Y, Namerikawa T. Consensus-based cooperative formation control with collision avoidance for a multi-UAV system[C]. Proceedings of 2014 American Control Conference. IEEE, 2014: 2077-2082.
- [22] Tal Shima, Steven J Rasmussen, Andrew G Sparks. Multiple task assignments for cooperating uninhabited aerial vehicles using genetic algorithms [J]. Computers Operations Research, 2005, 33(2006) 3252-3269.
- [23] Shuyan T, Zheng Q, Jiankuan X. Collaborative task assignment scheme for multi-UAV based on cluster structure [C]. Proceedings of 2nd International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC). IEEE, 2010, 2: 285-289.
- [24] Kuhn H W. The Hungarian method for the assignment problem [J]. Naval

- research logistics quarterly, 1955, 2(1-2): 83-97.
- [25] Nagarajan R, Solairaju A. Computing improved fuzzy optimal Hungarian assignment problems with fuzzy costs under robust ranking techniques [J]. International Journal of Computer Application, 2010, 6(4):6-13.
- [26] Bellingham J, Tillerson M, Richards A, et al. Multi-task allocation and path planning for cooperating UAVs [M]. Cooperative Control: Models, Applications and Algorithms. Springer US, 2003: 23-41.
- [27] Alighanbari M, Kuwata Y, How J P. Coordination and control of multiple uavs with timing constraints and loitering [C]. Proceedings of American Control Conference, 2003. IEEE, 2003, 6: 5311-5316.
- [28] Alighanbari M, How J P. Cooperative task assignment of unmanned aerial vehicles in adversarial environments [C]. Proceedings of American Control Conference, 2005. IEEE, 2005: 4661-4666.
- [29] Mehdi A. Task assignment algorithms for teams of UAVs in dynamic environments [D]. Massachusetts Institute of Technology, 2004.
- [30] Jeong B M, Ha J S, Choi H L. MDP based mission planning for multi-UAV persistent surveillance [C]. Proceedings of 14th International Conference on Control, Automation and Systems (ICCAS), 2014. Korea: IEEE, 2014: 831-834.
- [31] 龙涛, 朱华勇, 沈林成. 多 UCAV 协同中基于协商的分布式任务分配研究 [J]. 宇航学报, 2006, 27(3): 457-462.
- [32] Li Y W, Li B A. Research of Multiple UAVs Task Allocation Based on Improved Contract Net[C] Proceedings of Trans Tech Publications on Advanced Materials Research. 2013, 823: 439-444.
- [33] Kim M G, Shin S H, Lee E B, et al. Modified Consensus Based Auction Algorithm for Task Allocation of Multiple Unmanned Aerial Vehicle[J]. Journal of the Korea Society for Simulation, 2014, 23(4): 197-202.
- [34] Gartenberg D, Breslow L A, McCurry J M, et al. Time pressure, memory, and task knowledge facilitate the opportunism heuristic in dynamic tasks [C]. Proceedings of the Human Factors and Ergonomics Society Annual Meeting. SAGE Publications, 2012, 56(1): 1025-1029.
- [35] Moon S, Oh E, Shim D H. An integral framework of task assignment and path planning for multiple unmanned aerial vehicles in dynamic environments [J]. Journal of Intelligent & Robotic Systems, 2013, 70(1-4): 303-313.

- [36] Wen Y, Liu L, Wang Z, et al. Multi-UCAVs targets assignment using opposition based genetic algorithm [C]. Proceedings of 27th Chinese Control and Decision Conference (CCDC). IEEE, 2015: 6026-6030.
- [37] Zuo Y, Peng Z, Liu X. Task allocation of multiple UAVs and targets using improved genetic algorithm [C]. Proceedings of 2nd International Conference on Intelligent Control and Information Processing (ICICIP). IEEE, 2011, 2: 1030-1034.
- [38] Eun Y, Bang H. Cooperative task assignment/path planning of multiple unmanned aerial vehicles using genetic algorithm [J]. Journal of Aircraft, 2009, 46(1): 338-343.
- [39] Zhao Z, Lu G. Receding horizon control for cooperative search of multi-UAVs based on differential evolution [J]. International Journal of Intelligent Computing and Cybernetics, 2012, 5(1): 145-158.
- [40] Shen Y, Li J, Li P, et al. Task allocation based on the immune network adjusted by the leukocyte in the multi-robot systems [J]. Information Technology Journal, 2014, 13(1): 60.
- [41] Trianni V, López-Ibáñez M. Advantages of task-specific multi-objective optimisation in evolutionary robotics [J]. PloS one, 2015, 10(8): e0136406.
- [42] 宋敏, 魏瑞轩, 冯志明. 基于差分进化算法的异构多无人机任务分配. 系统仿真学报, 2010, 22(7): 1706-1710.
- [43] Engelbrecht A P. Computational intelligence: an introduction [M]. John Wiley & Sons, 2007.
- [44] Wang Xinzeng, Ci Linlin, Li Junshan, Yu Ning. Based on PSO algorithm multiple task assignments for cooperating UAVs [C]. International Conference on Educational and Information Technology. 2010.
- [45] Choudhury B B, Biswal B B. A PSO based multi-robot task allocation [J]. International Journal of Computational Vision and Robotics, 2011, 2(1): 49-61.
- [46] Souravlias D, Parsopoulos K E. Particle swarm optimization with neighborhood based budget allocation [J]. International Journal of Machine Learning and Cybernetics, 2014: 1-27.
- [47] Shinn-Ying Ho, Hung-Sui Lin, Weei-Hurng Liauh, Shinn-Jang Ho. OPSO: Orthogonal particle swarm optimization and its application to task assignment problems [J]. IEEE Transactions on Systems, Man, and Cybernetics. 2008,

38(2):288-298.

- [48] Aleksandar Jevtic, Aldo Jaimes. Unmanned aerial vehicle route optimization using ant system algorithm [C]. 5th International Conference on System of Systems Engineering. 2010.
- [49] Chang W.L, Zeng D, Chen R.C, et al. An artificial bee colony algorithm for data collection path planning in sparse wireless sensor networks [J]. International Journal of Machine Learning and Cybernetics, 2013: 1-9.
- [50] Liu Zhong, Quan Luo, Ding Wen, et al. A task assignment algorithm for multiple aerial Vehicles to attack targets with dynamic values [J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(1), 236-248.
- [51] Zaza T, Richards A. Ant colony optimization for routing and tasking problems for teams of UAVs [C]. Proceedings of 2014 UKACC International Conference on Control. Loughborough, UK: IEEE, 2014: 652-655.
- [52] Tsourdos A, White B, Shanmugavel M. Cooperative path planning of unmanned aerial vehicles [M]. John Wiley & Sons, 2010.
- [53] 马培军, 毛云云, 张洪涛, 等. 基于 3DSAS 的多约束多航迹协同规划与搜索方法[J]. 系统工程与电子技术, 2011(7):1527-1533.
- [54] Mitsutake, K. Higashino, S.I. An A*-EC hybrid path planning method for waypoint traveling problem considering terrain [C]. Proceedings of AIAA Guidance Navigation and Control Conference. AIAA. 2008, 7133: 2008.
- [55] 任波, 周焘, 于雷. 基于改进 A* 算法的飞行器三维航迹规划算法[J]. 系统工程与电子技术, 2008, 30(2):324-326.
- [56] Meng Bo-bo. Gao Xiaoguang. UAV Path Planning based on bidirectional sparse A* search algorithm [C]. Proceedings of 2010 International Conference on Intelligent Computation Technology and Automation. IEEE, 2010:1106-1109.
- [57] Meng Z J, Huang P F, Yan J. Trajectory planning for hypersonic vehicle using improved sparse A* algorithm [C]. The 2008 IEEE/ASME International Conference on Advanced Intelligent Mechatronics. 2008.
- [58] Yao M, Zhao M. Cooperative Attack Strategy of Unmanned Aerial Vehicles in Adversarial Environment[J]. Intelligent Automation & Soft Computing, 2013, 19(3): 487-496.
- [59] Geng L, Zhang Y F, Wang J, et al. Cooperative mission planning with multiple

- UAVs in realistic environments[J]. Unmanned Systems, 2014, 2(01): 73-86.
- [60] Dai, R. Cochran, J. Path planning and state estimation for unmanned aerial vehicles in hostile environments [J]. Journal of Guidance, Control, and Dynamics, 2010, 33(2): 595-601.
- [61] Pehlivanoglu, Y.V. A new vibrational genetic algorithm enhanced with a voronoi diagram for path planning of autonomous UAV [J]. Aerospace Science and Technology, 2012, 16(1): 47-55.
- [62] KhatibO. Real time obstacle avoidance for manipulators and mobiles robots [J]. International Journal of Robotics Research, 1986, 5(1): 90-99.
- [63] Daily, R. Bevly, D.M. Harmonic potential field path planning for high speed vehicles [C]. American Control Conference, 2008. IEEE, 2008: 4609-4614.
- [64] Cetin, O. Zagli, I. Yilmaz, G. Establishing obstacle and collision free communication relay for UAVs with artificial potential fields [J]. Journal of Intelligent & Robotic Systems, 2013, 69(1-4): 361-372.
- [65] Edison E, Shima T. Integrated task assignment and path optimization for cooperating uninhabited aerial vehicles using genetic algorithms [J]. Computers & Operations Research, 2011, 38(1): 340-356.
- [66] Nikolos I K, Valavanis K P, Tsourveloudis N C, et al. Evolutionary algorithm based offline/online path planner for UAV navigation [J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics. 2003, 33(6): 898-912.
- [67] Nikolos I K, Brintaki A N. Coordinated UAV path planning using differential evolution [C]. Proceedings of the 2005 IEEE International Symposium on, Mediterrean Conference on Control and Automation. IEEE, 2005: 549-556.
- [68] Mittal S, Deb K. Three-dimensional offline path planning for UAVs using multiobjective evolutionary algorithms [C]. Proceedings of the Congress on Evolutionary Computation (CEC-2007), Singapore, 2007: 3195-3202.
- [69] Ozalp N, Sahingoz O K. Optimal UAV path planning in a 3D threat environment by using parallel evolutionary algorithms [C]. Proceedings of International Conference on Unmanned Aircraft Systems (ICUAS). 2013: 308-317.
- [70] Shen X. A quantum evolutionary algorithm for robot path planning in dynamic environment[C] Proceedings of 32nd Chinese Control Conference (CCC). IEEE, 2013: 8061-8065.

- [71] Cheng Z, Sun Y, Liu Y. Path planning based on immune genetic algorithm for UAV [C]. Electric Information and Control Engineering (ICEICE), 2011 International Conference on. IEEE, 2011: 590-593.
- [72] Hasircioglu I, Topcuoglu H R, Ermis M. 3D path planning for the navigation of unmanned aerial vehicles by using evolutionary algorithms [C]. Proceedings of the 10th Annual Conference on Genetic and Evolutionary Computation. ACM, 2008: 1499-1506.
- [73] Foo J.L, Knutzon J, Kalivarapu V, et al. Path planning of unmanned aerial vehicles using B-splines and particle swarm optimization [J]. Journal of Aerospace Computing, Information, and Communication, 2009, 6(4): 271-290.
- [74] Karimi J, Pourtakdoust S H. Optimal maneuver-based motion planning over terrain and threats using a dynamic hybrid PSO algorithm [J]. Aerospace Science and Technology, 2013, 26(1): 60-71.
- [75] Alejo D, Cobano J A, Heredia G, et al. Particle swarm optimization for collision free 4d trajectory planning in unmanned aerial vehicles [C]. Proceedings of International Conference on Unmanned Aircraft Systems (ICUAS). IEEE, 2013: 298-307.
- [76] Fu Y, Ding M, Zhou C, et al. Route planning for unmanned aerial vehicle (UAV) on the sea using hybrid differential evolution and quantum-behaved particle swarm optimization [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2013, 43(6): 1451-1465.
- [77] Roberge V, Tarbouchi M, Labont é G. Comparison of parallel genetic algorithm and particle swarm optimization for real-time UAV path planning [J]. IEEE Transactions on Industrial Informatics, 2013, 9(1): 132-141.
- [78] Hai bin Duan, Xiang yin Zhang, Jiang Wu, Guan jun Ma. Max-min adaptive ant colony optimization approach to multi-UAVs coordinated trajectory replanning in dynamic and uncertain environments [J]. Journal of Bionics Engineering, 2009, 6(2):161-173.
- [79] Tang Bi wei, Zhu Zhan xia, Fang Qun, etc. Planning and re-planning 3D route of UAV using improved ant colony algorithm [J]. Journal of Northwestern Polytechnical University, 2013, 31(6): 901-907.
- [80] Alves R M F, Lopes C R, Branquinho A A B. Generating plans using LRTA[C] Proceedings of Brazilian Conference on Intelligent Systems (BRACIS). IEEE,

- 2013: 207-212..
- [81] Eslami A, Asadi S, Soleymani G R, et al. A real-time global optimal path planning for mobile robot in dynamic environment based on artificial immune approach [J]. Journal on Computing (JoC), 2014, 2(1).
- [82] Horn J F, Schmidt E M, Geiger B R, et al. Neural network-based trajectory optimization for unmanned aerial vehicles [J]. Journal of Guidance, Control, and Dynamics, 2012, 35(2): 548-562.
- [83] 安柏义. 多无人机系统协同航迹规划研究[D]. 南京: 南京航空航天大学. 2008.01.
- [84] Surynek P. Towards optimal cooperative path planning in hard setups through satisfiability solving[C] Proceedings of Pacific Rim International Conference on Artificial Intelligence. Springer Berlin Heidelberg, 2012: 564-576..
- [85] Berger J, Boukhtouta A, Benmoussa A, et al. A new mixed-integer linear programming model for rescue path planning in uncertain adversarial environment [J]. Computers & Operations Research, 2012, 39(12): 3420-3430.
- [86] Zucker M, Kuffner J, Branicky M. Multipartite RRTs for rapid replanning in dynamic environments [C]. Proceedings of IEEE International Conference on Robotics and Automation. IEEE, 2007: 1603-1609.
- [87] Hanqiao H, Wei Z, Xin Z, et al. Study on 4D path planning and tracking controlling of UCAV in multiple constraints dynamic condition [C]. Proceedings of 33rd Chinese Control Conference (CCC). IEEE, 2014: 31-36.
- [88] Dicheva S, Bestaoui Y. Three-Dimensional A* Dynamic Mission Planning for an Airborne Launch Vehicle[J]. Journal of Aerospace Information Systems, 2014, 11(2): 98-106..
- [89] Wagner G, Choset H. M. A complete multirobot path planning algorithm with performance bounds [C]. Proceedings of IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2011: 3260-3267.
- [90] Besada Portas E, de la Torre L, de la Cruz J M, et al. Evolutionary trajectory planner for multiple UAVs in realistic scenarios [J]. IEEE Transactions on Robotics, 2010, 26(4): 619-634.
- [91] Kok J, Gonzalez L F, Kelson N. FPGA implementation of an evolutionary algorithm for autonomous unmanned aerial vehicle on-board path planning [J]. IEEE Transactions on Evolutionary Computation, 2013, 17(2): 272-281.

- [92] Lu L, Gong D. Robot path planning in unknown environments using particle swarm optimization [C]. Proceedings of ICNC'08 Fourth International Conference on Natural Computation. IEEE, 2008, 4: 422-426.
- [93] Liu X, Yi H, Ni Z. Application of ant colony optimization algorithm in process planning optimization[J]. Journal of Intelligent Manufacturing, 2013, 24(1): 1-13.
- [94] Al-Sabban W H, Gonzalez L F, Smith R N. Wind energy based path planning for unmanned aerial vehicles using markov decision processes [C]. Proceedings of International Conference on Robotics and Automation (ICRA). IEEE, 2013: 784-789.
- [95] Ragi S, Chong E K P. UAV path planning in a dynamic environment via partially observable markov decision process [J]. IEEE Transactions on Aerospace and Electronic Systems, 2013, 49(4): 2397-2412.
- [96] Feyzabadi S, Carpin S. Risk aware path planning using hirerachical constrained markov decision processes [C]. Proceedings of International Conference on Automation Science and Engineering (CASE). IEEE, 2014: 297-303.
- [97] Zhang B, Mao Z, Liu W, et al. Geometric reinforcement learning for path planning of UAVs [J]. Journal of Intelligent & Robotic Systems, 2015, 77(2): 391-409.
- [98] Yang H, Guo Q, Xu X, et al. Self-learning PD algorithms based on approximate dynamic programming for robot motion planning[C] Proceedings of International Joint Conference on Neural Networks (IJCNN). IEEE, 2014: 3663-3670.
- [99] Konar A, Chakraborty I G, Singh S J, et al. A deterministic improved Q-learning for path planning of a mobile robot [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2013, 43(5): 1141-1153.
- [100] Asl S V, Davarzani Z, Staji S. Planning flying robot navigation in a three-dimensional space by optimaztion combining Q-learning and monte carlo algorithms[J]. International Journal of Hybrid Information Technology, 2015, 8(11): 297-306..
- [101] Ben-Asher Y, Feldman S, Gurfil P, et al. Distributed decision and control for cooperative UAVs using ad-hoc communication [J]. IEEE Transactions on

- Control Systems Technology. 2008, 16(3): 511-516.
- [102] Yu Y, Ru L, Chi W, et al. Ant colony optimization based polymorphism aware routing algorithm for ad hoc UAV network[J]. Multimedia Tools and Applications, 2016: 1-26..
- [103] Pohl A J, Lamont G B. Multi-objective UAV mission planning using evolutionary computation [C]. Proceedings of the 40th Conference on Winter Simulation. Winter Simulation Conference, 2008: 1268-1279.
- [104] Darrah M, Niland W, Stolarik B, et al. UAV cooperative task assignments for a SEAD mission using genetic algorithms [C]. Proceedings of AIAA Guidance, Navigation, and Control Conference and Exhibit, AIAA, Keystone, Colorado, 2006.
- [105] Godfrey C. Onwubolu, Donald Davendra. Differential evolution: a handbook for global permutation-based combinatorial optimization [M]. Springer-Verlag Berlin Heidelberg. 2009.
- [106] R. Joshi and A.C. Sanderson. Minimal representation multisensory fusion using differential evolution [J]. IEEE Transactions on Systems, Man and Cybernetics, Part A: Systems and Humans. 1999, 29(1): 63-76.
- [107] Barlow G J, Oh C K, Smith S F. Evolving cooperative control on sparsely distributed tasks for UAV teams without global communication [C]. Proceedings of the 10th Annual Conference on Genetic and Evolutionary Computation. ACM, 2008: 177-184.
- [108] Bethke B, Valenti M, How J P. UAV task assignment [J]. Robotics & Automation Magazine, IEEE, 2008, 15(1): 39-44.
- [109] 刘毅, 李为民, 邢清华等. 基于双层规划的攻击无人机协同目标分配优化[J]. 系统工程与电子技术, 2010, 32(3):579-583.
- [110] Humphrey L, Cohen K. Application of proper orthogonal decomposition and artificial neural networks to multiple UAV task assignment [C]. Invited Paper, AIAA Guidance, Navigation, and Control Conference, AIAA, 2010-8439.
- [111] Hoai A.L.T, Duc M.N, Tao P.D. Globally solving a nonlinear UAV task assignment problem by stochastic and deterministic optimization approaches [J]. Optimization Letters, 2012,6(2):315-329.
- [112] Storn R, Price K. Differential evolution a simple and efficient heuristic for

- global optimization over continuous spaces [J]. Journal of Global Optimization, 1997, 11(4): 341-359.
- [113] Epitropakis M G, Tasoulis D K, Pavlidis N G, et al. Enhancing differential evolution utilizing proximity based mutation operators [J]. IEEE Transactions on Evolutionary Computation. 2011, 15(1): 99-119.
- [114] Zamuda A, Brest J, Boskovic B, et al. Large scale global optimization using differential evolution with self-adaptation and cooperative co-evolution [C]. Proceedings of World Congress on Computational Intelligence: Evolutionary Computation, 2008: 3718-3725.
- [115] Fu Y, Yu X, Zhang Y. Sense and collision avoidance of unmanned aerial vehicles using Markov decision process and flatness approach[C] Proceedings of Information and Automation. IEEE, 2015: 714-719.
- [116] Zimmermann H J. Fuzzy set theory and its applications [M]. Springer Science & Business Media, 2001.
- [117] Garcia M A P, Montiel O, Castillo O, et al. Path planning for autonomous mobile robot navigation with ant colony optimization and fuzzy cost function evaluation [J]. Applied Soft Computing, 2009, 9(3): 1102-1110.
- [118] Reynolds, R.G. An introduction to cultural algorithms [C]. Proceedings of the Third Annual Conference on Evolutionary Programming. Singapore, 1994: 131-139.
- [119] Yang G. A Discretization Algorithm Based on Cultural Immune Algorithm[J]. Advances in Information Sciences and Service Sciences, 2013, 5(10): 595.
- [120] Sun, Y. Zhang, L. Gu, X. A hybrid co-evolutionary cultural algorithm based on particle swarm optimization for solving global optimization problems [J]. Neuro Computing, 2012, 98: 76-89.
- [121] 郭一楠, 王辉, 程健. 自适应免疫克隆选择文化算法 [J]. 电子学报, 2010, 38(4): 966-0972.
- [122] Becerra, R.L. Coello, C.A.C. A cultural algorithm with differential evolution to solve constrained optimization problems [M]. Advances in Artificial Intelligence IBERAMIA 2004. Springer Berlin Heidelberg, 2004: 881-890.
- [123] Jung D, Tsiotras P. On-line path generation for unmanned aerial vehicles

- using B-spline path templates [J]. Journal of Guidance, Control, and Dynamics, 2013, 36(6): 1642-1653.
- [124] Elbanhawi M, Simic M, Jazar R N. Continuous path smoothing for car-like robots using B-spline curves[J]. Journal of Intelligent & Robotic Systems, 2015, 80(1): 23-56.
- [125] Lu P, Dong H, Zhai H, et al. Fuzzy C-means based on cooperative QPSO with learning Behavior[C] Proceedings of International Conference on Intelligent Science and Big Data Engineering. Springer International Publishing, 2015: 343-351.
- [126] Watkins C J C H, Dayan P. Q-learning [J]. Machine Learning, 1992, 8(3-4): 279-292.
- [127] Gao X, Fang Y, Wu Y. Fuzzy Q learning algorithm for dual-aircraft path planning to cooperatively detect targets by passive radars [J]. Journal of Systems Engineering and Electronics. 2013, 24(5): 800-810.
- [128] Hao Chuan-chuan, Fang Zhou, Li Ping. A 3D route planning algorithm for UAV based on Q-learning [J]. Journal of Shanghaijiaotong, 2012, 12: 011.
- [129] 许亚. 基于强化学习的移动机器人路径规划研究[D]. 山东: 山东大学, 2013.
- [130] Xu X, Lian C, Zuo L, et al. Kernel-based approximate dynamic programming for real-time online learning control: an experimental study[J]. IEEE Transactions on Control Systems Technology, 2014, 22(1): 146-156.

攻读博士学位期间发表的论文及其它成果

- [1] 赵明, 苏小红, 马培军, 赵玲玲. 复杂多约束 UAVs 协同目标分配的一种统一建模方法. 自动化学报, 2012, 38(12): 2038-2048, EI 收录号: 20130315915474
- [2] Zhao Ming, Zhao Lingling, Su Xiaohong, Ma Peijun, Zhang Yanhang. Improved discrete mapping differential evolution for multi-unmanned aerial vehicles cooperative multi-targets assignment under unified model. International Journal of Machine Learning and Cybernetics. DOI 10.1007/s13042-015-0364-3, 2015, SCI(E)刊源
- [3] Su Xiaohong, Zhao Ming, Zhao Lingling, Zhang Yanhang. A novel multi stage cooperative path re-planning method for multi UAV. Proceedings of The 14th Pacific Rim International Conference on Artificial Intelligence (PRICAI-2016).2016.8 (已录用), CCF 推荐(C 区)
- [4] 赵明, 赵玲玲, 苏小红, 马培军, 张彦航. 一种三维多 UAV 协同航迹规划的空间模糊文化算法. 哈尔滨工业大学学报. 2015, 47(10): 29-34, EI 收录号: 20154901636716
- [5] Zhao Ming, Zhao Lingling, Su Xiaohong, Ma Peijun, Zhang Yanhang. A Cooperative Path Planning and Smoothing Algorithm for UAVs in Three Dimensional Environment. Instrumentation and Measurement, Computer, Communication and Control (IMCCC), 2014 Fourth International Conference on. IEEE, 2014: 274-278. DOI 10.1109/IMCCC.2014.64, EI 收录号: 20150500470185
- [6] 赵明, 李涛, 苏小红, 赵玲玲, 张彦航. 三维多无人机系统协同任务规划关键问题综述. 智能计算机与应用.2016, 6(1): 31-35.

致 谢

本文是在我的导师苏小红教授的悉心指导下完成的，在此首先向我的导师苏小红教授表达最衷心的感谢！几年来，苏老师对我的学习和工作悉心指导，谆谆教诲，在科研上给予了大力的支持和帮助；对日常生活等方面，苏老师也无微不至的关怀和照顾。攻读博士学位期间，在论文的选题、开题以及博士论文撰写的各个阶段，苏老师都给予了我耐心细致的指导。苏老师渊博的知识、远见的学术洞察力、严谨的治学态度和执着的敬业精神使我受益匪浅。没有苏老师耐心的指导和热情的鼓励，我的博士论文工作就不能顺利完成。在此，谨向恩师致以由衷的敬意和衷心的感谢！

同时感谢赵玲玲老师、张彦航老师、以及实验室的师兄师姐、师弟师妹们，谢谢你们对我课题研究、学术交流、论文写作等方面给予的大力帮助。同时感谢所有对我的论文提出宝贵意见和建议的老师、同学、专家和教授们，是您们的帮助使我的论文和研究能够顺利完成。此外，还要感谢我原单位的那些一直顶着各种压力支持我继续深造学习的同事和领导们，谢谢你们的理解和帮助。

万分感谢我的父母和亲人，是他们的理解、支持和一直以来寄予的厚望，才使我能全身心地投入学习；是他们的鼓励和寄托，使我能够在最艰难的时刻获得继续前进的勇气和力量。谨以此文，告慰父亲的在天之灵，愿您可以在另一个世界获得安息。

我还要由衷感谢我的爱人王月、女儿赵紫涵，是她们在我面对艰难抉择之时，始终陪在我的身边，默默的支持和鼓励着我继续前行，不离不弃地陪我走过了这段难以忘怀的求学岁月。

怀着一颗感恩的心，在此论文完成之际，谨向给予我无私帮助和关怀的人们致以最诚挚的谢意！

